Perceptrón simple y Adaline

Compuertas lógicas, Iris y autenticación de billetes

Taller 1 – Informe

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 17 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

1. Introducción

En este taller implementé una neurona de una sola capa con dos modelos: el perceptrón simple, con las tres reglas de corrección de pesos del enunciado, y Adaline, con la regla delta. Los dos quedaron parametrizables (entradas, umbral, regla, α, épocas) y se probaron en compuertas AND y OR de 2, 3 y 4 entradas y en dos conjuntos reales: Iris (Setosa contra el resto) y *data_banknote_authentication*, con particiones 60-40, 70-30, 80-20 y 90-10. El enunciado pide scripts de MATLAB; los hice en Python (Jupyter), replicando la lógica de *Dataset_train_test.mlx*.

Entregables: el cuaderno `taller1_perceptron_adaline.ipynb` ejecutado, `requirements.txt`, la carpeta `bibliografia/` con *data_banknote_authentication.txt* (el cuaderno lee el archivo desde esa ruta) y este informe. Todo el desarrollo quedó grabado en video (sección 7).

2. Marco teórico

Perceptrón simple. La entrada se aumenta con un 1 para que w_0 haga de sesgo: $X = [1, x_1, \ldots, x_n]$. La neurona calcula $z = W \cdot X$ y responde $Y = 1$ si $z \geq \theta$, y $Y = 0$ en otro caso. Después de cada ejemplo los pesos se ajustan con $W^* = W + \Delta W$, usando una de tres reglas:

$$(1)\ \Delta W = d\,X \qquad (2)\ \Delta W = (d - Y)\,X \qquad (3)\ \Delta W = \alpha\,(d - Y)\,X$$

El teorema de convergencia del perceptrón garantiza que las reglas 2 y 3 terminan en un número finito de pasos si las clases son linealmente separables. La regla 1 no usa el error: corrige igual cuando la respuesta es correcta.

Adaline. Usa la misma suma ponderada, pero el ajuste se hace con la salida *lineal* $Y = W \cdot X$, sin escalón: $\Delta W = \alpha\,(d - Y)\,X$ (regla delta). Esto es descenso de gradiente sobre el error cuadrático, así que Adaline minimiza el MSE y no el número de errores. El escalón con umbral θ solo se usa para clasificar.

3. Metodología

Entorno. Python 3.12 con numpy, pandas y matplotlib; scikit-learn solo para cargar Iris. Todos los parámetros están en el diccionario `PARAMS` al inicio del cuaderno (tabla 1). Las clases `Perceptron` y `Adaline` reciben como argumentos el número de entradas, el umbral, la regla, α, el máximo de épocas y, en Adaline, la tolerancia; los experimentos (compuertas, número de entradas, reglas, valores de α, particiones y semilla) también se leen de `PARAMS`, así que cualquier corrida se cambia sin editar el código.

Tabla 1: Parámetros de los experimentos (`PARAMS`).

Parámetro	Perceptrón	Adaline
Pesos iniciales	ceros	ceros
Umbral θ	0 y 0,5 (compuertas); 0 (datasets)	0,5
Regla	1, 2 y 3	delta
α	0,01; 0,1; 0,5; 1	0,001; 0,01; 0,05; 0,1
Máximo de épocas	100	200
Criterio de parada	una época sin errores	cambio del MSE $< 10^{-6}$ o divergencia
Semilla de partición	2021	2021
Compuertas	AND, OR de 2, 3 y 4 entradas	AND, OR de 2, 3 y 4 entradas
Particiones	60-40, 70-30, 80-20, 90-10	60-40, 70-30, 80-20, 90-10

Compuertas. Se generan todas las combinaciones de entradas binarias (2^n filas) con `itertools.product`; la salida deseada es AND u OR de la fila.

Particiones (puntos 4, 5, 10 y 11). La función `particionar` hace lo mismo que *Dataset_train_test.mlx*: fija la semilla, permuta los índices y corta según la proporción. El generador de numpy no produce la misma permutación que `randperm` de MATLAB, así que las particiones son equivalentes pero no idénticas. Iris tiene 150 muestras (50 Setosa = 1, 100 resto = 0). Banknote tiene 1372 muestras con 4 atributos (762 de clase 0 y 610 de clase 1); como sus escalas son distintas, se normaliza con la media y la desviación del entrenamiento y esas mismas estadísticas se aplican a la prueba. En Adaline también se normaliza Iris.

4. Resultados

4.1. Perceptrón en compuertas (punto 3)

La tabla 2 resume las épocas hasta converger. Las reglas 2 y 3 convergen en todos los casos con 100 % de exactitud; la regla 1 llega siempre al máximo de 100 épocas.

Tabla 2: Épocas hasta converger del perceptrón (100 = no convergió). Regla 3 con $\alpha = 0{,}1$.

		Regla 1		Regla 2		Regla 3	
Compuerta	Entradas	$\theta = 0$	$\theta = 0{,}5$	$\theta = 0$	$\theta = 0{,}5$	$\theta = 0$	$\theta = 0{,}5$
AND	2	100	100	6	6	4	3
AND	3	100	100	7	7	3	4
AND	4	100	100	16	16	17	2
OR	2	100	100	4	4	4	2
OR	3	100	100	5	5	5	2
OR	4	100	100	6	6	6	3

Con la regla 1 los pesos solo crecen: en AND de 2 entradas terminan en $[100, 100, 100]$ y la exactitud queda

en 25 % (AND-3: 12,5 %; AND-4: 6,25 %; OR-2: 75 %; OR-4: 93,75 %). La figura 1 muestra los errores por época de las tres reglas en AND y OR de 2 entradas.

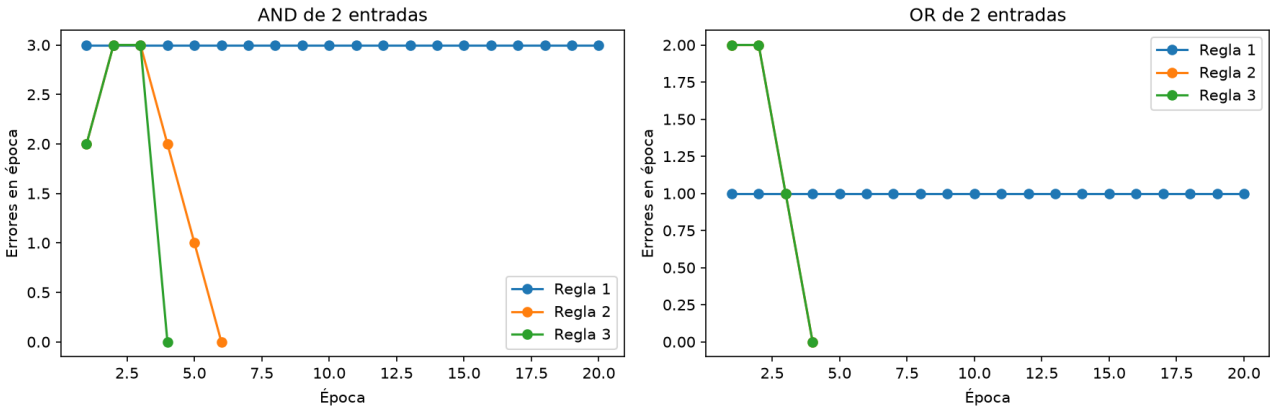


Figura 1: Errores por época del perceptrón en AND y OR de 2 entradas ($\theta = 0$, $\alpha = 0{,}1$).

La tabla 3 cruza α y θ en la regla 3.

Tabla 3: Épocas de la regla 3 según α y el umbral θ.

		$\theta = 0$				$\theta = 0{,}5$			
Compuerta	Entradas	0,01	0,1	0,5	1	0,01	0,1	0,5	1
AND	2	6	4	6	6	18	3	6	6
AND	3	7	3	7	7	14	4	7	7
AND	4	16	17	16	16	11	2	16	16
OR	2	4	4	4	4	13	2	4	4
OR	3	5	5	5	5	8	2	5	5
OR	4	6	6	6	6	6	3	6	6

4.2. Perceptrón en datos reales (puntos 4 a 6)

La tabla 4 muestra el perceptrón en las cuatro particiones de cada conjunto. En Iris converge siempre; en banknote llega al máximo de épocas en todas las particiones, pero con exactitud de prueba alta.

Tabla 4: Perceptrón (regla 3, $\theta = 0$) en Iris y banknote. El resultado es el mismo para los cuatro valores de α.

	Iris (Setosa / resto)			Banknote			
Partición	Train / test	Épocas	Test	Train / test	Épocas	Train	Test
60-40	90 / 60	2	100 %	823 / 549	100	98,30 %	97,27 %
70-30	105 / 45	2	100 %	960 / 412	100	99,27 %	99,03 %
80-20	120 / 30	2	100 %	1097 / 275	100	98,91 %	98,91 %
90-10	135 / 15	2	100 %	1234 / 138	100	99,19 %	98,55 %

4.3. Adaline (puntos 7 a 12)

La tabla 5 muestra la exactitud de Adaline en las compuertas y la figura 2 el MSE por época en OR de 2 entradas para distintos α, incluidos 0,5 y 1 para ver el límite de estabilidad.

Tabla 5: Exactitud de Adaline ($\theta = 0{,}5$) en compuertas según α.

Compuerta	Entradas	0,001	0,01	0,05	0,1
AND	2	75 %	100 %	100 %	100 %
AND	3	87,5 %	87,5 %	100 %	100 %
AND	4	93,75 %	93,75 %	93,75 %	100 %
OR	2	100 %	100 %	100 %	100 %
OR	3	100 %	100 %	87,5 %	87,5 %
OR	4	93,75 %	93,75 %	93,75 %	93,75 %

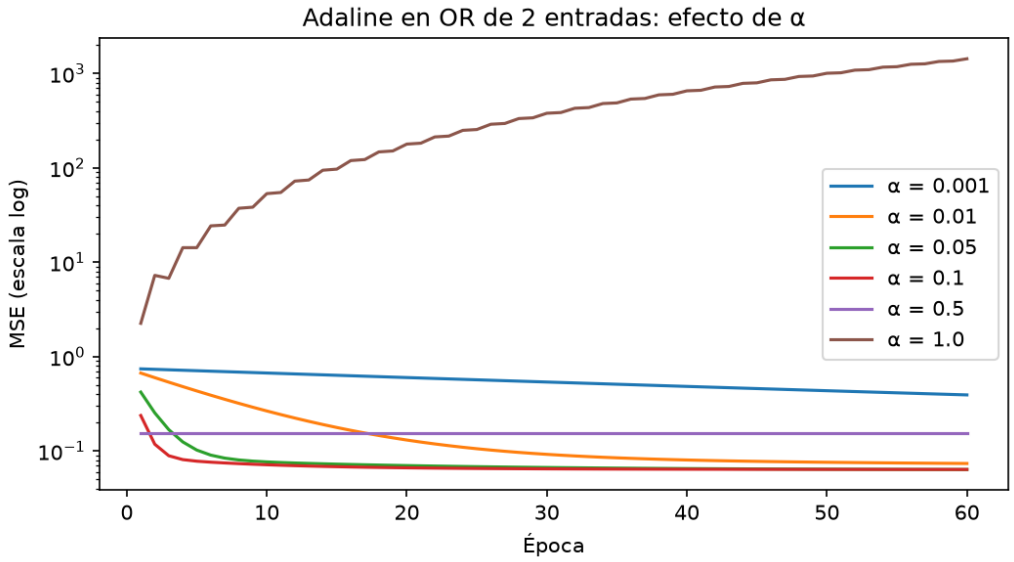


Figura 2: MSE por época de Adaline en OR de 2 entradas (60 épocas, escala logarítmica).

La tabla 6 muestra Adaline en las particiones de banknote: la exactitud de prueba varía entre 96,1 % y 97,5 % y ningún α es mejor en todas. Después de 60 épocas, el MSE en OR-2 es 0,393 con $\alpha = 0{,}001$, 0,074 con 0,01 y 0,064 con 0,05 y 0,1. Con $\alpha = 0{,}5$ se queda fijo en 0,156 desde la primera época y con $\alpha = 1$ crece hasta 1428.

Tabla 6: Exactitud de prueba de Adaline en banknote según α (en Iris es 100 % en todos los casos salvo 98,3 % con $\alpha = 0{,}1$ en 60-40).

Partición	0,001	0,01	0,05	0,1
60-40	96,54 %	96,36 %	96,54 %	97,09 %
70-30	96,36 %	96,12 %	97,09 %	97,33 %
80-20	96,73 %	97,45 %	97,09 %	97,09 %
90-10	96,38 %	96,38 %	97,10 %	96,38 %

4.4. Comparación

La tabla 7 reúne la mejor exactitud de prueba de cada modelo por partición.

Tabla 7: Mejor exactitud de prueba por partición (máximo sobre α).

Partición	Perceptrón Iris	Adaline Iris	Perceptrón banknote	Adaline banknote
60-40	100 %	100 %	97,27 %	97,09 %
70-30	100 %	100 %	99,03 %	97,33 %
80-20	100 %	100 %	98,91 %	97,45 %
90-10	100 %	100 %	98,55 %	97,10 %

5. Análisis

La regla 1 no aprende. $\Delta W = d\,X$ no depende de la respuesta Y: cada ejemplo con $d = 1$ suma su entrada a los pesos y los ejemplos con $d = 0$ no restan nada. Los pesos solo crecen y la neurona termina respondiendo 1 para todas las entradas; por eso su exactitud es exactamente la proporción de unos de la compuerta (25 % en AND-2, 75 % en OR-2). Con $\theta = 0{,}5$ pasa lo mismo.

El efecto de α depende del umbral. Con $\theta = 0$ y pesos iniciales en cero, todos los pesos son múltiplos de α, así que el signo de z no cambia al escalar y la frontera es la misma: casi todas las columnas de $\theta = 0$ en la tabla 3 coinciden con la regla 2. Las diferencias en $\alpha = 0{,}1$ (4 épocas en AND-2, 17 en AND-4) vienen del redondeo de punto flotante en los empates $z = 0$: $0{,}1 + 0{,}2 - 0{,}3$ no da exactamente cero. Con $\theta = 0{,}5$ el umbral fija una escala y α sí importa: con 0,01 los pasos son pequeños frente al umbral y AND-2 tarda 18 épocas; con 0,1 tarda 3; con 0,5 y 1 los pasos son tan grandes que el umbral deja de pesar y se repiten las épocas de $\theta = 0$.

Iris y banknote. Setosa es linealmente separable del resto, y el perceptrón converge en 2 épocas con 100 % en prueba en todas las particiones. Banknote no es perfectamente separable: el perceptrón nunca termina una época sin errores y siempre llega a 100 épocas, pero la frontera que encuentra clasifica entre 97,3 % y 99,0 % en prueba. Como los pesos parten de cero y $\theta = 0$, α tampoco cambia el resultado aquí. La partición 60-40 es la más baja porque tiene menos datos para entrenar.

Adaline. Al minimizar el MSE, Adaline busca la recta de mínimos cuadrados y no la que separa sin errores, así que no siempre clasifica bien todas las filas aunque la compuerta sea separable (OR-4 se queda en 93,75 % con todos los α). Un α muy pequeño no alcanza a bajar el error en 200 épocas (AND-2 con 0,001: 75 %). La figura 2 muestra el límite de estabilidad: hasta 0,1 el MSE baja al mínimo de 0,064; con 0,5 la actualización oscila entre dos valores y el MSE no se mueve; con 1 los pesos se disparan y el error diverge.

Perceptrón contra Adaline. En Iris los dos llegan a 100 %. En banknote el perceptrón queda por encima en las cuatro particiones (tabla 7): Adaline converge en pocas épocas al mínimo del MSE, pero ese mínimo no es la frontera con menos errores de clasificación.

6. Conclusiones

1. Las reglas 2 y 3 del perceptrón resolvieron todas las compuertas AND y OR de 2, 3 y 4 entradas (regla 2: AND en 6, 7 y 16 épocas; OR en 4, 5 y 6). La regla 1 no convergió en ninguna, porque sin el término de error los pesos solo crecen y la neurona responde 1 para todo.
2. Con $\theta = 0$ y pesos en cero, α solo escala los pesos y no cambia la frontera. Con $\theta = 0{,}5$ sí importa: en AND-2, $\alpha = 0{,}01$ necesitó 18 épocas y $\alpha = 0{,}1$, 3.
3. En Iris (Setosa contra el resto) el perceptrón convergió en 2 épocas con 100 % en prueba. En banknote no convergió en 100 épocas, pero alcanzó entre 97,3 % y 99,0 % en prueba.
4. Adaline necesita un α pequeño: en OR-2, con 0,05 y 0,1 llega al MSE mínimo (0,064), con 0,5 se estanca y con 1 diverge. Como minimiza el MSE y no los errores, no clasifica perfecto todas las compuertas (OR-4: 93,75 %).
5. En banknote el perceptrón superó a Adaline en las cuatro particiones (mejor caso 99,0 % contra 97,5 %); en Iris los dos llegaron a 100 %.

7. Declaración de uso de IA

Usé Claude (Anthropic) para revisar y corregir errores y para redactar este informe a partir de los resultados del cuaderno. Todo el desarrollo quedó grabado (cerca de 2 horas y 40 minutos):

https://youtu.be/TNVHhuWUC0g