



Perceptrón Multicapa (MLP) y Algoritmo de Retropropagación: Implementación Vectorizada, Dinámica de Hiperparámetros, Representación en Espacios Latentes y Regularización por Parada Temprana



Maestría en Ciencias de la Información y las Comunicaciones
(MCIC)

Inteligencia Computacional Aplicada – Docente: Cesar Andrey Perdomo
Charry

Estudiante: Juan Felipe Rodríguez Galindo — Código: 20261595004

Resumen

En el presente trabajo se desarrolla, formaliza analíticamente y evalúa exhaustivamente el modelo del **Perceptrón Multicapa** (*Multilayer Perceptron*, MLP) optimizado mediante el algoritmo de **Retropropagación del Error** (*Backpropagation*) y la regla delta generalizada con momento inercial β . La totalidad de la arquitectura de software fue diseñada e implementada desde primeros principios matemáticos en Python exclusivamente con la librería NumPy, proscribiendo el empleo de módulos de diferenciación automática o cajas negras comerciales. Se demuestra analítica y geoméricamente la superación de la barrera histórica de no-separabilidad lineal impuesta por Minsky y Papert (1969) sobre compuertas lógicas canónicas (XOR de 2 y 3 entradas), alcanzando una exactitud de clasificación perfecta del **100.0 %** frente al colapso asintótico del Perceptrón Simple (50.0 %) y de Adaline (50.0 % – 75.0 %). Se realiza un barrido de alta densidad en el plano de hiperparámetros $(\eta, \beta) \in [0.1, 2.0] \times [0.0, 1.0]$, comprobando que la adición del momento inercial induce una aceleración del **87.4 %** en el número de épocas hasta la convergencia ($\beta = 0.9$ vs. $\beta = 0.0$), a la vez que amortigua oscilaciones transversales en cañones de gradiente escarpado. Asimismo, se evalúa la capacidad discriminativa multiclase y multivariable sobre cuatro conjuntos de datos continuos de referencia: **Fisher's Iris** (93.33 % en test), **Wine Recognition** (100.0 %), **Breast Cancer Wisconsin Diagnostic** (98.25 %) y **Banknote Authentication** (100.0 %), garantizando estricta prevención de fuga de información (*data leakage*) mediante estandarización z-score calculada únicamente sobre entrenamiento en cuatro particiones reproducibles (60-40, 70-30, 80-20 y 90-10). A través de proyecciones en componentes principales (PCA), se evidencia cómo las capas ocultas ejecutan un desenredo no lineal continuo de la variedad geométrica de los datos. Finalmente, se modela la patología del sobreajuste en una red sobreparametrizada de 4097 parámetros (14.43 parámetros por muestra), demostrando cuantitativamente que la parada temprana (*Early Stopping*) reduce el error cuadrático en prueba en un **16.65 %**, contrae la brecha de generalización en un **37.23 %** y provee un ahorro computacional del **95.73 %**, consolidándose como un regularizador implícito de norma sináptica equivalente al decaimiento de pesos L_2 .

Palabras clave: Perceptrón Multicapa, Backpropagation, Regla Delta Generalizada, Momento Inercial, Espacios Latentes, Sobreajuste, Parada Temprana, Data Leakage.

Abstract

This research presents the analytical derivation, software engineering, and experimental assessment of the **Multilayer Perceptron** (MLP) trained via the **Backpropagation** algorithm with generalized momentum β . The software framework was implemented from first mathematical principles in pure Python and NumPy, deliberately avoiding high-level automatic differentiation libraries. We analytically and geometrically validate the resolution of the non-linearly separable parity paradox formulated by Minsky and Papert (1969) on 2-bit and 3-bit XOR gates, attaining an exact **100.0%** test accuracy against the systematic breakdown of Rosenblatt's Simple Perceptron (50.0%) and Widrow-Hoff's Adaline (50.0% – 75.0%). A high-resolution parameter sweep over the $(\eta, \beta) \in [0.1, 2.0] \times [0.0, 1.0]$ manifold reveals that the inertial momentum term provides an **87.4%** computational acceleration in convergence epochs ($\beta = 0.9$ vs. $\beta = 0.0$) while dampening cross-valley gradient oscillations. Furthermore, multiclass and high-dimensional generalization capabilities were validated across four canonical continuous benchmarks: **Fisher's Iris** (93.33% test accuracy), **Wine Recognition** (100.0%), **Breast Cancer Wisconsin Diagnostic** (98.25%), and **Banknote Authentication** (100.0%). Strict avoidance of data leakage was enforced through z-score feature scaling computed exclusively on training partitions across 60-40, 70-30, 80-20, and 90-10 stratified splits. Dimensionality reduction via Principal Component Analysis (PCA) uncovers the topological disentanglement of non-linear input manifolds within the latent representations of hidden layers. Lastly, overfitting dynamics were explored on an overparameterized architecture (4097 trainable parameters, 14.43 parameter-to-sample ratio), proving that **Early Stopping** curtails test mean squared error by **16.65%**, narrows the generalization gap by **37.23%**, and yields a **95.73%** computational economy, behaving as an implicit weight decay regularizer.

Keywords: Multilayer Perceptron, Backpropagation, Generalized Delta Rule, Inertial Momentum, Latent Representations, Overfitting, Early Stopping, Data Leakage.

1. Introducción

La computación neuronal moderna experimentó su génesis a mediados del siglo XX a partir de dos arquitecturas lineales pioneras: el **Perceptrón Simple** concebido por Frank Rosenblatt en 1958 [?] y la red **Adaline** (*Adaptive Linear Neuron*) desarrollada por Bernard Widrow y Ted Hoff en 1960 [?]. Ambos modelos demostraron la viabilidad de ajustar pesos sinápticos mediante mecanismos adaptativos guiados por la señal de error. No obstante, compartían una restricción matemática intrínseca y categórica: la toma de decisiones basada en una única transformación lineal seguida de una función umbral o identidad. En consecuencia, la frontera de separación entre clases en el espacio de características $\mathbb{R}^D$ queda confinada indefectiblemente a un hiperplano de dimensión $D - 1$.

Esta rigidez topológica fue rigurosamente formalizada por Marvin Minsky y Seymour Papert en su célebre monografía de 1969 [?]. Los autores demostraron que operadores lógicos no lineales elementales, tales como la disyunción exclusiva (XOR) y la paridad de N bits, son geoméricamente insolubles para cualquier clasificador monocapa. Al no existir un hiperplano capaz de aislar los vértices conexos en el hipercubo booleano, las reglas de Rosenblatt y Widrow-Hoff fracasan sistemáticamente: el Perceptrón oscila indefinidamente sin converger, mientras que Adaline converge hacia un hiperplano degenerado de compromiso que minimiza el error cuadrático medio ($MSE \approx 0.25$) pero preserva una tasa de error de clasificación de al menos el 25 % – 50 %. Esta demostración precipitó el denominado primer “invierno de la inteligencia artificial”, producto de la incapacidad técnica de extender el aprendizaje hacia capas intermedias (ocultas) debido a la ausencia de una regla analítica para asignar crédito o responsabilidad del error a las neuronas que no tienen contacto directo con la salida deseada.

El renacimiento de las redes conexionistas tuvo lugar en 1986 de la mano de David Rumelhart, Geoffrey Hinton y Ronald Williams [?], quienes formularon formalmente la regla delta generalizada y el algoritmo de **Retropropagación del Error** (*Backpropagation*). Al sustituir las funciones de activación discontinuas de tipo escalón por funciones sigmoideas continuas y derivables en todo su dominio ($\sigma(z) \in (0, 1)$), y aplicar sistemáticamente la regla de la cadena del cálculo diferencial multivariable, fue posible propagar las señales de gradiente hacia atrás, desde la capa de salida hacia las capas ocultas. Esta formulación facultó a las redes neuronales multicapa (*Multilayer Perceptrons*, MLP) para aprender representaciones jerárquicas internas, resolviendo definitivamente el problema de la no-separabilidad lineal.

En este marco, el presente trabajo persigue seis objetivos de ingeniería e investigación aplicada:

1. **Implementación vectorizada desde primeros principios:** Construir una arquitectura orientada a objetos en NumPy puro para instanciar perceptrones multicapa con topologías arbitrarias, inicialización sináptica formal (Xavier/Glorot y He), múltiples activaciones y modos de optimización (*online*, *batch* y *mini-batch*).
2. **Validación analítica y geométrica en XOR:** Demostrar la convergencia perfecta del MLP en compuertas de disyunción exclusiva de 2 y 3 entradas, contrastando su dinámica de aprendizaje frente al colapso de los modelos lineales del Taller 1.
3. **Caracterización de hiperparámetros y aceleración inercial:** Cuantificar mediante barridos exhaustivos en mallas bidimensionales el impacto de la tasa de aprendizaje η y el coeficiente de momento $\beta \in [0, 1)$, corroborando su analogía con la mecánica de partículas amortiguadas.
4. **Análisis de espacios latentes:** Visualizar la deformación geométrica y el desenredo topológico de las variedades de datos a través de las capas ocultas utilizando reducciones dimensionales de componentes principales (PCA).
5. **Evaluación multiclase y multivariable con particiones reproducibles:** Evaluar el MLP sobre cuatro conjuntos de datos continuos (*Iris*, *Wine*, *Breast Cancer* y *Banknote*) bajo particiones estratificadas de 60-40, 70-30, 80-20 y 90-10, garantizando estricta ausencia de fuga de información (*zero data leakage*).
6. **Estudio sistemático de sobreajuste y parada temprana:** Modelar la descomposición sesgo-varianza en una arquitectura sobreparametrizada y evaluar la eficacia de *Early Stopping* como técnica de regularización implícita.

El resto del manuscrito se estructura de la siguiente forma: la Sección 2 expone la formulación matemática detallada y la derivación paso a paso de Backpropagation; la Sección 3 describe la arquitectura de software, los conjuntos de datos y el protocolo experimental; la Sección 4 presenta los hallazgos empíricos y cuantitativos; la Sección 5 ofrece un análisis multidimensional comparativo; la Sección 6 sintetiza las conclusiones principales; y la Sección 7 lista las referencias bibliográficas.

2. Marco Teórico y Formulación Matemática

2.1. Topología de Red y Propagación Hacia Adelante (*Forward Pass*)

Considérese una red neuronal multicapa compuesta por L capas de procesamiento, indexadas por $l = 0, 1, \dots, L$, donde $l = 0$ representa la capa de entrada sensorial, $l \in \{1, \dots, L-1\}$ designa las capas ocultas intermedias, y $l = L$ denota la capa de salida. Cada capa l consta de n_l unidades de cómputo (neuronas).

Para cada capa de transición $l \in \{1, \dots, L\}$, los parámetros sinápticos entrenables están definidos por la matriz de pesos interconectores $W^{(l)} \in \mathbb{R}^{n_{l-1} \times n_l}$ y el vector fila de sesgos (*biases*) $b^{(l)} \in \mathbb{R}^{1 \times n_l}$. Dado un vector de entrada de activación $a^{(l-1)} \in \mathbb{R}^{1 \times n_{l-1}}$ (donde $a^{(0)} = x \in \mathbb{R}^{1 \times n_0}$), la propagación hacia adelante se rige por las siguientes ecuaciones fundamentales:

$$z^{(l)} = a^{(l-1)}W^{(l)} + b^{(l)} \quad (1)$$

$$a^{(l)} = f^{(l)}(z^{(l)}) \quad (2)$$

donde $z^{(l)} \in \mathbb{R}^{1 \times n_l}$ denota el vector de potenciales netos de activación (combinación lineal afín) y $f^{(l)} : \mathbb{R} \rightarrow \mathbb{R}$ representa la función de activación no lineal evaluada componente a componente. Para una muestra individual, la componente escalar j -ésima en la capa l adopta la forma escalar:

$$z_j^{(l)} = \sum_{i=1}^{n_{l-1}} a_i^{(l-1)} W_{ij}^{(l)} + b_j^{(l)}, \quad a_j^{(l)} = f^{(l)}(z_j^{(l)}) \quad (3)$$

La Figura 1 ilustra la topología genérica de un perceptrón multicapa, detallando la propagación hacia adelante de las señales de excitación y la posterior retropropagación de los gradientes locales de error.




Figura 1: Diagrama topológico estructural de un Perceptrón Multicapa (MLP) ilustrando la cinemática de la propagación hacia adelante y el flujo retrógrado de los gradientes locales de error.

2.2. Derivación Analítica Rigurosa del Algoritmo de Retropropagación (*Backpropagation*)

Considérese un conjunto de datos de entrenamiento supervisado $\mathcal{D} = \{(x^{(p)}, y^{(p)})\}_{p=1}^N$, donde $x^{(p)} \in \mathbb{R}^{n_0}$ representa el patrón de entrada y $y^{(p)} \in \mathbb{R}^{n_L}$ el vector de etiquetas deseadas (*target*). Para una muestra dada, la función de costo cuadrática instantánea (*Mean Squared Error* o pérdida de mínimos cuadrados) se formula analíticamente como:

$$J(W, b) = \frac{1}{2} \|y - a^{(L)}\|^2 = \frac{1}{2} \sum_{k=1}^{n_L} (y_k - a_k^{(L)})^2 \quad (4)$$

donde el factor $\frac{1}{2}$ se introduce canónicamente para simplificar la constante multiplicativa resultante de la diferenciación.

El objetivo de la optimización consiste en computar las derivadas parciales exactas de la función de costo con respecto a cada peso sináptico $W_{ij}^{(l)}$ y cada sesgo $b_j^{(l)}$, denotadas por $\frac{\partial J}{\partial W_{ij}^{(l)}}$ y $\frac{\partial J}{\partial b_j^{(l)}}$. Para estructurar el cálculo de

manera modular, se define el **término de error local** (o gradiente respecto al potencial neto) de la neurona j en la capa l como:

$$\delta_j^{(l)} \equiv -\frac{\partial J}{\partial z_j^{(l)}} \quad (5)$$

Esta convención de signo positivo para el error residual $e_k = (y_k - a_k)$ coincide fielmente con la derivación canónica de Rumelhart, Hinton y Williams [?] y la regla delta estándar, de modo que el paso de actualización por descenso de gradiente adopta la forma aditiva:

$$W_{ij}^{(l)}(t+1) = W_{ij}^{(l)}(t) - \eta \frac{\partial J}{\partial W_{ij}^{(l)}} = W_{ij}^{(l)}(t) + \eta \Delta W_{ij}^{(l)} \quad (6)$$

donde $\Delta W_{ij}^{(l)} = a_i^{(l-1)} \delta_j^{(l)}$ y $\eta > 0$ es la tasa de aprendizaje.

2.2.1. 1. Gradiente del Error en la Capa de Salida ($l = L$)

Aplicando la regla de la cadena del cálculo diferencial sobre la neurona de salida $k \in \{1, \dots, n_L\}$:

$$\frac{\partial J}{\partial z_k^{(L)}} = \frac{\partial J}{\partial a_k^{(L)}} \frac{\partial a_k^{(L)}}{\partial z_k^{(L)}} \quad (7)$$

Diferenciando la función de costo (4) respecto a la activación de salida $a_k^{(L)}$:

$$\frac{\partial J}{\partial a_k^{(L)}} = \frac{\partial}{\partial a_k^{(L)}} \left[\frac{1}{2} \sum_{p=1}^{n_L} (y_p - a_p^{(L)})^2 \right] = -(y_k - a_k^{(L)}) \quad (8)$$

Puesto que $a_k^{(L)} = f^{(L)}(z_k^{(L)})$, la derivada respecto al potencial neto es:

$$\frac{\partial a_k^{(L)}}{\partial z_k^{(L)}} = f'^{(L)}(z_k^{(L)}) \quad (9)$$

Sustituyendo ambos términos en la definición (5), se obtiene el error local de salida:

$$\delta_k^{(L)} = - \left[-(y_k - a_k^{(L)}) f'^{(L)}(z_k^{(L)}) \right] = (y_k - a_k^{(L)}) f'^{(L)}(z_k^{(L)}) \quad (10)$$

En notación matricial fila para la capa de salida:

$$\delta^{(L)} = (y - a^{(L)}) \odot f'^{(L)}(z^{(L)}) \quad (11)$$

donde $\odot$ denota el producto de Hadamard (multiplicación elemento a elemento).

2.2.2. 2. Retropropagación del Gradiente a las Capas Ocultas ($l = L - 1, \dots, 1$)

Para una neurona intermedia j ubicada en una capa oculta l , la variación de su potencial neto $z_j^{(l)}$ afecta a la función de costo J indirectamente a través de todas las neuronas $k \in \{1, \dots, n_{l+1}\}$ de la capa subsiguiente $l + 1$. Aplicando la regla de la cadena multivariable:

$$\frac{\partial J}{\partial z_j^{(l)}} = \sum_{k=1}^{n_{l+1}} \frac{\partial J}{\partial z_k^{(l+1)}} \frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}} \quad (12)$$

Reescribiendo en términos de los errores locales $\delta_k^{(l+1)} = -\frac{\partial J}{\partial z_k^{(l+1)}}$:

$$-\delta_j^{(l)} = \sum_{k=1}^{n_{l+1}} (-\delta_k^{(l+1)}) \frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}} \implies \delta_j^{(l)} = \sum_{k=1}^{n_{l+1}} \delta_k^{(l+1)} \frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}} \quad (13)$$

Para descomponer el término de acoplamiento inter-capas $\frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}}$, se utiliza la variable de activación intermedia $a_j^{(l)}$:

$$\frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}} = \frac{\partial z_k^{(l+1)}}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \quad (14)$$

El potencial neto en la capa $l + 1$ está dado por $z_k^{(l+1)} = \sum_{p=1}^{n_l} a_p^{(l)} W_{pk}^{(l+1)} + b_k^{(l+1)}$. Diferenciando respecto a $a_j^{(l)}$:

$$\frac{\partial z_k^{(l+1)}}{\partial a_j^{(l)}} = W_{jk}^{(l+1)} \quad (15)$$

Asimismo, puesto que $a_j^{(l)} = f^{(l)}(z_j^{(l)})$, su derivada es $\frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} = f'^{(l)}(z_j^{(l)})$. Sustituyendo estas relaciones en (13):

$$\delta_j^{(l)} = \left(\sum_{k=1}^{n_{l+1}} \delta_k^{(l+1)} W_{jk}^{(l+1)} \right) f'^{(l)}(z_j^{(l)}) \quad (16)$$

La ecuación (16) constituye el núcleo matemático de Backpropagation: el error local de una neurona oculta es directamente proporcional al producto de la sensibilidad no lineal de su función de activación $f'(z_j^{(l)})$ y la suma ponderada de los errores locales provenientes de la capa posterior transmitidos a través de los pesos sinápticos transcurridos $W_{jk}^{(l+1)}$.

En notación matricial compacta y vectorizada para toda la capa l :

$$\delta^{(l)} = \left(\delta^{(l+1)} (W^{(l+1)})^T \right) \odot f'^{(l)}(z^{(l)}) \quad (17)$$

donde $\delta^{(l+1)} \in \mathbb{R}^{1 \times n_{l+1}}$, $(W^{(l+1)})^T \in \mathbb{R}^{n_{l+1} \times n_l}$, y el producto vectorial-matricial genera un vector fila de dimensión $1 \times n_l$.

2.2.3. 3. Gradientes de Parámetros Sinápticos ($\nabla_W J$ y $\nabla_b J$)

Una vez determinados los vectores de error local $\delta^{(l)}$ para todas las capas $l \in \{1, \dots, L\}$, el cálculo de los gradientes de pesos y sesgos se efectúa de manera directa mediante la regla de la cadena:

$$\frac{\partial J}{\partial W_{ij}^{(l)}} = \frac{\partial J}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial W_{ij}^{(l)}} = -\delta_j^{(l)} a_i^{(l-1)} \implies \nabla_{W^{(l)}} J = -(a^{(l-1)})^T \delta^{(l)} \quad (18)$$

$$\frac{\partial J}{\partial b_j^{(l)}} = \frac{\partial J}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial b_j^{(l)}} = -\delta_j^{(l)} (1) \implies \nabla_{b^{(l)}} J = -\delta^{(l)} \quad (19)$$

Para un lote de N patrones procesados simultáneamente, donde $A^{(l-1)} \in \mathbb{R}^{N \times n_{l-1}}$ y $\Delta^{(l)} \in \mathbb{R}^{N \times n_l}$:

$$\nabla_{W^{(l)}} J = -(A^{(l-1)})^T \Delta^{(l)}, \quad \nabla_{b^{(l)}} J = -\sum_{p=1}^N \Delta_p^{(l)} = -\mathbf{1}_N^T \Delta^{(l)} \quad (20)$$

2.3. Regla Delta Generalizada con Momento Inercial (β)

El descenso de gradiente estándar en superficies de error altamente anisotrópicas (caracterizadas por valles estrechos donde la curvatura en una dirección transversal es órdenes de magnitud superior a la pendiente a lo largo del fondo del valle) padece de severas oscilaciones oscilatorias perpendiculares al curso óptimo, ralentizando drásticamente la tasa de avance longitudinal.

Para subsanar esta deficiencia, Rumelhart et al. [?] incorporaron la **Regla Delta Generalizada**, que introduce una memoria inercial o término de momento $\beta \in [0, 1]$:

$$\Delta W^{(l)}(t) = \eta (a^{(l-1)})^T \delta^{(l)} + \beta \Delta W^{(l)}(t-1) \quad (21)$$

$$\Delta b^{(l)}(t) = \eta \delta^{(l)} + \beta \Delta b^{(l)}(t-1) \quad (22)$$

$$W^{(l)}(t+1) = W^{(l)}(t) + \Delta W^{(l)}(t) \quad (23)$$

$$b^{(l)}(t+1) = b^{(l)}(t) + \Delta b^{(l)}(t) \quad (24)$$

2.3.1. Analogía Mecánica y Análisis Espectral

Desde la perspectiva de la física clásica, la actualización con momento equivale a la simulación numérica por diferencias finitas de una partícula puntual de masa unitaria que se desplaza sobre una hipersuperficie potencial $J(w)$ sometida a una fuerza de amortiguamiento viscoso proporcional a su velocidad [?]:

$$m \frac{d^2 w}{dt^2} + \gamma \frac{dw}{dt} = -\nabla J(w) \quad (25)$$

Desarrollando la ecuación en serie temporal retrospectiva para un gradiente constante g :

$$\Delta w(t) = \eta g \sum_{k=0}^t \beta^k \xrightarrow{t \rightarrow \infty} \frac{\eta}{1-\beta} g \quad (26)$$

Este resultado analítico revela dos propiedades críticas:

1. **Amplificación asintótica longitudinal:** En direcciones donde el gradiente conserva su signo a lo largo de iteraciones sucesivas (el lecho del valle o mesetas planas), la velocidad de avance efectivo se escala por un factor $\frac{1}{1-\beta}$. Para $\beta = 0.9$, la tasa efectiva de paso se amplifica por un factor de $10\times$.
2. **Cancelación por interferencia destructiva transversal:** En direcciones donde el gradiente oscila alternando su signo entre pasos subsecuentes ($g(t) \approx -g(t-1)$), los términos sucesivos se anulan mutuamente, suprimiendo las oscilaciones parásitas y estabilizando el trayecto de optimización.
3. **Criterio de estabilidad espectral:** La convergencia está garantizada si y solo si $\beta < 1$. Cuando $\beta \geq 1.0$, el sistema entra en régimen de amplificación no disipativa (resonancia), produciendo la divergencia infinita de los pesos y el estancamiento numérico.

2.4. Catálogo Exhaustivo de Funciones de Activación y sus Derivadas

La no-linealidad introducida por la función de activación $f(z)$ es la propiedad que faculta al MLP para aproximar funciones arbitrarias. En la Tabla 1 se compendian formalmente las funciones implementadas en el núcleo de cómputo junto con sus derivadas analíticas y rangos de salida.

Tabla 1: Formulación matemática y derivadas analíticas del catálogo de activaciones.

Función	Ecuación Directa $f(z)$	Derivada Analítica $f'(z)$	Rango $\mathcal{R}_f$	Saturación
Sigmoide	$\sigma(z) = \frac{1}{1+e^{-z}}$	$\sigma(z)(1 - \sigma(z)) = a(1 - a)$	$(0, 1)$	$ z > 4 \implies f' \rightarrow 0$
Tanh	$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	$1 - \tanh^2(z) = 1 - a^2$	$(-1, 1)$	$ z > 3 \implies f' \rightarrow 0$
ReLU	$\max(0, z)$	$\begin{cases} 1 & z > 0 \\ 0 & z \leq 0 \end{cases}$	$[0, \infty)$	$z < 0 \implies$ Neurona Muerta
Lineal	$f(z) = z$	$f'(z) = 1$	$(-\infty, \infty)$	No satura
Softmax	$s_i(z) = \frac{e^{z_i - \max(z)}}{\sum_j e^{z_j - \max(z)}}$	$\frac{\partial s_i}{\partial z_j} = s_i(\delta_{ij} - s_j)$	$(0, 1), \sum s_i = 1$	Probabilística multiclase

Deducción del Jacobiano de Softmax: Para la función Softmax en problemas multiclase, la derivada cruzada respecto a la entrada neta z_j se obtiene aplicando la regla del cociente:

$$\frac{\partial s_i}{\partial z_j} = \frac{\frac{\partial e^{z_i}}{\partial z_j} \sum_k e^{z_k} - e^{z_i} \frac{\partial \sum_k e^{z_k}}{\partial z_j}}{(\sum_k e^{z_k})^2} = \frac{\delta_{ij} e^{z_i}}{\sum_k e^{z_k}} - \frac{e^{z_i} e^{z_j}}{(\sum_k e^{z_k})^2} = s_i \delta_{ij} - s_i s_j = s_i(\delta_{ij} - s_j) \quad (27)$$

donde δ_{ij} representa el delta de Kronecker ($\delta_{ij} = 1$ si $i = j$, y 0 en caso contrario).

2.5. Teorema de Aproximación Universal y Linealización en Espacios Latentes

La solvencia del Perceptrón Multicapa para resolver tareas no lineales descansa sobre el **Teorema de Aproximación Universal**, demostrado rigurosamente por George Cybenko en 1989 para activaciones sigmoideas [?] y generalizado por Kurt Hornik en 1991 para cualquier función de activación no constante y acotada [?]:

Sea I_n el hipercubo unitario compacto $[0, 1]^n$ en $\mathbb{R}^n$ y sea $C(I_n)$ el espacio de funciones continuas sobre I_n . Dada cualquier función continua $f \in C(I_n)$ y cualquier umbral de tolerancia arbitrario $\epsilon > 0$, existe una suma finita de la forma:

$$G(x) = \sum_{j=1}^M \alpha_j \sigma(w_j^T x + \theta_j) \quad (28)$$

tal que $|G(x) - f(x)| < \epsilon$ para todo $x \in I_n$.

2.5.1. Mecanismo de Desenredo en el Espacio Latente

La interpretación geométrica moderna de este teorema establece que las capas ocultas no computan simplemente combinaciones lineales sucesivas, sino que inducen un mapeo continuo no lineal (difeomorfismo) $\Phi : \mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_1}$ que deforma la variedad de datos. Patrones que están inextricablemente entrelazados o solapados en el espacio de entrada son proyectados hacia un espacio latente de representación $H^{(l)} = a^{(l)}$ donde la frontera óptima de decisión entre clases se endereza, transformándose en una variedad linealmente separable para la capa de salida final $W^{(L)}$.

2.6. Descomposición Sesgo-Varianza y Regularización por Parada Temprana (*Early Stopping*)

Desde la teoría estadística del aprendizaje, el error esperado de generalización de un modelo predictivo $\hat{f}(x; w)$ condicionado a una muestra de datos aleatoria $\mathcal{D}$ se descompone aditivamente en tres términos ortogonales [?]:

$$\mathbb{E}_{\mathcal{D}} \left[(y - \hat{f}(x; w))^2 \right] = \underbrace{\left(f(x) - \mathbb{E}_{\mathcal{D}}[\hat{f}(x)] \right)^2}_{\text{Sesgo}^2 \text{ (Incapacidad de ajuste)}} + \underbrace{\mathbb{E}_{\mathcal{D}} \left[(\hat{f}(x) - \mathbb{E}_{\mathcal{D}}[\hat{f}(x)])^2 \right]}_{\text{Varianza (Sensibilidad muestral)}} + \underbrace{\sigma_{\epsilon}^2}_{\text{Ruido irreducible}} \quad (29)$$

A medida que el proceso de entrenamiento transcurre a lo largo de épocas continuas ($t \rightarrow \infty$):

- El **Sesgo** decrece asintóticamente hacia cero ($\text{Sesgo}^2 \rightarrow 0$), dado que la red expande la curvatura de sus hiperplanos para envolver cada instancia individual de entrenamiento.
- La **Varianza** se incrementa explosivamente ($\text{Varianza} \rightarrow \infty$), pues la red ajusta las fluctuaciones estocásticas y el ruido del conjunto empírico, provocando la pérdida catastrófica de generalización (*overfitting*).

2.6.1. Equivalencia Analítica entre Early Stopping y Decaimiento de Pesos L_2

Existe una correspondencia matemática directa entre el número de iteraciones de descenso de gradiente y la penalización de Tikhonov o regularización L_2 (*Weight Decay*) [?]. Aproximando la superficie de costo mediante una expansión de Taylor cuadrática alrededor del mínimo óptimo w^* con matriz Hessiana H :

$$w(t) = [I - (I - \eta H)^t] w^* \quad (30)$$

Por su parte, la solución analítica regularizada con penalización $\frac{\lambda}{2} \|w\|^2$ satisface:

$$w_{\text{reg}} = (H + \lambda I)^{-1} H w^* \quad (31)$$

Comparando el filtrado espectral en las bases ortonormales de autovectores del Hessiano, se comprueba que detener el entrenamiento en la época óptima t^* impone una cota estricta sobre la norma del vector de pesos $\|w(t)\|_2 \leq R(t^*)$, actuando como un regularizador implícito donde el parámetro efectivo de penalización es inversamente proporcional al tiempo de entrenamiento:

$$\lambda_{\text{efectivo}} \approx \frac{1}{\eta t^*} \quad (32)$$

En consecuencia, *Early Stopping* restringe la capacidad de memorización sin requerir la selección heurística de coeficientes de peso en la función de costo.

3. Metodología Experimental y Diseño de Software

3.1. Arquitectura de Software Orientada a Objetos en NumPy Puro

Para asegurar independencia tecnológica, transparencia pedagógica y máximo rendimiento computacional, se diseñó e implementó una arquitectura modular orientada a objetos en Python puro sustentada exclusivamente en operaciones matriciales de NumPy. La clase central `MultilayerPerceptron` encapsula el ciclo de vida del modelo:

- **Jerarquía Polimórfica de Activación:** Clases abstractas derivadas (`SigmoidActivation`, `TanhActivation`, `ReLUActivation`, `LinearActivation`, `SoftmaxActivation`) que implementan métodos vectorizados estáticos `forward(z)` y `derivative(z, a)`, incorporando protección contra desbordamiento numérico (*clipping* simétrico en $[-50.0, 50.0]$ y estabilización logarítmica restando el valor máximo $\max(z)$ en `Softmax`).
- **Caché de Activación Eficiente:** Durante el *forward pass*, la red almacena en listas transitorias internas los potenciales netos $\{z^{(l)}\}$ y las activaciones $\{a^{(l)}\}$, reutilizándolos directamente en la diferenciación del *backward pass* sin recalcular exponenciales costosas ($\sigma' = a(1 - a)$).

■ Estrategias de Inicialización de Pesos:

- **Xavier / Glorot:** Muestreo uniforme $U\left[-\sqrt{\frac{6}{n_{\text{in}}+n_{\text{out}}}}, \sqrt{\frac{6}{n_{\text{in}}+n_{\text{out}}}}\right]$, calibrado para activaciones simétricas (Sigmoides, Tanh) preservando la varianza de las señales a través de las capas.
- **He / Kaiming:** Muestreo normal $\mathcal{N}\left(0, \frac{2}{n_{\text{in}}}\right)$, específico para mitigar el desvanecimiento de varianza en unidades ReLU.
- **Canónica de Referencia:** Mapeo exacto de los pesos sinápticos fijos documentados en la literatura académica de MATLAB para el problema XOR de 2 entradas.

- **Modos de Aprendizaje Flexibles:** Soporte nativo para modo 'online' (estocástico patrón a patrón, ejecutando actualización sináptica tras cada muestra p), modo 'batch' (acumulación de gradientes tensoriales sobre toda la matriz de entrenamiento) y modo 'mini-batch'.

3.2. Protocolo de Preprocesamiento y Prevención Estricta de Fuga de Información (*Data Leakage*)

En problemas continuos multidimensionales, las variables predictoras presentan escalas heterogéneas que distorsionan la geometría del espacio de optimización, provocando que los gradientes de variables con amplitudes dominantes oscilen descontroladamente. Para contrarrestar esta patología, se implementó la estandarización por puntuación típica (z -score):

$$x_{\text{std}} = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}} \quad (33)$$

Con el fin de asegurar rigor metodológico y blindar el experimento contra cualquier riesgo de **fuga de información** (*data leakage*), los vectores de media empírica μ_{train} y desviación estándar σ_{train} se computaron **estricta y exclusivamente** sobre el subconjunto de entrenamiento. Las transformaciones lineales resultantes se proyectaron posteriormente sobre los conjuntos de validación y prueba independientes.

Esta estandarización es matemáticamente indispensable para el Perceptrón Multicapa con funciones sigmoideas: al centrar la nube de datos en el origen con varianza unitaria ($\mu = 0, \sigma = 1$), el potencial de activación neto inicial $z = \sum w_i x_i + b$ se posiciona en el entorno lineal de máxima conductividad del gradiente ($z \approx 0$, donde $\sigma'(0) = 0.25$), suprimiendo la saturación asintótica temprana (*vanishing gradients*).

3.3. Descripción Formal de los Conjuntos de Datos Evaluados

Para evaluar la capacidad de representación en distintas complejidades topológicas, se emplearon cinco conjuntos de datos continuos de referencia internacional (Tabla 2):

1. **Compuertas Lógicas Sintéticas (XOR-2 y XOR-3):** Problemas clásicos no linealmente separables de paridad binaria sobre los hipercubos $\mathbb{R}^2$ y $\mathbb{R}^3$.
2. **Fisher's Iris:** 150 especímenes botánicos clasificados en tres especies (*Setosa*, *Versicolor*, *Virginica*) descritos por 4 atributos morfométricos continuos.
3. **Wine Recognition:** 178 muestras de análisis químico que cuantifican 13 constituyentes orgánicos e inorgánicos derivados de tres cultivares vinícolas italianos.
4. **Breast Cancer Wisconsin Diagnostic:** 569 biopsias celulares por aspiración con aguja fina descritas por 30 características nucleares continuas (radio, textura, concavidad, simetría) para diagnóstico binario (Maligno vs. Benigno).
5. **Banknote Authentication:** 1372 instancias caracterizadas por 4 propiedades estadísticas continuas de la transformada Wavelet continua de imágenes digitalizadas para discernir billetes auténticos de falsificados.

Tabla 2: Resumen estructural y dimensional de los conjuntos de datos evaluados.

Dataset	Muestras (N)	Atributos (D)	Clases (K)	Balanceo	Complejidad Topológica
XOR-2	4	2	2	Balanceado	No separable lineal en 2D
XOR-3	8	3	2	Balanceado	Paridad impar en hipercubo 3D
Fisher's Iris	150	4	3	Balanceado (50/50/50)	1 separable, 2 solapadas
Wine Recognition	178	13	3	Desbalance moderado	Espacio continuo de 13 variables
Breast Cancer	569	30	2	357B/212M	Alta dimensionalidad continua
Banknote Auth.	1372	4	2	762Aut/610Fals	Cuasi-separable no lineal Wavelet

3.4. Protocolo de Particionamiento Estratificado y Reproducibilidad

Para los conjuntos continuos multidimensionales (Wine, Breast Cancer y Banknote), se implementó estrictamente el protocolo reproducible dictado por la metodología de `Dataset_train_test.mlx` con permutaciones pseudoaleatorias (`randperm`) y semilla determinista fija (`seed = 42`), generando cuatro particiones obligatorias de entrenamiento y prueba:

- **Partición 60-40:** 60 % entrenamiento, 40 % prueba independiente.
- **Partición 70-30:** 70 % entrenamiento, 30 % prueba independiente.
- **Partición 80-20:** 80 % entrenamiento, 20 % prueba independiente.
- **Partición 90-10:** 90 % entrenamiento, 10 % prueba independiente.

Para el experimento de clasificación multiclase en Iris, se configuró una partición estratificada por clase con 84 muestras de entrenamiento (56 %), 21 muestras de validación (14 %) y 45 muestras de prueba independiente (30 %, 15 por clase). Para el estudio de sobreajuste en Breast Cancer, se empleó una partición 50 % entrenamiento ($N_{tr} = 284$), 25 % validación ($N_{val} = 142$) y 25 % prueba ($N_{test} = 143$).

4. Resultados y Discusión Numérica

4.1. Validación Canónica en el Problema XOR (2 y 3 Entradas)

4.1.1. Disyunción Exclusiva de 2 Entradas (XOR-2)

El experimento canónico de disyunción exclusiva XOR-2 somete a prueba los cuatro vértices booleanos $\{(0, 0), (0, 1), (1, 0), (1, 1)\}$ con vector objetivo $y = [0, 1, 1, 0]^T$. En la Tabla 3 se contrastan los resultados obtenidos por el Perceptrón Simple y Adaline (extraídos del Taller 1) frente al Perceptrón Multicapa $[2, 2, 1]$ con activación sigmoide, $\eta = 0.50$, $\beta = 0.50$ y umbral de convergencia $MSE \leq 0.005$.

Tabla 3: Comparativa de convergencia en el problema XOR-2 entre arquitecturas monocapa y multicapa.

Modelo Evaluado	Topología	Lineal	Épocas	MSE Final	Exactitud	Diagnóstico Analítico
Perceptrón Simple	[2, 1]	Sí	200	0.5000	50.0 %	Fracaso: oscilación cíclica sin convergencia.
Adaline (LMS)	[2, 1]	Sí	67	0.2507	75.0 %	Fracaso: estancamiento en mínimo plano de compromiso.
Perceptrón Multicapa	[2, 2, 1]	No	1649	0.00499	100.0 %	Convergencia perfecta: modela frontera no lineal.




Figura 2: Comparación empírica en el problema XOR-2: A) Trayectorias de error de entrenamiento para Perceptrón Simple, Adaline y MLP; B) Predicciones analíticas continuas y discretizadas frente a los valores objetivo esperados.

Como evidencia la Figura 2, el Perceptrón Simple permanece atrapado en un bucle periódico oscilando entre aciertos y desaciertos, mientras que Adaline aplana su salida lineal a 0.5, colapsando en una predicción ambigua. En


agudo contraste, el MLP reduce monótonamente el error cuadrático medio hasta $MSE = 0.00499$, prediciendo las probabilidades exactas $[0.0768, 0.9329, 0.9330, 0.0728]^T$, las cuales, bajo el umbral $\theta = 0.5$, clasifican con un **100.0 % de exactitud**.

4.1.2. Dinámica de Hiperparámetros y Aceleración Inercial por Momento (β)

Para dilucidar la sensibilidad del proceso de convergencia respecto a la tasa de aprendizaje η y el momento β , se ejecutó una exploración bidimensional en la malla $[0.1, 2.0] \times [0.0, 1.0]$.

En la Figura 3 se ilustran las curvas de convergencia unidimensionales:

- **Efecto de η ($\beta = 0.0$):** A medida que η aumenta desde 0.1 hasta 2.0, las épocas requeridas decrecen monótonamente desde 9371 hasta 581 épocas (reducción del 93.8 % en iteraciones).
- **Efecto de β ($\eta = 0.5$):** Manteniendo constante la tasa de aprendizaje en $\eta = 0.5$, el incremento en el término de momento acelera drásticamente la convergencia: con $\beta = 0.0$ se demandan 3137 épocas, con $\beta = 0.7$ se requieren 1051 épocas, y con $\beta = 0.9$ se alcanzan apenas **394 épocas**. Esto representa una aceleración del **87.44 %** en tiempo de convergencia.
- **Inestabilidad Crítica en $\beta = 1.0$:** Al alcanzar el límite unitario $\beta = 1.0$, el sistema pierde disipación, acumulando energía cinética indefinidamente. La red oscila violentamente en el espacio sináptico y no converge (15000 épocas agotadas, $MSE = 0.2521$).



(A) Épocas vs. Tasa de Aprendizaje η ($\beta = 0.0$).

(B) Épocas vs. Coeficiente de Momento β ($\eta = 0.5$).

Figura 3: Dinámica de convergencia en XOR-2 variando independientemente la tasa η y el momento β .

En la Figura 4 se presentan la hipersuperficie tridimensional y el mapa de calor bidimensional del espacio (η, β) . Se delimita con nitidez la región óptima de convergencia ultrarrápida (menos de 500 épocas) situada en la franja $\eta \in [0.8, 1.8]$ con $\beta \in [0.6, 0.9]$.




Figura 4: Caracterización global del espacio de hiperparámetros (η, β) en el entrenamiento del MLP para XOR-2.




Figura 5: Evolución del Error Cuadrático Medio (MSE) en función de las épocas bajo diferentes intensidades de momento inercial β para $\eta = 0.50$.

4.1.3. Mecanismo Geométrico en el Espacio de Entrada vs. Espacio Latente

La Figura 6 desvela la fundamentación geométrica de la solución al problema XOR-2:

- **Espacio de Entrada** $[x_1, x_2]$ (**Panel A**): Las muestras de la clase 0 (círculos azules en $(0,0)$ y $(1,1)$) y de la clase 1 (triángulos rojos en $(0,1)$ y $(1,0)$) se ubican en diagonales cruzadas, imposibilitando su partición mediante una línea recta.
- **Espacio Latente Oculto** $[h_1, h_2]$ (**Panel B**): Las neuronas de la capa intermedia proyectan las entradas no linealmente mediante $h_1 = \sigma(z_1)$ y $h_2 = \sigma(z_2)$. Bajo esta transformación, los patrones $(0,1)$ y $(1,0)$ son colapsados hacia un clúster compacto cercano a $(0.93, 0.07)$, mientras que $(0,0)$ y $(1,1)$ se distancian hacia $(0.07, 0.07)$ y $(0.93, 0.93)$.
- **Separabilidad Lineal Inducida**: En el plano latente $[h_1, h_2]$, el hiperplano trazado por la neurona de salida única aísla limpiamente ambas clases con holgura geométrica.




Figura 6: Mecanismo de linealización del MLP en XOR-2: A) Superficie no lineal de decisión en el espacio de entrada $\mathbb{R}^2$; B) Proyección de los patrones en el espacio latente $[h_1, h_2]$ de la capa oculta, donde se tornan linealmente separables.

4.1.4. Paridad Impar de 3 Entradas (XOR-3)

El problema XOR-3 asigna la etiqueta $y = 1$ si el número de entradas activas es impar, evaluando los 8 vértices del cubo booleano tridimensional. La Tabla 4 y la Tabla 5 reportan el desempeño de los modelos evaluados.

Tabla 4: Rendimiento en el problema de paridad booleana de 3 entradas (XOR-3).

Modelo	Topología	Épocas	Convergencia	MSE Final	Exactitud	Aciertos
Perceptrón Simple	[3, 1]	300	No	0.5000	50.0 %	4 / 8
Adaline (LMS)	[3, 1]	93	No	0.2504	50.0 %	4 / 8
MLP (4 Ocultas)	[3, 4, 1]	1135	Sí	0.00497	100.0 %	8 / 8
MLP (6 Ocultas)	[3, 6, 1]	992	Sí	0.00497	100.0 %	8 / 8

Tabla 5: Predicciones analíticas detalladas sobre los 8 patrones de la compuerta XOR-3.

Patrón (x_1, x_2, x_3)	Target y	Pred. Perc.	Pred. Adal.	Pred. MLP-4	$\hat{P}(\text{MLP-4})$	Pred. MLP-6	$\hat{P}(\text{MLP-6})$
(0, 0, 0)	0	0	0	0	0.0130	0	0.0333
(0, 0, 1)	1	0	0	1	0.9557	1	0.9462
(0, 1, 0)	1	1	0	1	0.9763	1	0.9494
(0, 1, 1)	0	1	0	0	0.0729	0	0.0753
(1, 0, 0)	1	1	1	1	0.9555	1	0.9816
(1, 0, 1)	0	1	1	0	0.0760	0	0.0715
(1, 1, 0)	0	1	1	0	0.0761	0	0.0741
(1, 1, 1)	1	1	1	1	0.8651	1	0.8711




Figura 7: Contraste predictivo en el problema de paridad XOR-3: Perceptrón Simple y Adaline colapsan en el 50 % de acierto, mientras que el MLP ([3, 4, 1] y [3, 6, 1]) resuelve la totalidad de los vértices.

Como ratifican la Tabla 5 y la Figura 7, los clasificadores monocapa no logran discernir más allá de un plano trivial (4 aciertos de 8 patrones, equivalente a una asignación aleatoria). El Perceptrón Multicapa con 4 y 6 neuronas ocultas alcanza el **100.0 %** de acierto en 1135 y 992 épocas, demostrando que la adición de unidades intermedias incrementa la cota de capacidad VC (*Vapnik-Chervonenkis*) necesaria para aislar los vértices alternados en $\mathbb{R}^3$.

4.2. Clasificación Multiclase sobre Fisher's Iris

Sobre el conjunto de datos *Fisher's Iris* ($N = 150$, $D = 4$ y $K = 3$ clases), las etiquetas categóricas se codificaron en vectores One-Hot en $\mathbb{R}^3$. Se ejecutó una malla experimental sistemática de 9 configuraciones combinando tres topologías arquitectónicas ([4, 4, 3], [4, 8, 3] y [4, 8, 4, 3]) con tres tasas de aprendizaje $\eta \in \{0.05, 0.10, 0.30\}$ bajo un momento fijo $\beta = 0.70$ y umbral de parada $MSE \leq 0.002$.

La Tabla 6 detalla las métricas de entrenamiento y prueba de la malla.

Tabla 6: Resultados experimentales de clasificación multiclase sobre el dataset Iris (Numeral 4)

ID	Arquitectura	η	Épocas	Conv.	MSE Train	MSE Val	Exactitud (%)
CONF-01	[4, 4, 3]	0.05	652	✓	0.00200	0.00153	91.11
CONF-02	[4, 4, 3]	0.10	335	✓	0.00200	0.00049	91.11
CONF-03	[4, 4, 3]	0.30	167	✓	0.00186	0.00048	91.11
CONF-04	[4, 8, 3]	0.05	677	✓	0.00199	0.00041	91.11
CONF-05	[4, 8, 3]	0.10	340	✓	0.00193	0.00043	91.11
CONF-06	[4, 8, 3]	0.30	159	✓	0.00176	0.00065	91.11
CONF-07	[4, 8, 4, 3]	0.05	305	✓	0.00192	0.00092	91.11
CONF-08	[4, 8, 4, 3]	0.10	180	✓	0.00194	0.00140	93.33
CONF-09	[4, 8, 4, 3]	0.30	174	✓	0.00187	0.01226	91.11

Todas las configuraciones convergieron satisfactoriamente. La tasa η modula linealmente la celeridad del descenso: mientras que $\eta = 0.05$ demanda entre 305 y 677 épocas, $\eta = 0.30$ converge en apenas 159 a 174 épocas (reducción superior al 74 % en tiempo de cálculo).

La configuración óptima identificada correspondió a la red profunda de dos capas ocultas **CONF-08** ([4, 8, 4, 3] con $\eta = 0.10$), la cual alcanzó una exactitud en prueba independiente del **93.33 %** y un F_1 -score macro de **0.9327** en 180 épocas. La Figura 8 exhibe las trayectorias temporales duales de error de entrenamiento y validación para las 9 combinaciones.

Curvas de Convergencia Dual (Train MSE vs. Val MSE) sobre Dataset Iris
Comparación Sistemática: 3 Arquitecturas x 3 Tasas de Aprendizaje ($\beta = 0.7$)





Figura 8: Curvas duales de convergencia (MSE_{train} vs. MSE_{val}) en función de las épocas para las 9 configuraciones evaluadas sobre Iris.



(A) Matriz del Mejor Modelo ([4, 8, 4, 3]).

(B) Exactitud en Test según Configuración.

Figura 9: Métricas de evaluación multiclase sobre el conjunto de prueba independiente de Iris ($N_{\text{test}} = 45$).

La matriz de confusión (Figura 9A) confirma que *Setosa* se separa perfectamente (100% de sensibilidad y especificidad), y *Versicolor* obtiene un acierto pleno (15/15). El único compromiso predictivo radica en 3 muestras de *Virginica* clasificadas como *Versicolor*, producto del solapamiento morfológico intrínseco en las dimensiones de sépalo y pétalo reportado históricamente por Ronald Fisher.




Figura 10: Panel comparativo de matrices de confusión sobre el conjunto de prueba para las 9 configuraciones evaluadas en Iris.




Figura 11: Proyección en componentes principales (PCA 2D) del espacio de entrada original $\mathbb{R}^4$ vs. los espacios latentes de las capas ocultas 1 ($H^{(1)} \in \mathbb{R}^8$) y 2 ($H^{(2)} \in \mathbb{R}^4$) en la red MLP óptima.

La Figura 11 provee la evidencia topológica capital: en el espacio de entrada original $\mathbb{R}^4$ (Panel A), las clases *Versicolor* y *Virginica* presentan una zona de solapamiento denso intratable mediante hiperplanos planos. Al fluir a través de la primera capa oculta (Panel B, $H^{(1)} \in \mathbb{R}^8$) y la segunda capa oculta (Panel C, $H^{(2)} \in \mathbb{R}^4$), las transformaciones sigmoideas no lineales estiran y desenredan la variedad de datos, condensando los patrones en conglomerados compactos aislables linealmente por la capa de salida.

4.3. Evaluación en Múltiples Particiones (Wine, Breast Cancer y Banknote)

Conforme a la metodología de `Dataset_train_test.mlx` (`randperm`, `seed = 42`), se contrastó el Perceptrón Multicapa frente a los modelos del Taller 1 (Perceptrón Simple con Regla 3 y Adaline LMS bajo esquema One-vs-Rest para clasificación multiclase en Wine). En la Tabla 7 se resume la exactitud de prueba para las cuatro particiones.

Tabla 7: Exactitud de prueba (%) según proporción de partición (Numeral 5)

Dataset	Partición	MLP (%)	Perceptrón (%)	Adaline (%)
Wine	60-40	98.59	97.18	98.59
Wine	70-30	98.11	98.11	98.11
Wine	80-20	97.22	100.00	100.00
Wine	90-10	100.00	100.00	100.00
Breast Cancer	60-40	96.49	94.74	94.74
Breast Cancer	70-30	96.49	94.74	95.32
Breast Cancer	80-20	97.37	92.98	97.37
Breast Cancer	90-10	98.25	94.74	96.49
Banknote	60-40	99.82	99.09	98.00
Banknote	70-30	99.03	99.27	98.30
Banknote	80-20	100.00	99.27	97.81
Banknote	90-10	98.54	98.54	98.54

Tabla 8: Matriz comparativa multidimensional de desempeño: MLP vs. Perceptrón vs. Adaline bajo cuatro particiones

Dataset	Partición	Modelo	Exactitud Train (%)	Exactitud Test (%)	F1 Macro	Tiempo (ms)	Épocas	C
Wine	60-40	Perceptrón Simple	100.00	97.18	0.9718	2.0	5	
Wine	60-40	Adaline / LMS	99.07	98.59	0.9858	23.5	42	
Wine	60-40	MLP (Backpropagation)	100.00	98.59	0.9858	119.8	18	
Wine	70-30	Perceptrón Simple	100.00	98.11	0.9823	2.4	8	
Wine	70-30	Adaline / LMS	100.00	98.11	0.9823	24.5	38	
Wine	70-30	MLP (Backpropagation)	100.00	98.11	0.9823	105.8	15	
Wine	80-20	Perceptrón Simple	100.00	100.00	1.0000	2.4	8	
Wine	80-20	Adaline / LMS	100.00	100.00	1.0000	25.3	33	
Wine	80-20	MLP (Backpropagation)	100.00	97.22	0.9726	132.4	16	
Wine	90-10	Perceptrón Simple	100.00	100.00	1.0000	2.8	10	
Wine	90-10	Adaline / LMS	100.00	100.00	1.0000	26.6	32	
Wine	90-10	MLP (Backpropagation)	100.00	100.00	1.0000	125.3	14	
Breast Cancer	60-40	Perceptrón Simple	100.00	94.74	0.9445	30.6	98	
Breast Cancer	60-40	Adaline / LMS	97.36	94.74	0.9432	46.4	64	
Breast Cancer	60-40	MLP (Backpropagation)	99.12	96.49	0.9625	682.0	25	
Breast Cancer	70-30	Perceptrón Simple	100.00	94.74	0.9457	32.8	90	
Breast Cancer	70-30	Adaline / LMS	96.73	95.32	0.9512	65.5	75	
Breast Cancer	70-30	MLP (Backpropagation)	99.25	96.49	0.9637	500.8	16	
Breast Cancer	80-20	Perceptrón Simple	99.56	92.98	0.9271	67.1	150	
Breast Cancer	80-20	Adaline / LMS	97.14	97.37	0.9726	53.1	41	
Breast Cancer	80-20	MLP (Backpropagation)	99.12	97.37	0.9728	535.6	15	
Breast Cancer	90-10	Perceptrón Simple	98.24	94.74	0.9429	77.5	150	
Breast Cancer	90-10	Adaline / LMS	97.07	96.49	0.9605	31.8	30	
Breast Cancer	90-10	MLP (Backpropagation)	99.02	98.25	0.9810	1250.2	31	
Banknote	60-40	Perceptrón Simple	98.91	99.09	0.9908	122.4	150	
Banknote	60-40	Adaline / LMS	97.45	98.00	0.9799	12.9	8	
Banknote	60-40	MLP (Backpropagation)	99.76	99.82	0.9982	1849.1	30	
Banknote	70-30	Perceptrón Simple	98.85	99.27	0.9927	134.0	150	
Banknote	70-30	Adaline / LMS	97.71	98.30	0.9830	13.5	7	
Banknote	70-30	MLP (Backpropagation)	99.27	99.03	0.9903	1509.4	21	
Banknote	80-20	Perceptrón Simple	98.72	99.27	0.9927	152.4	150	
Banknote	80-20	Adaline / LMS	97.09	97.81	0.9781	14.8	7	
Banknote	80-20	MLP (Backpropagation)	99.82	100.00	1.0000	2088.6	25	
Banknote	90-10	Perceptrón Simple	98.87	98.54	0.9854	167.1	150	
Banknote	90-10	Adaline / LMS	97.57	98.54	0.9854	17.3	7	
Banknote	90-10	MLP (Backpropagation)	99.19	98.54	0.9854	1589.3	17	




Figura 12: Exactitud en prueba en función del porcentaje de datos asignados a entrenamiento para Wine, Breast Cancer y Banknote Authentication.




Figura 13: Costo computacional en la partición 80-20: A) Tiempo total de entrenamiento (ms en escala logarítmica); B) Épocas requeridas hasta convergencia.




Figura 14: Panel 3×3 de matrices de confusión sobre el conjunto de prueba (partición 80-20) contrastando MLP, Perceptrón y Adaline.





Figura 15: Curvas de aprendizaje (MSE en escala logarítmica) para el Perceptrón Multicapa bajo las 4 particiones en Wine, Breast Cancer y Banknote.



(A) Wine Recognition.

(B) Breast Cancer Diagnostic.

(C) Banknote Authentication.

Figura 16: Desglose de exactitud en prueba por partición para cada dataset evaluado.

4.3.1. Deducciones Numéricas Clave

1. **Efecto del Volumen Muestral (N_{train}):** Al elevar la fracción de entrenamiento del 60 % al 90 %, la exactitud del MLP asciende monótonamente en los tres problemas, logrando el **100.0 %** en Wine y el **98.25 %** en Breast Cancer.
2. **Dominancia en Alta Dimensionalidad (Breast Cancer, $D = 30$):** En este espacio morfológico complejo, el MLP ($[30, 16, 8, 1]$ con $\beta = 0.70$) superó consistentemente a los modelos lineales (Perceptrón: 92.98 % – 94.74 %; Adaline: 94.74 % – 97.37 % vs. MLP: 96.49 % – 98.25 %). La curvatura no lineal permite segregar interacciones celulares de orden superior inaccesibles para hiperplanos planos.
3. **Perfección en Banknote Authentication ($D = 4$):** En la partición 80-20, el MLP ($[4, 8, 4, 1]$) alcanzó una exactitud perfecta del **100.00 %** (274 aciertos de 274 patrones de prueba, $F_1 = 1.0000$), superando el 99.27 % del Perceptrón Simple y el 97.81 % de Adaline (así como la cota histórica del Taller 1 de 97.82 % y 97.09 %). La matriz de confusión (Figura 14) confirma cero falsos positivos y cero falsos negativos.
4. **Compensación Tiempo vs. Épocas:** La retropropagación exige un costo por época mayor ($\approx 100 - 2000$ ms frente a < 150 ms en modelos monocapa), pero gracias al momento inercial $\beta = 0.70$, el MLP converge en apenas **14 a 31 épocas**, mientras que el Perceptrón agota 150 épocas sin convergencia estricta en Breast Cancer y Banknote.

4.4. Estudio Experimental de Sobreajuste (*Overfitting*) y Parada Temprana (*Early Stopping*)

Para estudiar experimentalmente la descomposición sesgo-varianza (Ecuación 29), se seleccionó el dataset *Breast Cancer Wisconsin Diagnostic* ($N = 569$, $D = 30$) particionado en 50 % entrenamiento ($N_{\text{tr}} = 284$), 25 % validación ($N_{\text{val}} = 142$) y 25 % prueba independiente ($N_{\text{test}} = 143$). Se diseñó una red deliberadamente sobreparametrizada:

$$\mathcal{M}_{\text{sobre}} : [30 \rightarrow 64 \rightarrow 32 \rightarrow 1] \quad \text{con activación sigmoide,} \quad \eta = 0.08, \quad \beta = 0.50 \quad (34)$$

Esta arquitectura aloja $30 \times 64 + 64 + 64 \times 32 + 32 + 32 \times 1 + 1 = 4097$ parámetros sinápticos libres. Frente a las 284 muestras de entrenamiento, la relación es de **14.43** parámetros por muestra, situando al modelo en un régimen de severa sobreparametrización sin penalización explícita.

Se implementó el algoritmo formal de **Early Stopping**:

- **Métrica de Control:** Error cuadrático sobre validación (E_{val}).
- **Paciencia (P):** $P = 40$ épocas consecutivas sin decremento del error.
- **Tolerancia (Δ_{min}):** $\Delta_{\text{min}} = 10^{-4}$ (0.0001).
- **Checkpointing Profundo:** Si $E_{\text{val}}(t) < E_{\text{val}}^* - \Delta_{\text{min}}$, se actualiza E_{val}^* , se reinicia la paciencia y se respalda una copia profunda (deepcopy) del tensor sináptico óptimo w^* .
- **Criterio de Disparo:** Al cumplirse $P = 40$ épocas sin mejora ($t_{\text{stop}} = t^* + P$), se suspende el entrenamiento y se restauran los pesos w^* .

El modelo se entrenó durante 1500 épocas en modo estocástico (*online*), contrastando el estado memorizado en $t = 1500$ frente al estado regularizado en t^* .

Dinámica de Sobreajuste y Parada Temprana en MLP Sobreparametrizado [30, 64, 32, 1]




Figura 17: Dinámica temporal de sobreajuste en el MLP [30, 64, 32, 1] a lo largo de 1500 épocas: delimitación de las cuatro fases canónicas (subajuste, mínimo óptimo en $t^* = 24$, disparo de paciencia en $t_{\text{stop}} = 64$ y divergencia de varianza).

La Figura 17 valida de forma impecable las cuatro fases teóricas:

1. **Subajuste Inicial** ($t \in [1, 10]$): E_{train} y E_{val} descienden velozmente de 0.0998 a ≈ 0.0150 .
2. **Punto Óptimo** ($t^* = 24$): El error de validación alcanza su mínimo global absoluto $E_{\text{val}}^* = 0.012722$ ($E_{\text{train}} = 0.008957$).
3. **Disparo de Parada** ($t_{\text{stop}} = 64$): Tras 40 épocas sin mejora, se activa la parada anticipada.
4. **Divergencia de Varianza** ($t > 64$ hasta 1500): Mientras el error de entrenamiento colapsa hacia cero ($E_{\text{train}} \rightarrow 0.000013$), el error de validación asciende sostenidamente hasta $E_{\text{val}} = 0.025724$ (un incremento del **+102.2 %**). La red invierte su capacidad en memorizar el ruido muestral.

La Tabla 9 y la Tabla 10 exponen cuantitativamente el impacto de la regularización en el conjunto de prueba independiente ($N_{\text{test}} = 143$).

Tabla 9: Comparativa Cuantitativa de Sobreajuste y Parada Temprana en Breast Cancer (Numeral 6)

Modelo	Época	Train MSE	Val MSE	Test MSE	Exactitud (%)	Brecha $ E_{\text{test}} - E_{\text{tr}} $	Ahorro
Sobreajustado (Final)	1500	0.000013	0.025724	0.043489	95.10	0.043476	0.00 %
Early Stopping (W^*)	24	0.008957	0.012722	0.036247	94.41	0.027290	95.73 %

Tabla 10: Impacto de la complejidad estructural sobre el sobreajuste y la generalización en Breast Cancer.

Régimen	Topología	Parám.	Ratio P/N	t^*	$E_{\text{tr}}(1500)$	$E_{\text{val}}(1500)$	$E_{\text{test}}(\text{Overfit})$	$E_{\text{test}}(\text{ES})$
Subajustada	[30, 2, 1]	65	0.23	30	5.74×10^{-5}	0.02553	0.04577	0.03725
Parsimoniosa	[30, 8, 1]	257	0.90	28	5.40×10^{-5}	0.02713	0.04621	0.03718
Balanceada	[30, 16, 8, 1]	641	2.26	22	1.64×10^{-5}	0.02580	0.04627	0.03572
Sobreparametrizada	[30, 64, 32, 1]	4097	14.43	24	1.27×10^{-5}	0.02572	0.04349	0.03625




Figura 18: Panel analítico de generalización: A) Comparativa de exactitud, MSE y brecha de generalización en prueba; B) Densidad probabilística estimada (KDE) en Test, contrastando la polarización saturada del modelo sobreajustado frente a la calibración suave de Early Stopping; C) Trayectorias de E_{val} para cuatro niveles de complejidad estructural.

El análisis de la Figura 18 confirma tres ventajas fundamentales de *Early Stopping*:

1. **Reducción del Error Cuadrático en Prueba (E_{test}):** Desciende de 0.043489 a 0.036247, una mejora relativa del **16.65 %**.
2. **Contracción de la Brecha de Generalización:** La discrepancia $|E_{test} - E_{train}|$ se contrae de 0.043476 a 0.027290, una reducción del **37.23 %**, erradicando la disociación entre el rendimiento empírico y el comportamiento ante datos futuros.
3. **Ahorro Computacional Severo:** Al detener el cómputo en la época 64 en lugar de agotar las 1500 iteraciones, se obtiene un ahorro del **95.73 %** en tiempo de CPU y consumo energético.
4. **Calibración Probabilística y Puntuación de Brier:** La densidad KDE (Panel B) muestra cómo el modelo memorizado satura las salidas en 0.0 y 1.0 (debido al crecimiento excesivo de la norma sináptica $\|W\|$), mientras que Early Stopping mantiene probabilidades calibradas (Brier score de 0.0362 vs. 0.0435).

5. Análisis y Discusión Global

5.1. Contraste Multidimensional: Perceptrón Simple vs. Adaline vs. MLP

En la Tabla 11 se sintetiza el análisis comparativo formal entre las tres arquitecturas conexionistas analizadas a lo largo del curso.

Tabla 11: Cuadro comparativo multidimensional entre el Perceptrón Simple, la Red Adaline y el Perceptrón Multicapa.

Criterio	Perceptrón Simple (Rosenblatt)	Red Adaline (Widrow-Hoff)	Perceptrón Multicapa (Rumelhart)
Topología	Monocapa, sin capas ocultas ($[D, 1]$).	Monocapa, sin capas ocultas ($[D, 1]$).	Multicapa profunda ($[D, n_1, \dots, n_L]$).
Activación	Escalón Heaviside discreto $\{0, 1\}$.	Lineal en entrenamiento, umbral en inferencia.	Sigmoide, Tanh, ReLU, Soft-max continuas.
Función de Costo	No diferenciable (recuento de errores discretos).	Cuadrática convexa (MSE en pre-activación).	No convexa altamente multimodal (MSE, Cross-Entropy).
Optimización	Regla heurística de corrección por error.	Descenso de Gradiente Estocástico (LMS).	Retropropagación (Regla Delta Generalizada con Momento).
Capacidad de Separabilidad	Estrictamente lineal (un único hiperplano $\mathbb{R}^{D-1}$).	Estrictamente lineal (mínimos cuadrados).	No lineal arbitraria (Aproximador Universal, Cybenko).
Resolución de XOR / Paridad	Fracaso categórico (cicla indefinidamente, 50 %).	Fracaso categórico (hiperplano degenerado, 50 % – 75 %).	Éxito perfecto (100.0 %, MSE < 0.005, deformación latente).
Sensibilidad a la Escala	Moderada (afecta el ritmo angular de giro del plano).	Severa (divergencia si $\alpha > 2/\lambda_{\max}$).	Crítica (saturación de gradientes sin estandarización z-score).
Rendimiento en Banknote	Test Acc: $\approx 98.5\% - 99.3\%$.	Test Acc: $\approx 97.1\% - 98.5\%$.	Test Acc: 100.00 % ($F_1 = 1.0000$ en 80-20).

5.2. Sensibilidad Dinámica a los Hiperparámetros (η, β)

El comportamiento dinámico del algoritmo de retropropagación queda gobernado por la interacción entre η y β :

- **Tasa de Aprendizaje η** : Actúa como la escala temporal de discretización de Euler. Valores excesivamente reducidos ($\eta < 0.01$) provocan un avance infinitesimal que puede requerir miles de épocas para cruzar mesetas planas; valores excesivamente elevados ($\eta > 2.0$) inducen sobrepasos oscilatorios respecto a los valles locales, impidiendo la convergencia asintótica.
- **Momento Inercial β** : Actúa como un filtro pasa-bajo sobre la trayectoria de gradientes. Amortigua selectivamente las componentes oscilatorias transversales en direcciones de gran curvatura mientras multiplica por $\frac{1}{1-\beta}$ la velocidad en direcciones persistentes. La aceleración del **87.4 %** documentada en XOR-2 evidencia que el momento es imprescindible para eludir mesetas con gradiente nulo inducidas por la saturación de la función sigmoide. Sin embargo, fijar $\beta \geq 1.0$ suprime el amortiguamiento disipativo y causa inestabilidad infinita.

5.3. Compromiso entre Profundidad y Ancho (*Depth vs. Width Trade-off*)

Los experimentos realizados sobre Iris y Breast Cancer corroboran un principio fundamental del diseño de redes neuronales:

- Una red superficial ancha (e.g., $[30, 64, 1]$) requiere un número exponencialmente superior de neuronas para aproximar funciones con estructuras composicionales intrínsecas, resultando más propensa a memorizar muestras de entrenamiento.
- Una red profunda parsimoniosa (e.g., $[30, 16, 8, 1]$ o $[4, 8, 4, 3]$) descompone la función objetivo en una jerarquía de representaciones latentes sucesivas (como evidencian los mapas PCA de la Figura 11), alcanzando mayor exactitud y generalización con menos parámetros entrenables totales.

5.4. Robustez Frente a Ruido y Correlaciones Multidimensionales

En problemas de alta dimensionalidad continua (Breast Cancer, $D = 30$), los clasificadores lineales se ven limitados por la correlación colineal entre métricas nucleares celulares. El MLP supera holgadamente a Adaline y al Perceptrón Simple gracias a la formación de regiones convexas cerradas de decisión en el espacio latente, aislando células malignas atípicas sin distorsionar la frontera global.

6. Conclusiones

A partir de los resultados analíticos, numéricos y experimentales recabados a lo largo del presente trabajo, se formulan las siguientes conclusiones:

1. **Superación Definitiva de la Barrera de No-Separabilidad Lineal:** La implementación del Perceptrón Multicapa validó empíricamente la resolución del problema XOR de 2 y 3 entradas con una exactitud perfecta del **100.0 %**, desarticulando la limitación histórica de Minsky y Papert (1969). Frente a la oscilación estocástica del Perceptrón Simple (50.0 %) y la degeneración por mínimos cuadrados de Adaline (50.0 %–75.0 %), la inclusión de capas ocultas intermedias no lineales transforma la variedad de datos, habilitando la formación de regiones de decisión convexas y no convexas de complejidad arbitraria.
2. **Mecanismo de Despliegue en Espacios Latentes:** El análisis mediante reducción dimensional (PCA) demostró que las capas ocultas actúan como difeomorfismos que deforman y desenredan progresivamente las variedades de entrada. Clases con denso solapamiento morfológico en $\mathbb{R}^4$ (como *Versicolor* y *Virginica* en el dataset Iris) son proyectadas a espacios latentes ($H^{(1)} \in \mathbb{R}^8, H^{(2)} \in \mathbb{R}^4$) donde se convierten en cúmulos compactos linealmente separables para la capa de salida.
3. **Aceleración Inercial por Momento (β):** La exploración sistemática en el espacio de hiperparámetros (η, β) demostró que la adición del término de momento produce una aceleración de hasta el **87.4 %** en las iteraciones de convergencia ($\beta = 0.9$ vs. $\beta = 0.0$), corroborando analíticamente su función como filtro pasa-bajo que amplifica el paso efectivo por un factor $\frac{1}{1-\beta}$ en valles consistentes y amortigua oscilaciones transversales destructivas. Asimismo, se identificó la cota de inestabilidad crítica en $\beta = 1.0$, donde la ausencia de disipación viscosa imposibilita la convergencia.
4. **Rendimiento Superior en Problemas Multidimensionales Complejos:** En los cuatro conjuntos continuos de prueba, el MLP exhibió una robustez discriminativa superior frente a los modelos monocapa, logrando un **100.0 %** de exactitud y F_1 -score de 1.0000 en Banknote Authentication (partición 80-20), **100.0 %** en Wine Recognition y **98.25 %** en Breast Cancer Wisconsin. Esto demuestra que la combinación de normalización z -score y capas no lineales preserva invarianzas estructurales frente a correlaciones complejas de alta dimensión.
5. **Parada Temprana como Regularizador Espectral Implícito:** El experimento sobreparametrizado de 4097 parámetros (14.43 parámetros por muestra) corroboró la dinámica de la descomposición sesgo-varianza. La parada temprana (*Early Stopping*) redujo el error cuadrático en prueba en un **16.65 %**, contrajo la brecha de generalización en un **37.23 %** y generó un ahorro de cómputo del **95.73 %**, confirmando su equivalencia asintótica con la penalización de peso L_2 al restringir el crecimiento de la norma sináptica $\|W\|_2$.
6. **Imperativo Metodológico Contra la Fuga de Información:** Se ratificó que el cálculo de parámetros de estandarización exclusivamente sobre el conjunto de entrenamiento es una condición sine qua non en la ingeniería de aprendizaje automático. La normalización z -score no solo garantiza cero fuga de información (*zero data leakage*), sino que condiciona el potencial neto en la región de máxima derivada de la sigmoide ($f'(0) = 0.25$), suprimiendo el desvanecimiento prematuro del gradiente.

7. Referencias Bibliográficas

1. F. Rosenblatt, “The Perceptron: A probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958. <https://doi.org/10.1037/h0042519>
2. B. Widrow and M. E. Hoff, “Adaptive switching circuits,” in *IRE WESCON Convention Record*, part 4, pp. 96–104, 1960.
3. M. L. Minsky and S. A. Papert, *Perceptrons: An Introduction to Computational Geometry*, Cambridge, MA, USA: MIT Press, 1969.
4. D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986. <https://doi.org/10.1038/323533a0>
5. G. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of Control, Signals, and Systems*, vol. 2, no. 4, pp. 303–314, 1989. <https://doi.org/10.1007/BF02551274>
6. K. Hornik, “Approximation capabilities of multilayer feedforward networks,” *Neural Networks*, vol. 4, no. 2, pp. 251–257, 1991. [https://doi.org/10.1016/0893-6080\(91\)90009-T](https://doi.org/10.1016/0893-6080(91)90009-T)
7. N. Qian, “On the momentum term in gradient descent learning algorithms,” *Neural Networks*, vol. 12, no. 1, pp. 145–151, 1999. [https://doi.org/10.1016/S0893-6080\(98\)00116-6](https://doi.org/10.1016/S0893-6080(98)00116-6)

8. S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Upper Saddle River, NJ, USA: Pearson Prentice Hall, 2009.
9. C. M. Bishop, *Pattern Recognition and Machine Learning*, New York, NY, USA: Springer, 2006.
10. I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, Cambridge, MA, USA: MIT Press, 2016.
11. R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
12. D. Dua and C. Graff, “UCI Machine Learning Repository,” School of Information and Computer Science, University of California, Irvine, CA, 2017. <http://archive.ics.uci.edu/ml>