



Taller 2: Redes Neuronales Multicapa (MLP) y Backpropagation

Implementación Vectorizada, Dinámica de Hiperparámetros, Espacios Latentes y
Regularización por Parada Temprana

Informe Técnico y Experimental de Resultados

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiante: Juan Felipe Rodríguez Galindo
Código: 20261595004
Programa: Maestría en Ciencias de la Información y las Comunicaciones (MCIC)
Fecha: 25 de septiembre de 2026

Universidad Distrital Francisco José de Caldas
Facultad de Ingeniería – Bogotá D.C., Colombia

Índice

1. Introducción	2
2. Marco Teórico	3
2.1. Arquitectura y Propagación Hacia Adelante (<i>Forward Pass</i>)	3
2.1.1. Catálogo de Funciones de Activación y sus Derivadas	4
2.2. Retropropagación del Error y Regla Delta Generalizada con Momento	5
2.2.1. 1. Gradiente del Error en la Capa de Salida ($l = L$)	5
2.2.2. 2. Retropropagación a Capas Ocultas ($l = L - 1, \dots, 1$)	5
2.2.3. 3. Regla Delta Generalizada con Momento Inercial (β)	5
2.3. Separabilidad Lineal, Espacios Latentes y Regularización	6
3. Metodología	7
3.1. Diseño Arquitectónico y Parametrizabilidad (Numeral 2)	7
3.2. Datasets y Protocolo de Particionamiento	8
4. Resultados	10
4.1. Problemas XOR (2 y 3 Entradas) (Numeral 3)	10
4.1.1. Disyunción Exclusiva de 2 Entradas (XOR-2)	10
4.1.2. Mecanismo de Despliegue en el Espacio Latente	10
4.1.3. Dinámica de Hiperparámetros y Aceleración Inercial por Momento (β)	11
4.1.4. Paridad Impar de 3 Entradas (XOR-3)	13
4.2. Clasificación Multiclase: Fisher's Iris (Numeral 4)	14
4.3. Evaluación en Múltiples Particiones: Wine, Breast Cancer y Banknote (Numeral 5)	14
4.3.1. Hallazgos Numéricos Principales	17
4.4. Sobreajuste y Parada Temprana (<i>Early Stopping</i>) (Numeral 6)	20
4.4.1. Impacto de la Variación del Número de Neuronas Ocultas	21
5. Análisis y Discusión	22
5.1. Cuadro Comparativo Multidimensional: Perceptrón vs. Adaline vs. MLP	22
5.2. Sensibilidad Dinámica a la Interacción de Hiperparámetros (η, β)	22
5.3. Compromiso entre Profundidad y Ancho (<i>Depth vs. Width Trade-off</i>)	22
6. Conclusiones	23
7. Referencias	24

1. Introducción

La computación neuronal moderna experimentó su punto de partida a mediados del siglo XX con el **Perceptrón Simple** de Rosenblatt (1958) [1] y el modelo **Adaline** de Widrow y Hoff (1960) [2]. Ambos modelos establecieron la viabilidad de adaptar ponderaciones sinápticas mediante señales de retroalimentación de error. No obstante, compartían una restricción arquitectónica infranqueable: al basar la decisión en una única combinación lineal afín, la superficie discriminante en $\mathbb{R}^D$ queda confinada forzosamente a un hiperplano de dimensión $D - 1$.

Esta rigidez geométrica fue formalizada analíticamente por Marvin Minsky y Seymour Papert en 1969 [3]. Demostraron matemáticamente que operadores lógicos no lineales fundamentales, tales como la disyunción exclusiva (XOR), resultan insolubles para cualquier clasificador monocapa. Al no existir un hiperplano capaz de separar los vértices cruzados del hipercubo booleano, el Perceptrón oscila indefinidamente sin converger (exactitud $\leq 50,0\%$), mientras que Adaline colapsa en un compromiso plano ($MSE \approx 0,25$). Esta barrera teórica condujo al denominado primer “invierno de la inteligencia artificial”, debido a la ausencia de una regla formal para propagar gradientes y asignar responsabilidad a neuronas intermedias ocultas.

La superación de esta limitación histórica se consolidó en 1986 con Rumelhart, Hinton y Williams [4], al formular la regla delta generalizada y el algoritmo de **Retropropagación del Error** (*Backpropagation*). Al reemplazar funciones de activación escalón discontinuas por sigmoides diferenciables ($\sigma(z) \in (0, 1)$), y aplicar sistemáticamente la regla de la cadena del cálculo multivariable, se habilitó la transmisión retrógrada de gradientes hacia capas ocultas. El **Perceptrón Multicapa** (*Multilayer Perceptron*, MLP) adquirió así la facultad de construir representaciones latentes jerárquicas capaces de deformar y desenredar variedades no lineales.

El presente estudio aborda la fundamentación teórica, formulación analítica desde primeros principios y evaluación experimental sistemática del Perceptrón Multicapa (*Multilayer Perceptron*, MLP) optimizado mediante el algoritmo de retropropagación del error con aceleración inercial por momento (β). El propósito central radica en comprender cómo la composición de transformaciones afines no lineales permite franquear las barreras de separabilidad lineal impuestas por los clasificadores monocapa, caracterizar la topología del espacio latente intermedio, y analizar cuantitativamente las dinámicas de convergencia hiperparamétrica y regularización frente a datos complejos y ruidosos.

A fin de articular el desarrollo de la investigación de manera metódica, los objetivos se estructuran en cinco fases interconectadas, presentadas esquemáticamente en la Figura 1:

1. **Formulación y Gradientes:** Deducir rigurosamente las ecuaciones del gradiente retrógrado y de la regla delta con momento inercial β para activaciones continuas.
2. **Validación No Lineal:** Contrastar analítica y empíricamente el MLP frente al Perceptrón Simple y Adaline en compuertas XOR-2 y XOR-3 (paridad), examinando el espacio latente $[h_1, h_2]$.
3. **Dinámica de Hiperparámetros:** Explorar la superficie de convergencia en el plano (η, β) , cuantificando la aceleración inercial y los límites de estabilidad.
4. **Clasificación en Variedades Reales:** Evaluar el comportamiento en los conjuntos *Iris*, *Wine*, *Breast Cancer* y *Banknote* bajo protocolo *Zero Data Leakage*.
5. **Diagnóstico de Generalización:** Caracterizar el compromiso sesgo-varianza en regímenes sobreparametrizados y cuantificar la eficacia de la parada temprana (*Early Stopping*).





Figura 1: Diagrama de flujo metodológico y articulación secuencial de las cinco fases de investigación.

2. Marco Teórico

2.1. Arquitectura y Propagación Hacia Adelante (*Forward Pass*)

La unidad elemental de procesamiento en las redes neuronales artificiales es el nodo o neurona artificial, formulada conceptualmente por McCulloch y Pitts (1943) y formalizada en el perceptrón de Rosenblatt (1958) [1]. Como ilustra la Figura 2, cada neurona recibe un vector sensorial de estímulos $x \in \mathbb{R}^{n_0}$, modula cada componente mediante una ponderación sináptica w_i , incorpora un sesgo escalar b para desplazar el umbral de activación, y proyecta la combinación afín resultante a través de una función de transferencia no lineal $f(\cdot)$.



Transición del Nodo Individual a la Red Multicapa:

Si bien un único nodo lineal queda acotado a discriminar regiones separadas por un hiperplano afín $\sum w_i x_i + b = 0$, la concatenación de múltiples neuronas organizadas en capas secuenciales permite construir superficies continuas de decisión altamente complejas.

Cada capa proyecta las activaciones de la capa antecedente hacia un nuevo espacio de representación latente, transformando progresivamente variedades complejas en geometrías linealmente desacopladas en la capa de salida.

Figura 2: Modelo formal de la unidad neuronal artificial (fuente canónica [9]): integración afín ponderada y mapeo no lineal.

Al extender esta unidad elemental a una arquitectura en red, considérese un sistema estructurado en L capas de procesamiento indexadas por $l = 0, 1, \dots, L$, donde $l = 0$ denota la capa sensorial de entrada (n_0 dimensiones), $l \in \{1, \dots, L-1\}$ representa las capas ocultas intermedias, y $l = L$ corresponde a la capa de salida. Cada capa l agrupa n_l unidades neuronales.

Para cada capa $l \in \{1, \dots, L\}$, los parámetros entrenables comprenden la matriz de pesos sinápticos $W^{(l)} \in \mathbb{R}^{n_{l-1} \times n_l}$ y el vector de sesgos (*biases*) $b^{(l)} \in \mathbb{R}^{1 \times n_l}$. Dado el vector de activación de la capa




Figura 3: Diagrama estructural del Perceptrón Multicapa (MLP) ilustrando la cinemática de propagación directa y el flujo retrógrado de gradientes locales de error.

previa $a^{(l-1)}$ (con $a^{(0)} = x \in \mathbb{R}^{1 \times n_0}$), la propagación hacia adelante se gobierna por:

$$z^{(l)} = a^{(l-1)}W^{(l)} + b^{(l)}, \quad a^{(l)} = f^{(l)}(z^{(l)}) \quad (1)$$

donde $z^{(l)}$ es el potencial neto post-sináptico y $f^{(l)} : \mathbb{R} \rightarrow \mathbb{R}$ representa la función de activación no lineal. En forma escalar, para cada neurona $j \in \{1, \dots, n_l\}$:

$$z_j^{(l)} = \sum_{i=1}^{n_{l-1}} a_i^{(l-1)}W_{ij}^{(l)} + b_j^{(l)}, \quad a_j^{(l)} = f^{(l)}(z_j^{(l)}). \quad (2)$$

2.1.1. Catálogo de Funciones de Activación y sus Derivadas

En conformidad con el Numeral 1 de la guía, se incorporaron y vectorizaron las tres funciones canónicas de activación junto con la función Softmax multiclase y la activación lineal. La Tabla 1 sintetiza sus formulaciones, derivadas analíticas y propiedades cinemáticas.

Tabla 1: Formulación matemática y derivadas analíticas de las funciones de activación implementadas.

Función	Ecuación Directa $f(z)$	Derivada Analítica $f'(z)$	Rango $\mathcal{R}_f$	Zona de Saturación
Sigmoide	$\sigma(z) = \frac{1}{1+e^{-z}}$	$\sigma(z)(1 - \sigma(z)) = a(1 - a)$	$(0, 1)$	$ z > 4 \implies f' \rightarrow 0$
Tanh	$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	$1 - \tanh^2(z) = 1 - a^2$	$(-1, 1)$	$ z > 3 \implies f' \rightarrow 0$
ReLU	$\max(0, z)$	$\begin{cases} 1 & z > 0 \\ 0 & z \leq 0 \end{cases}$	$[0, \infty)$	$z < 0 \implies$ Neurona Inactiva
Lineal	$f(z) = z$	$f'(z) = 1$	$(-\infty, \infty)$	No satura
Softmax	$s_i(z) = \frac{e^{z_i - \max(z)}}{\sum_j e^{z_j - \max(z)}}$	$\frac{\partial s_i}{\partial z_j} = s_i(\delta_{ij} - s_j)$	$(0, 1), \sum s_i = 1$	Normalización probabilística

Inicialización Sináptica: Para prevenir la saturación prematura de las sigmoides en épocas iniciales, se implementó la inicialización Xavier/Glorot uniforme, $W \sim U[-\sqrt{6/(n_{\text{in}} + n_{\text{out}})}, \sqrt{6/(n_{\text{in}} + n_{\text{out}})}]$, la cual preserva la varianza de las activaciones a través de las capas. Para capas ReLU se programó la inicialización He normal, $W \sim \mathcal{N}(0, 2/n_{\text{in}})$.

2.2. Retropropagación del Error y Regla Delta Generalizada con Momento

Dado un conjunto supervisado de entrenamiento $\mathcal{D} = \{(x^{(p)}, y^{(p)})\}_{p=1}^N$, la función de costo cuadrática instantánea (*Mean Squared Error*) se define como:

$$J(W, b) = \frac{1}{2} \|y - a^{(L)}\|^2 = \frac{1}{2} \sum_{k=1}^{n_L} (y_k - a_k^{(L)})^2. \quad (3)$$

Se define el **error local** $\delta_j^{(l)}$ de la neurona j en la capa l como la sensibilidad negativa del costo respecto a su potencial neto post-sináptico:

$$\delta_j^{(l)} \equiv -\frac{\partial J}{\partial z_j^{(l)}}. \quad (4)$$

2.2.1. 1. Gradiente del Error en la Capa de Salida ($l = L$)

Aplicando la regla de la cadena sobre la neurona de salida k :

$$\frac{\partial J}{\partial z_k^{(L)}} = \frac{\partial J}{\partial a_k^{(L)}} \frac{\partial a_k^{(L)}}{\partial z_k^{(L)}} = -(y_k - a_k^{(L)}) f'^{(L)}(z_k^{(L)}). \quad (5)$$

Sustituyendo en (4), el error local en la capa de salida adquiere la forma vectorial:

$$\delta^{(L)} = (y - a^{(L)}) \odot f'^{(L)}(z^{(L)}) \quad (6)$$

donde $\odot$ denota el producto de Hadamard (elemento a elemento).

2.2.2. 2. Retropropagación a Capas Ocultas ($l = L - 1, \dots, 1$)

El potencial neto $z_j^{(l)}$ de una unidad oculta afecta el costo J a través de todas las conexiones que parten hacia la capa subsiguiente $l + 1$:

$$\frac{\partial J}{\partial z_j^{(l)}} = \sum_{k=1}^{n_{l+1}} \frac{\partial J}{\partial z_k^{(l+1)}} \frac{\partial z_k^{(l+1)}}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} = \sum_{k=1}^{n_{l+1}} (-\delta_k^{(l+1)}) W_{jk}^{(l+1)} f'^{(l)}(z_j^{(l)}). \quad (7)$$

Multiplicando por -1 , se deduce la ecuación fundamental de retropropagación:

$$\delta_j^{(l)} = \left(\sum_{k=1}^{n_{l+1}} \delta_k^{(l+1)} W_{jk}^{(l+1)} \right) f'^{(l)}(z_j^{(l)}). \quad (8)$$

En notación matricial fila vectorizada:

$$\delta^{(l)} = \left(\delta^{(l+1)} (W^{(l+1)})^T \right) \odot f'^{(l)}(z^{(l)}). \quad (9)$$

2.2.3. 3. Regla Delta Generalizada con Momento Inercial (β)

El descenso de gradiente estándar sufre oscilaciones destructivas en valles de gradiente escarpado y anisotrópico. La **Regla Delta Generalizada** incorpora un término inercial $\beta \in [0, 1)$ que almacena

memoria de la dirección previa:

$$\Delta W^{(l)}(t) = \eta (a^{(l-1)})^T \delta^{(l)} + \beta \Delta W^{(l)}(t-1) \quad (10)$$

$$\Delta b^{(l)}(t) = \eta \delta^{(l)} + \beta \Delta b^{(l)}(t-1) \quad (11)$$

$$W^{(l)}(t+1) = W^{(l)}(t) + \Delta W^{(l)}(t), \quad b^{(l)}(t+1) = b^{(l)}(t) + \Delta b^{(l)}(t). \quad (12)$$

Analogía Física y Filtrado Espectral: Físicamente, el momento equivale a modelar el aprendizaje como una partícula con masa en un campo de potencial viscoso amortiguado [7]. Si el gradiente es persistente en magnitud g , la actualización asintótica converge a:

$$\Delta w(t) = \eta g \sum_{k=0}^t \beta^k \xrightarrow{t \rightarrow \infty} \frac{\eta}{1-\beta} g. \quad (13)$$

Por ende, con $\beta = 0,9$, la velocidad de avance efectivo longitudinal se amplifica por un factor de $10 \times (\frac{1}{1-0,9})$, mientras que los gradientes transversales de signo alternante interfieren destructivamente y se cancelan. Si $\beta \geq 1,0$, el sistema pierde disipación y diverge inestablemente.




Figura 4: Dinámica comparativa de optimización en topografías anisotrópicas (adaptado de [7, 8]): el descenso de gradiente estándar oscila bruscamente en valles estrechos, mientras que el momento inercial β acumula velocidad en la dirección persistente y cancela oscilaciones parásitas.

2.3. Separabilidad Lineal, Espacios Latentes y Regularización

Separabilidad Lineal y Teorema de Aproximación Universal: Un clasificador lineal monocapa (Perceptrón/Adaline) genera una frontera plana $w^T x + b = 0$. En problemas no linealmente separables como XOR, los estados activos y pasivos no admiten separación por un hiperplano. En contraste, el Teorema de Aproximación Universal (Cybenko, 1989 [5]; Hornik, 1991 [6]) estipula que una red feedforward con al menos una capa oculta no lineal continua puede aproximar con precisión arbitraria cualquier funcional continuo sobre compactos de $\mathbb{R}^n$.

Geoméricamente, las capas ocultas ejecutan una transformación no lineal continua $\Phi : \mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_1}$ que proyecta los datos a un **espacio latente** $H = a^{(1)}$. En este nuevo espacio, la variedad geométrica entrelazada se deforma y desdobra, logrando que clases originalmente no separables resulten trivialmente separables mediante la capa de salida lineal.

Descomposición Sesgo-Varianza y Parada Temprana: El error esperado de generalización ante datos no vistos se descompone en tres fuentes ortogonales [10]:

$$\mathbb{E}[(y - \hat{f}(x))^2] = \underbrace{(f(x) - \mathbb{E}[\hat{f}(x)])^2}_{\text{Sesgo}^2} + \underbrace{\mathbb{E}[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^2]}_{\text{Varianza}} + \underbrace{\sigma_\epsilon^2}_{\text{Ruido Irreducible}}. \quad (14)$$

Conforme el número de épocas tiende a infinito en una red sobreparametrizada, el sesgo sobre entrenamiento colapsa asintóticamente a cero mientras la varianza se incrementa patológicamente (memorización de ruido). *Early Stopping* congela los pesos en el punto de mínima pérdida de validación t^* . Teóricamente, esto actúa como una regularización espectral implícita equivalente al decaimiento de pesos L_2 (*Weight Decay*) con coeficiente efectivo $\lambda_{\text{efectivo}} \approx \frac{1}{\eta t^*}$ [11], acotando la norma de Frobenius $\|W\|_F$ sin requerir cálculo de multiplicadores de Lagrange.




Figura 5: Curva conceptual del compromiso sesgo-varianza y mecanismo de Parada Temprana (*Early Stopping*) (adaptado de [11]): evolución divergente del error de entrenamiento frente al error de validación e identificación del punto óptimo de generalización antes del sobreajuste.

3. Metodología

3.1. Diseño Arquitectónico y Parametrizabilidad (Numeral 2)

En observancia del Numeral 2 de la guía, el modelo neuronal se implementó siguiendo un diseño orientado a objetos en Python, empleando matrices de álgebra lineal vectorizada con NumPy para trasladar las transformaciones afines y la retropropagación a operaciones contiguas de memoria en CPU. Este diseño modular desacopla la topología de la optimización y viabiliza la parametrización sistemática de la red:

- **Topología Parametrizable:** Configuración arbitraria de dimensiones $[n_0, n_1, \dots, n_L]$ mediante la lista `layer_sizes`, permitiendo evaluar redes delgadas o profundas sin alterar la lógica de cálculo.
- **Polimorfismo de Activación:** Selección flexible por capa de funciones continuas (Sigmoide, Tanh, ReLU, Lineal y Softmax) con derivadas analíticas vectorizadas y acotamiento numérico (*clipping* $[-50, 50]$) para estabilidad en coma flotante.
- **Regímenes de Optimización:** Soporte para aprendizaje estocástico muestra a muestra (*online*), por lote completo (*batch*) y mini-lotes (*mini-batch*), gobernados por la tasa η y el factor de momento β .
- **Monitor de Generalización y Parada Temprana:** Evaluación periódica sobre un subconjunto de validación con persistencia y restauración del estado sináptico óptimo $\mathbf{W}^*$ ante el agotamiento de la paciencia configurada.




Figura 6: Diagrama del flujo computacional y arquitectura modular del Perceptrón Multicapa.

La Tabla 2 resume las configuraciones representativas parametrizadas para los experimentos centrales del taller.

Tabla 2: Configuraciones arquitectónicas principales implementadas y evaluadas.

Experimento	Topología	η	β	Activación	Modo	Criterio de Parada
XOR-2	[2, 2, 1]	0.50	0.50	Sigmoide	Online	$MSE \leq 0,005$
XOR-3 (Paridad)	[3, 4, 1] y [3, 6, 1]	0.50	0.50	Sigmoide	Online	$MSE \leq 0,005$
Iris (Óptimo)	[4, 8, 4, 3]	0.10	0.70	Sigmoide	Online	$MSE \leq 0,002$ (180 épocas)
Particiones Bench.	$[D, 16, 8, K]$	0.08	0.70	Sigmoide	Online	Paciencia 40 / 150 épocas
Sobreajuste	[30, 64, 32, 1]	0.08	0.50	Sigmoide	Online	Paciencia 40 / 1500 épocas

3.2. Datasets y Protocolo de Particionamiento

Se evaluaron cinco conjuntos de datos con diversas propiedades topológicas y dimensionales, descritos en la Tabla 3.

Prevención Estricta de Fuga de Información (Zero Data Leakage): En variables continuas con rangos heterogéneos, las componentes de gran escala dominan el gradiente numérico. Se aplicó estandarización *z-score*:

$$x_{\text{std}} = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}. \quad (15)$$

Tabla 3: Resumen estructural y dimensional de los conjuntos de datos evaluados.

Dataset	Muestras (N)	Atributos (D)	Clases (K)	Balanceo	Desafío Topológico
XOR-2	4	2	2	Balanceado	No separable linealmente en $\mathbb{R}^2$
XOR-3	8	3	2	Balanceado	Paridad impar en hipercubo 3D
Fisher's Iris	150	4	3	Balanceado (50/50/50)	1 linealmente separable, 2 solapadas
Wine Recognition	178	13	3	59 / 71 / 48	13 variables químicas continuas
Breast Cancer	569	30	2	357 Ben. / 212 Mal.	Alta dimensionalidad diagnóstica
Banknote Auth.	1372	4	2	762 Aut. / 610 Fals.	Momentos continuos wavelet continuos

La media μ_{train} y desviación σ_{train} se computaron **exclusivamente sobre la partición de entrenamiento** de cada corte. Los subconjuntos de validación y prueba se transformaron empleando los estadísticos de entrenamiento previamente congelados. Esto garantiza estricta validez científica al impedir cualquier fuga de información hacia el modelo. Además, el centrado en cero sitúa los potenciales netos en la región de máxima derivada sigmoidea ($\sigma'(0) = 0,25$), acelerando el flujo de gradientes.

Particionamiento Estratificado: Para los datasets *Wine*, *Breast Cancer* y *Banknote*, se generaron cuatro particiones estratificadas: 60-40, 70-30, 80-20 y 90-10, preservando la proporción original de clases y fijando la semilla aleatoria en $\text{seed} = 42$ para garantizar absoluta reproducibilidad. Para el estudio multiclase en Iris, se empleó una partición estratificada con 56 % train ($N = 84$), 14 % validación ($N = 21$) y 30 % test ($N = 45$, exactamente 15 por especie). Para el estudio de sobreajuste en Breast Cancer, se fijó una distribución 50 % train ($N = 284$), 25 % val ($N = 142$) y 25 % test ($N = 143$).

4. Resultados

4.1. Problemas XOR (2 y 3 Entradas) (Numeral 3)

4.1.1. Disyunción Exclusiva de 2 Entradas (XOR-2)

La Tabla 4 compara cuantitativamente el desempeño de los modelos monocapa evaluados en el Taller 1 frente al Perceptrón Multicapa ($[2, 2, 1]$, sigmoide, $\eta = 0,50$, $\beta = 0,50$, umbral de convergencia $MSE \leq 0,005$).

Tabla 4: Comparativa de convergencia en el problema XOR-2 entre arquitecturas monocapa y multicapa.

Modelo	Topología	Lineal	Épocas	MSE Final	Exactitud	Diagnóstico Cinemático
Perceptrón Simple	$[2, 1]$	Sí	200	0.5000	50.0 %	Oscilación periódica sin convergencia
Adaline (LMS)	$[2, 1]$	Sí	67	0.2507	75.0 %	Estancamiento en mínimo plano de compromiso
MLP (Backpropagation)	$[2, 2, 1]$	No	1649	0.00499	100.0 %	Convergencia perfecta: resuelve la no-linealidad




Figura 7: Contraste empírico de modelos en compuertas XOR: el Perceptrón Simple y Adaline colapsan en el 50 %, mientras el MLP alcanza exactitud perfecta del 100 % en 2 y 3 dimensiones.

Como evidencia la Figura 7(a), el Perceptrón Simple oscila periódicamente entre clasificar tres vértices y cometer un error, mientras que Adaline proyecta un compromiso plano con salidas continuas en torno a 0,5. En contraste, el MLP reduce monótonamente su costo cuadrático hasta alcanzar $MSE = 0,00499$, generando predicciones continuas de $[0,0768, 0,9329, 0,9330, 0,0728]^T$ que se traducen en una exactitud del **100.0 %**.

4.1.2. Mecanismo de Despliegue en el Espacio Latente

El Numeral 3 de la guía solicita explícitamente evidenciar la necesidad de la capa oculta. La Figura 8 desglosa geoméricamente este mecanismo:

- **Espacio Sensorial de Entrada** $[x_1, x_2]$ (**Panel A**): Los estados activos $(0, 1)$ y $(1, 0)$ ocupan las esquinas de una diagonal, mientras los estados pasivos $(0, 0)$ y $(1, 1)$ ocupan la diagonal opuesta. Ninguna recta en $\mathbb{R}^2$ puede separar simultáneamente ambos conjuntos conexos.
- **Espacio Latente Intermedio** $[h_1, h_2]$ (**Panel B**): Las dos neuronas ocultas calculan combinaciones afines sigmoideas que repliegan el espacio. Los vértices $(0, 1)$ y $(1, 0)$ son proyectados congruentemente a la región $(0,93, 0,07)$, mientras $(0, 0)$ viaja hacia $(0,07, 0,07)$ y $(1, 1)$ es enviado hacia $(0,93, 0,93)$.
- **Separabilidad Lineal Inducida**: En el espacio latente H , las dos clases se encuentran geométricamente desacopladas, permitiendo que la neurona de salida trace un hiperplano lineal con margen amplio y robusto.




Figura 8: Mecanismo de linealización del MLP en XOR-2: (A) Superficie de decisión no lineal en el espacio de entrada $\mathbb{R}^2$; (B) Mapeo continuo al espacio latente $[h_1, h_2]$ generado por la capa oculta, donde los patrones resultan linealmente separables.

4.1.3. Dinámica de Hiperparámetros y Aceleración Inercial por Momento (β)

Se ejecutó un barrido de alta densidad en el plano $(\eta, \beta) \in [0,1, 2,0] \times [0,0, 1,0]$. La Figura 9 ilustra los cortes paramétricos unidimensionales:

- **Efecto de la Tasa η ($\beta = 0,0$):** El incremento de η desde 0,1 hasta 2,0 reduce las épocas de convergencia de 9371 a 581 (93,8 % de reducción). Para $\eta > 2,0$, aparecen rebotes oscilatorios y divergencia.
- **Efecto del Momento β ($\eta = 0,5$):** Con $\beta = 0,0$ se requieren 3137 épocas. Al incrementar el momento a $\beta = 0,5$ se reduce a 1649 épocas; con $\beta = 0,7$, a 1051; y con $\beta = 0,9$, la red converge en apenas **394 épocas** (una reducción del **87.44 %** en costo computacional).
- **Inestabilidad Crítica en $\beta = 1,0$:** Sin disipación viscosa de energía cinética, la optimización oscila indefinidamente, agotando el techo de 15000 épocas sin converger ($MSE = 0,2521$).




Figura 9: Dinámica de convergencia en XOR-2 evaluando el impacto individual de la tasa de aprendizaje η y el momento β .




Figura 10: Caracterización bidimensional global del espacio de hiperparámetros (η, β) para el entrenamiento del MLP en XOR-2.




Figura 11: Curvas de evolución temporal del Error Cuadrático Medio (MSE) en función de las épocas bajo diferentes intensidades de momento inercial β para una tasa fija $\eta = 0,50$.

La caracterización bidimensional completa (Figura 10) evidencia una cuenca de mínima resistencia computacional en el rango $\eta \in [0,5, 1,2]$ con $\beta \in [0,6, 0,9]$. Las trayectorias de MSE (Figura 11) demuestran cómo un β elevado comprime drásticamente la fase de meseta inicial previa al desprendimiento del gradiente.

4.1.4. Paridad Impar de 3 Entradas (XOR-3)

La compuerta XOR-3 asigna salida 1 si el número de entradas activas es impar. La Tabla 5 resume la comparación frente a clasificadores monocapa, mientras que la Tabla 6 detalla las predicciones patrón por patrón.

Tabla 5: Rendimiento cuantitativo en el problema de paridad booleana de 3 entradas (XOR-3).

Modelo Evaluado	Topología	Épocas	Convergencia	MSE Final	Exactitud	Patrones Correctos
Perceptrón Simple	[3, 1]	300	No	0.5000	50.0 %	4 / 8
Adaline (LMS)	[3, 1]	93	No	0.2504	50.0 %	4 / 8
MLP (4 Ocultas)	[3, 4, 1]	1135	Sí	0.00497	100.0 %	8 / 8
MLP (6 Ocultas)	[3, 6, 1]	992	Sí	0.00497	100.0 %	8 / 8

Tabla 6: Predicciones analíticas continuas y discretas sobre los 8 patrones de la compuerta XOR-3.

Patrón (x_1, x_2, x_3)	Target y	Pred. Perc.	Pred. Adal.	Pred. MLP-4	$\hat{P}(\text{MLP-4})$	Pred. MLP-6	$\hat{P}(\text{MLP-6})$
(0, 0, 0)	0	0	0	0	0.0130	0	0.0333
(0, 0, 1)	1	0	0	1	0.9557	1	0.9462
(0, 1, 0)	1	1	0	1	0.9763	1	0.9494
(0, 1, 1)	0	1	0	0	0.0729	0	0.0753
(1, 0, 0)	1	1	1	1	0.9555	1	0.9816
(1, 0, 1)	0	1	1	0	0.0760	0	0.0715
(1, 1, 0)	0	1	1	0	0.0761	0	0.0741
(1, 1, 1)	1	1	1	1	0.8651	1	0.8711

En 3 dimensiones, la alternancia de paridad requiere particionar el hipercubo con al menos dos planos de corte paralelos. El Perceptrón y Adaline quedan estrictamente restringidos al 50 % de acierto, mientras que el MLP con 4 neuronas ocultas converge en 1135 épocas, y con 6 neuronas ocultas acelera a 992 épocas, alcanzando **100.0 %** de acierto con alta certidumbre probabilística en todos los vértices.

4.2. Clasificación Multiclase: Fisher’s Iris (Numeral 4)

En atención estricta al Numeral 4 de la guía, se exploró una matriz de 9 configuraciones sistemáticas producto de combinar tres topologías ([4, 4, 3], [4, 8, 3] y la red profunda [4, 8, 4, 3]) con tres tasas de aprendizaje $\eta \in \{0,05, 0,10, 0,30\}$, bajo momento inercial fijo $\beta = 0,70$. La Tabla 7 compendia los resultados sobre el subconjunto de prueba independiente ($N_{\text{test}} = 45$).

Tabla 7: Resultados experimentales de clasificación multiclase sobre el dataset Iris (Numeral 4)

ID	Arquitectura	η	Épocas	Conv.	MSE Train	MSE Val	Exactitud (%)
CONF-01	[4, 4, 3]	0.05	652	✓	0.00200	0.00153	91.11
CONF-02	[4, 4, 3]	0.10	335	✓	0.00200	0.00049	91.11
CONF-03	[4, 4, 3]	0.30	167	✓	0.00186	0.00048	91.11
CONF-04	[4, 8, 3]	0.05	677	✓	0.00199	0.00041	91.11
CONF-05	[4, 8, 3]	0.10	340	✓	0.00193	0.00043	91.11
CONF-06	[4, 8, 3]	0.30	159	✓	0.00176	0.00065	91.11
CONF-07	[4, 8, 4, 3]	0.05	305	✓	0.00192	0.00092	91.11
CONF-08	[4, 8, 4, 3]	0.10	180	✓	0.00194	0.00140	93.33
CONF-09	[4, 8, 4, 3]	0.30	174	✓	0.00187	0.01226	91.11

Análisis de Convergencia y Arquitectura Óptima: Como ilustra la Figura 12, todas las configuraciones convergieron antes del límite de 1500 épocas. La arquitectura profunda CONF-08 ([4, 8, 4, 3] con $\eta = 0,10$) logró el desempeño superior con **93.33 %** de exactitud en prueba y $F_1 = 0,9327$ en 180 épocas.

Matriz de Confusión y Exactitud por Configuración: La Figura 13(a) y el panel general (Figura 14) confirman clasificación impecable al 100 % en *Setosa* (15/15) y *Versicolor* (15/15). Los tres únicos errores corresponden a patrones de *Virginica* clasificados como *Versicolor*, atribuibles a la zona de solapamiento morfométrico natural entre ambas especies botánicas.

Desenredo Topológico en Espacios Latentes: La proyección PCA (Figura 15) ilustra con gran elocuencia el principio de representación interna: en el espacio sensorial $\mathbb{R}^4$ (Panel A), *Versicolor* y *Virginica* se intersectan; en la primera capa oculta $H^{(1)} \in \mathbb{R}^8$ (Panel B), la dispersión intra-clase disminuye; y en la segunda capa oculta $H^{(2)} \in \mathbb{R}^4$ (Panel C), los cúmulos se condensan en entidades linealmente separables antes de ingresar a la capa de decisión Softmax.

4.3. Evaluación en Múltiples Particiones: Wine, Breast Cancer y Banknote (Numeral 5)

En cumplimiento del Numeral 5, se adaptó el protocolo de particionamiento estratificado sobre los tres conjuntos continuos bajo razones 60-40, 70-30, 80-20 y 90-10. La Tabla 8 resume la exactitud en prueba, y la Tabla 9 detalla el costo en tiempo (ms), épocas y métricas F1 frente a Perceptrón y Adaline.





Figura 12: Curvas duales de convergencia del error (MSE_{train} vs. MSE_{val}) en función de las épocas para las 9 configuraciones evaluadas sobre el dataset Iris (Numeral 4).



(a) Matriz de Confusión Mejor Modelo ([4, 8, 4, 3])

(b) Exactitud en Test según Tasa η

Figura 13: Evaluación multiclase sobre prueba en Iris: (a) Desempeño del mejor modelo; (b) Comparativa de exactitud entre las tres arquitecturas y tasas evaluadas.




Figura 14: Panel comparativo de matrices de confusión sobre el conjunto de prueba independiente para las 9 configuraciones exploradas en Iris.





Figura 15: Proyección PCA bidimensional del espacio sensorial $\mathbb{R}^4$ frente a los espacios latentes $H^{(1)} \in \mathbb{R}^8$ y $H^{(2)} \in \mathbb{R}^4$ en la red óptima [4, 8, 4, 3], evidenciando la separación progresiva de las clases.

Tabla 8: Exactitud de prueba (%) según proporción de partición (Numeral 5)


Dataset	Partición	MLP (%)	Perceptrón (%)	Adaline (%)
Wine	60-40	98.59	97.18	98.59
Wine	70-30	98.11	98.11	98.11
Wine	80-20	97.22	100.00	100.00
Wine	90-10	100.00	100.00	100.00
Breast Cancer	60-40	96.49	94.74	94.74
Breast Cancer	70-30	96.49	94.74	95.32
Breast Cancer	80-20	97.37	92.98	97.37
Breast Cancer	90-10	98.25	94.74	96.49
Banknote	60-40	99.82	99.09	98.00
Banknote	70-30	99.03	99.27	98.30
Banknote	80-20	100.00	99.27	97.81
Banknote	90-10	98.54	98.54	98.54

4.3.1. Hallazgos Numéricos Principales

- **Wine Recognition ($D = 13$):** El MLP alcanzó exactitud perfecta del **100.0 %** en la partición 90-10 ($F_1 = 1,0000$) y 98,59 % en 60-40, resolviendo la correlación cruzada entre compuestos químicos.
- **Breast Cancer Wisconsin ($D = 30$):** El MLP superó de forma sistemática a los modelos monocapa en todas las particiones: 96,49 % en 60-40 y 70-30, 97,37 % en 80-20 y **98.25 %** en 90-10 (frente al 94,74 % del Perceptrón). En diagnóstico oncológico, el MLP redujo los falsos negativos a su mínima expresión (Figura 18).
- **Banknote Authentication ($D = 4$):** En la partición estándar 80-20, el MLP logró **100.00 %** de acierto perfecto (274/274 instancias de prueba correctamente discriminadas, $F_1 = 1,0000$).
- **Tiempo vs. Épocas de Convergencia:** Como detalla la Figura 16(b), aunque el MLP involucra mayor sobre costo en milisegundos por iteración debido a las multiplicaciones matriciales del paso retrógrado, el momento inercial amortiguado reduce drásticamente las épocas requeridas: el MLP converge en apenas **14 a 31 épocas**, mientras el Perceptrón agota el techo de 150 épocas sin converger formalmente en Breast Cancer y Banknote.



(a) Exactitud de Prueba vs. Tamaño de Partición




(b) Tiempo (ms) y Épocas en Partición 80-20


Figura 16: Desempeño global en particiones continuas: (a) Evolución de la exactitud frente al volumen de entrenamiento; (b) Costo computacional de convergencia.

Tabla 9: Matriz comparativa multidimensional de desempeño: MLP vs. Perceptrón vs. Adaline bajo cuatro particiones


Dataset	Partición	Modelo	Exactitud Train (%)	Exactitud Test (%)	F1 Macro	Tiempo (ms)	Épocas	Conv.
Wine	60-40	Perceptrón Simple	100.00	97.18	0.9718	2.0	5	✓
Wine	60-40	Adaline / LMS	99.07	98.59	0.9858	23.5	42	✓
Wine	60-40	MLP (Backpropagation)	100.00	98.59	0.9858	119.8	18	✓
Wine	70-30	Perceptrón Simple	100.00	98.11	0.9823	2.4	8	✓
Wine	70-30	Adaline / LMS	100.00	98.11	0.9823	24.5	38	✓
Wine	70-30	MLP (Backpropagation)	100.00	98.11	0.9823	105.8	15	✓
Wine	80-20	Perceptrón Simple	100.00	100.00	1.0000	2.4	8	✓
Wine	80-20	Adaline / LMS	100.00	100.00	1.0000	25.3	33	✓
Wine	80-20	MLP (Backpropagation)	100.00	97.22	0.9726	132.4	16	✓
Wine	90-10	Perceptrón Simple	100.00	100.00	1.0000	2.8	10	✓
Wine	90-10	Adaline / LMS	100.00	100.00	1.0000	26.6	32	✓
Wine	90-10	MLP (Backpropagation)	100.00	100.00	1.0000	125.3	14	✓
Breast Cancer	60-40	Perceptrón Simple	100.00	94.74	0.9445	30.6	98	✓
Breast Cancer	60-40	Adaline / LMS	97.36	94.74	0.9432	46.4	64	✓
Breast Cancer	60-40	MLP (Backpropagation)	99.12	96.49	0.9625	682.0	25	✓
Breast Cancer	70-30	Perceptrón Simple	100.00	94.74	0.9457	32.8	90	✓
Breast Cancer	70-30	Adaline / LMS	96.73	95.32	0.9512	65.5	75	✓
Breast Cancer	70-30	MLP (Backpropagation)	99.25	96.49	0.9637	500.8	16	✓
Breast Cancer	80-20	Perceptrón Simple	99.56	92.98	0.9271	67.1	150	×
Breast Cancer	80-20	Adaline / LMS	97.14	97.37	0.9726	53.1	41	✓
Breast Cancer	80-20	MLP (Backpropagation)	99.12	97.37	0.9728	535.6	15	✓
Breast Cancer	90-10	Perceptrón Simple	98.24	94.74	0.9429	77.5	150	×
Breast Cancer	90-10	Adaline / LMS	97.07	96.49	0.9605	31.8	30	✓
Breast Cancer	90-10	MLP (Backpropagation)	99.02	98.25	0.9810	1250.2	31	✓
Banknote	60-40	Perceptrón Simple	98.91	99.09	0.9908	122.4	150	×
Banknote	60-40	Adaline / LMS	97.45	98.00	0.9799	12.9	8	✓
Banknote	60-40	MLP (Backpropagation)	99.76	99.82	0.9982	1849.1	30	✓
Banknote	70-30	Perceptrón Simple	98.85	99.27	0.9927	134.0	150	×
Banknote	70-30	Adaline / LMS	97.71	98.30	0.9830	13.5	7	✓
Banknote	70-30	MLP (Backpropagation)	99.27	99.03	0.9903	1509.4	21	✓
Banknote	80-20	Perceptrón Simple	98.72	99.27	0.9927	152.4	150	×
Banknote	80-20	Adaline / LMS	97.09	97.81	0.9781	14.8	7	✓
Banknote	80-20	MLP (Backpropagation)	99.82	100.00	1.0000	2088.6	25	✓
Banknote	90-10	Perceptrón Simple	98.87	98.54	0.9854	167.1	150	×
Banknote	90-10	Adaline / LMS	97.57	98.54	0.9854	17.3	7	✓
Banknote	90-10	MLP (Backpropagation)	99.19	98.54	0.9854	1589.3	17	✓



(a) Wine Recognition



(b) Breast Cancer Diagnostic



(c) Banknote Authentication

Figura 17: Desglose detallado de exactitud en prueba por partición para cada uno de los tres conjuntos de datos continuos evaluados.




Figura 18: Panel 3×3 de matrices de confusión sobre prueba (partición 80-20) contrastando Perceptrón Simple, Adaline y MLP.




Figura 19: Curvas de aprendizaje del MLP (MSE logarítmico) a lo largo de las cuatro particiones para Wine, Breast Cancer y Banknote.

4.4. Sobreajuste y Parada Temprana (*Early Stopping*) (Numeral 6)

Para modelar la patología del sobreajuste en cumplimiento del Numeral 6, se entrenó una red fuertemente sobreparametrizada sobre el subconjunto reducido de Breast Cancer ($N_{\text{tr}} = 284$ muestras):

$$\mathcal{M}_{\text{sobre}} : [30 \rightarrow 64 \rightarrow 32 \rightarrow 1], \quad \eta = 0,08, \quad \beta = 0,50 \implies \mathbf{4097} \text{ parámetros entrenables.} \quad (16)$$

La razón de capacidad es de **14.43 parámetros por muestra**, propiciando memorización del conjunto de entrenamiento. Se implementó parada temprana con paciencia $P = 40$ y tolerancia $\Delta_{\min} = 10^{-4}$ sobre el subconjunto de validación ($N_{\text{val}} = 142$), preservando copias de los pesos óptimos W^* .




Figura 20: Dinámica temporal de sobreajuste en la red $[30, 64, 32, 1]$ a lo largo de 1500 épocas: delimitación de las cuatro fases canónicas (subajuste, mínimo óptimo en $t^* = 24$, disparo de parada en $t_{\text{stop}} = 64$ y divergencia por sobreajuste).

La Figura 20 valida con gran nitidez las cuatro fases temporales del aprendizaje:

1. **Subajuste Inicial** ($t \in [1, 10]$): Descenso conjunto y rápido de E_{train} y E_{val} desde 0,0998 hasta $\approx 0,0150$.
2. **Mínimo Óptimo de Validación** ($t^* = 24$): Mínimo error global en validación ($E_{\text{val}}^* = 0,012722$, $E_{\text{train}} = 0,008957$).
3. **Disparo de Parada** ($t_{\text{stop}} = 64$): Tras transcurrir 40 épocas sin registrar una mejora de magnitud $\Delta_{\min}$, se suspende la optimización.
4. **Divergencia de Varianza** ($t > 64 \rightarrow 1500$): E_{train} continúa decreciendo asintóticamente hasta 0,000013, mientras E_{val} diverge un **+102.2 %** hasta 0,025724 debido a la memorización espuria de ruido.

La Tabla 10 cuantifica el impacto directo sobre el subconjunto independiente de prueba ($N_{\text{test}} = 143$).

Tabla 10: Comparativa Cuantitativa de Sobreajuste y Parada Temprana en Breast Cancer (Numeral 6)

Modelo	Época	Train MSE	Val MSE	Test MSE	Exactitud (%)	Brecha $ E_{\text{test}} - E_{\text{tr}} $	Ahorro
Sobreajustado (Final)	1500	0.000013	0.025724	0.043489	95.10	0.043476	0.00 %
Early Stopping (W^*)	24	0.008957	0.012722	0.036247	94.41	0.027290	95.73 %

4.4.1. Impacto de la Variación del Número de Neuronas Ocultas

Para cumplir con el mandato de evaluar la variación en el número de neuronas ocultas, se entrenaron cuatro arquitecturas de complejidad creciente bajo el mismo protocolo a 1500 épocas. La Tabla 11 y la Figura 21 detallan los resultados.

Tabla 11: Impacto de la complejidad estructural sobre el sobreajuste y la generalización en Breast Cancer.

Régimen	Topología	Parám.	Ratio P/N	t^*	$E_{\text{tr}}(1500)$	$E_{\text{val}}(1500)$	$E_{\text{test}}(\text{Overfit})$	$E_{\text{test}}(\text{ES})$
Subajustada	[30, 2, 1]	65	0.23	30	$5,74 \times 10^{-5}$	0.02553	0.04577	0.03725
Parsimoniosa	[30, 8, 1]	257	0.90	28	$5,40 \times 10^{-5}$	0.02713	0.04621	0.03718
Balanceada	[30, 16, 8, 1]	641	2.26	22	$1,64 \times 10^{-5}$	0.02580	0.04627	0.03572
Sobreparametrizada	[30, 64, 32, 1]	4097	14.43	24	$1,27 \times 10^{-5}$	0.02572	0.04349	0.03625

El panel analítico de la Figura 21 valida tres beneficios cardinales:

1. **Reducción del Error Cuadrático en Prueba:** E_{test} desciende de 0,043489 en el modelo sobreajustado a 0,036247 con Early Stopping, representando una mejora neta del **16.65 %**.
2. **Contracción de la Brecha de Generalización:** La brecha $|E_{\text{test}} - E_{\text{train}}|$ se contrae de 0,043476 a 0,027290, una reducción del **37.23 %**.
3. **Ahorro Computacional Drástico:** Al suspender en la época 64 y restaurar W_{24}^* , se economiza el **95.73 %** del tiempo total de procesamiento.
4. **Calibración Probabilística:** Como corrobora la estimación de densidad KDE (Panel B), Early Stopping previene la saturación extrema de probabilidades hacia los bordes 0 y 1, preservando una excelente calibración en la predicción.




Figura 21: Panel analítico de regularización por Early Stopping: (A) Exactitud, MSE y brecha de generalización en prueba; (B) Estimación de densidad KDE de probabilidades en test; (C) Trayectorias de E_{val} para cuatro niveles de complejidad.

5. Análisis y Discusión

5.1. Cuadro Comparativo Multidimensional: Perceptrón vs. Adaline vs. MLP

La Tabla 12 sintetiza el análisis formal contrastando las tres arquitecturas neuronales abordadas en el curso a través de ocho dimensiones analíticas directrices.

Tabla 12: Cuadro comparativo multidimensional entre el Perceptrón Simple, Adaline y el Perceptrón Multicapa.

Criterio	Perceptrón Simple (Rosenblatt)	Red Adaline (Widrow-Hoff)	Perceptrón Multicapa (Rumelhart)
Topología	Monocapa, sin capas ocultas ($[D, 1]$)	Monocapa, sin capas ocultas ($[D, 1]$)	Multicapa profunda ($[D, n_1, \dots, n_L]$)
Activación	Escalón Heaviside discreto $\{0, 1\}$	Lineal en entrenamiento, umbral en test	Sigmoide, Tanh, ReLU, Softmax continuas
Función Costo	No diferenciable (recuento de fallos)	Cuadrática convexa (MSE en pre-activación)	No convexa altamente multimodal (MSE, CE)
Optimización	Regla heurística de corrección	Descenso de Gradiente Estocástico (LMS)	Retropropagación con Momento Inercial β
Separabilidad	Estrictamente lineal ($\mathbb{R}^{D-1}$)	Estrictamente lineal (mínimos cuadrados)	No lineal arbitraria (Aproximador Universal)
Resolución XOR	Fracaso (cicla indefinido, 50 %)	Fracaso (compromiso plano, 50 % – 75 %)	Éxito perfecto (100,0 %, deformación latente)
Sensibilidad Escala	Moderada (altera velocidad angular)	Severa (diverge si $\alpha > 2/\lambda_{\max}$)	Crítica (satura gradientes sin estandarizar)
Banco Banknote	Test Acc: $\approx 98,5\% - 99,3\%$	Test Acc: $\approx 97,1\% - 98,5\%$	Test Acc: 100,00 % ($F_1 = 1,0000$ en 80-20)

5.2. Sensibilidad Dinámica a la Interacción de Hiperparámetros (η, β)

El comportamiento dinámico del algoritmo de retropropagación se encuentra determinado por la interacción no lineal entre la tasa de aprendizaje η y el coeficiente de momento β :

- **Tasa η :** Dicta la longitud del paso en el espacio de parámetros. Tasas excesivamente reducidas ($\eta \leq 0,01$) causan un progreso exasperadamente lento en zonas de gradiente atenuado; por su parte, valores demasiado altos ($\eta \geq 2,0$) inducen sobrepasos oscilatorios desestabilizadores.
- **Momento β :** Actúa como un filtro pasa-bajo que suaviza la trayectoria de descenso. Al ponderar la inercia acumulada, cancela componentes alternantes de alta frecuencia transversal y multiplica el desplazamiento en direcciones de curvatura consistente por $\frac{1}{1-\beta}$. La aceleración del **87.44 %** evidenciada en XOR-2 comprueba que el momento es imprescindible para atravesar mesetas de bajo gradiente sin estancarse.

5.3. Compromiso entre Profundidad y Ancho (*Depth vs. Width Trade-off*)

Los hallazgos en Iris y Breast Cancer sustentan principios fundamentales de diseño arquitectónico:

- Redes excesivamente anchas y superficiales requieren un número cuadrático de sinapsis en una sola capa, propiciando memorización localizada de patrones individuales.

- Redes más profundas y parsimoniosas ($[4, 8, 4, 3]$ o $[30, 16, 8, 1]$) construyen jerarquías composicionales progresivas. Como ratificó la proyección PCA en Iris, la primera capa extrae combinaciones lineales básicas, mientras que las capas intermedias subsiguientes desenredan la variedad topológica, alcanzando mayor exactitud con menor número de parámetros totales.

6. Conclusiones

1. **Superación Categórica de la Barrera Lineal:** El Perceptrón Multicapa demostró capacidad analítica y empírica para resolver las compuertas XOR de 2 y 3 entradas (paridad) con exactitud perfecta del **100.0 %**, desarticulando la restricción geométrica monocapa formalizada por Minsky y Papert (1969). Frente a la oscilación permanente del Perceptrón (50,0 %) y la degradación plana de Adaline (50,0 % – 75,0 %), la inclusión de capas ocultas intermedias no lineales faculta a la red para modelar contornos cerrados y regiones de decisión de complejidad arbitraria.
2. **Desenredo Topológico en Espacios Latentes:** Se evidenció visual y geoméricamente mediante análisis de componentes principales (PCA) que las capas ocultas actúan como proyectores no lineales que transforman las variedades continuas. En el problema XOR-2, la capa oculta mapea los patrones a un espacio latente bidimensional $[h_1, h_2]$ donde las clases son trivialmente separables por una recta. De forma análoga, en el dataset Iris, la red profunda $[4, 8, 4, 3]$ desacopló progresivamente las clases solapadas *Versicolor* y *Virginica*, alcanzando un **93.33 %** de exactitud en prueba.
3. **Aceleración Inercial por Momento (β):** La incorporación del término inercial β demostró acelerar la convergencia del entrenamiento en hasta un **87.44 %** ($\beta = 0,9$ vs. $\beta = 0,0$). Su mecanismo opera como un filtro pasa-bajo que amortigua oscilaciones destructivas en cañones estrechos de error y amplifica la velocidad efectiva por un factor de $\frac{1}{1-\beta}$. Asimismo, se comprobó experimentalmente la cota de inestabilidad divergente en $\beta = 1,0$ por ausencia de amortiguamiento viscoso.
4. **Desempeño Superior en Benchmarks Continuos Multiclase:** En los tres conjuntos de datos del Taller 1, el MLP superó holgadamente a los modelos lineales monocapa: **100.00 %** en Banknote Authentication (partición 80-20, $F_1 = 1,0000$), **100.00 %** en Wine Recognition (partición 90-10) y **98.25 %** en Breast Cancer Wisconsin. Aunque el paso hacia atrás incrementa el tiempo por época, la convergencia se logró en solo **14 a 31 épocas**, mientras que el Perceptrón Simple agotó 150 épocas sin converger en datos complejos.
5. **Regularización Efectiva por Parada Temprana:** En una red sobreparametrizada con 14,43 parámetros por muestra, la técnica de *Early Stopping* redujo el error de prueba en un **16.65 %**, contrajo la brecha de generalización en un **37.23 %** y brindó una economía computacional del **95.73 %**, confirmando su comportamiento como un regularizador implícito de norma sináptica (L_2 weight decay) que elude la memorización destructiva de ruido sin requerir re-entrenamientos sucesivos.
6. **Garantía Metodológica Contra Fuga de Información (*Data Leakage*):** Se demostró que computar la media y desviación estándar de estandarización z -score exclusivamente sobre la partición de entrenamiento no solo preserva la validez estadística, sino que conditioned los potenciales netos en la región de máxima conductividad de gradiente de la sigmoide ($\sigma'(0) = 0,25$), suprimiendo la saturación temprana de los pesos sinápticos.

7. Referencias

- [1] F. Rosenblatt, “The Perceptron: A probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958. doi:10.1037/h0042519
- [2] B. Widrow and M. E. Hoff, “Adaptive switching circuits,” in *IRE WESCON Convention Record*, part 4, pp. 96–104, 1960.
- [3] M. L. Minsky and S. A. Papert, *Perceptrons: An Introduction to Computational Geometry*, Cambridge, MA, USA: MIT Press, 1969.
- [4] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986. doi:10.1038/323533a0
- [5] G. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of Control, Signals, and Systems*, vol. 2, no. 4, pp. 303–314, 1989. doi:10.1007/BF02551274
- [6] K. Hornik, “Approximation capabilities of multilayer feedforward networks,” *Neural Networks*, vol. 4, no. 2, pp. 251–257, 1991. doi:10.1016/0893-6080(91)90009-T
- [7] N. Qian, “On the momentum term in gradient descent learning algorithms,” *Neural Networks*, vol. 12, no. 1, pp. 145–151, 1999. doi:10.1016/S0893-6080(98)00116-6
- [8] S. Ruder, “An overview of gradient descent optimization algorithms,” *arXiv preprint arXiv:1609.04747*, 2016. arXiv:1609.04747
- [9] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Upper Saddle River, NJ, USA: Pearson Prentice Hall, 2009.
- [10] C. M. Bishop, *Pattern Recognition and Machine Learning*, New York, NY, USA: Springer, 2006.
- [11] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, Cambridge, MA, USA: MIT Press, 2016.
- [12] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [13] D. Dua and C. Graff, “UCI Machine Learning Repository,” School of Information and Computer Science, University of California, Irvine, CA, 2017. <http://archive.ics.uci.edu/ml>