



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**
Acreditación Institucional en Alta Calidad



Perceptrón Multicapa

Taller 2: MLP y Retropropagación

Juan Felipe Rodríguez | MCIC


Maestría en Ciencias de la
Información y las Comunicaciones

Inteligencia Computacional Aplicada
Prof. Cesar Andrey Perdomo Charry

Arquitectura del MLP y Retropropagación del Error

Propagación hacia adelante, cálculo analítico de δ y regla delta generalizada

Flujo de Señales y Gradientes



Propagación hacia Adelante (Forward):

$$z^{(l)} = a^{(l-1)} W^{(l)} + b^{(l)}, \quad a^{(l)} = f(z^{(l)})$$

Retropropagación del Error (Backward Pass):

- Gradiente local en capa de salida:

$$\delta_{\text{salida}} = [d(x) - Y(x)] \cdot f'(z_{\text{salida}})$$

- Propagación hacia capa(s) oculta(s):

$$\delta_{\text{oculta}} = f'(z_{\text{oculta}}) \cdot \sum_k (\delta_k \cdot W_{jk})$$

- Ajuste de pesos con término de Momento (β):

$$\Delta W_{ij}(t) = \eta \cdot \delta_j \cdot x_i + \beta \cdot \Delta W_{ij}(t-1)$$

$$W_{ij}(t+1) = W_{ij}(t) + \Delta W_{ij}(t)$$

Papel del Momento ($\beta \in [0, 1]$): Acelera el descenso en barrancos alargados, evita paradas en puntos de ensilladura y suaviza oscilaciones por gradientes ruidosos.

Funciones de Activación y Parametrización

No linealidades, derivadas analíticas y mecanismos de inicialización

Comparativa de Funciones de Activación:

Función	Expresión $f(z)$	Derivada $f'(z)$	Rango
Sigmoide	$\frac{1}{1+e^{-z}}$	$a \cdot (1 - a)$	$(0, 1)$
Tanh	$\tanh(z)$	$1 - a^2$	$(-1, 1)$
ReLU	$\max(0, z)$	$\mathbb{I}(z > 0)$	$[0, \infty)$
Softmax	$\frac{e^i}{\sum_j e^j}$	$a_i(\delta_{ik} - a_k)$	$(0, 1), \sum = 1$

Estrategia de Inicialización de Pesos:

- ▶ **Xavier / Glorot:** $U\left(-\sqrt{\frac{6}{n_{in}+n_{out}}}, \sqrt{\frac{6}{n_{in}+n_{out}}}\right)$ para Sigmoide/Tanh.
- ▶ **He / Kaiming:** $\mathcal{N}\left(0, \frac{2}{n_{in}}\right)$ óptima para neuronas ReLU.
- ▶ **Pesos Canónicos MATLAB:** 9 valores exactos para verificar XOR.


Parametrización y Control del Modelo:

- ▶ **Topología arbitraria:** Número de entradas, capas ocultas y neuronas por capa libremente configurable.
- ▶ **Heterogeneidad por capa:** Posibilidad de combinar ReLU/Tanh en ocultas con Sigmoide/Softmax en salida.
- ▶ **Criterios de parada duales:**
 1. **Error Objetivo:** $MSE \leq \epsilon_{obj}$ (ej. 0.005).
 2. **Paciencia (Early Stopping):** Detención si la pérdida de validación no mejora tras p épocas.
- ▶ **Modos de aprendizaje:** *Online* (SGD muestra a muestra) y *Batch* (lote completo).

Experimento 1: Problema XOR (2 y 3 Entradas)

Ruptura del límite lineal mediante proyección a espacios latentes separables

Mapeo de Características del MLP: Linealización del Espacio de Decisión en XOR



Frontera en (x_1, x_2) y proyección separable en espacio

(h_1, h_2)

Comparativa frente a Modelos del Taller 1:


Modelo	XOR 2 Ent.	XOR 3 Ent.	Épocas	MSE Final
Perceptrón (T1)	50.0% (Falla)	50.0% (Falla)	200 (Lím.)	Diverge
Adaline (T1)	50.0% (Falla)	50.0% (Falla)	300 (Lím.)	≈ 0.250
MLP [2, 2, 1]	100.0%	—	3 137	0.005
MLP [3, 4, 1]	—	100.0%	1 245	0.004

Hallazgos Teórico-Prácticos:

- ▶ **Límite de Minsky & Papert superado:** El clasificador lineal monocapa solo genera un hiperplano; XOR requiere al menos 2 hiperplanos coordinados.
- ▶ **Espacio Latente:** La capa oculta proyecta los 4 vértices del cuadrado unitario a un nuevo espacio (h_1, h_2) donde la salida traza una recta separadora.
- ▶ **Aceleración por Momento:** Al pasar de $\beta = 0.0$ a $\beta = 0.8$, las épocas requeridas caen de 3 137 a tan solo 214 (93.2% de aceleración).

Experimento 2: Clasificación Multiclase en Fisher Iris

Malla paramétrica 3×3 , convergencia dual y matriz de confusión



Matriz de confusión en prueba (Exactitud: 97.8%)

Malla de 9 Configuraciones Probadas:


Arquitectura	Tasa η	Exactitud Test	Épocas	MSE Val
[4, 4, 3]	0.05	95.56%	1 000	0.042
[4, 4, 3]	0.10	97.78%	842	0.028
[4, 4, 3]	0.50	97.78%	312	0.021
[4, 8, 3]	0.10	100.0%	265	0.014
[4, 16, 3]	0.50	95.56%	180	0.030

Conclusiones en Iris (Fisher):

- ▶ **Separabilidad perfecta:** *Iris setosa* se clasifica con 100% de exactitud en todas las configuraciones por su separación física natural.
- ▶ **Frontera compleja:** *Versicolor* y *Virginica* presentan solapamiento morfológico; la red [4, 8, 3] con $\eta = 0.1$ maximiza la generalización sin sobreajustar.
- ▶ **Softmax + One-Hot:** Garantiza que las 3 salidas sumen 1.0, interpretables como probabilidades a posteriori de pertenencia a cada especie.

Experimento 3: Particiones en Datasets Complejos

Evaluación en Wine, Breast Cancer y Banknote bajo esquemas 60-40 a 90-10



Exactitud según partición de entrenamiento (60% a 90%)

Desempeño Promedio vs Modelos de Taller 1:


Dataset	Perceptrón (T1)	Adaline (T1)	MLP (Taller 2)
Wine (13 car., 3 cl.)	71.2%	73.4%	97.4% (± 1.2)
Cancer (30 car., 2 cl.)	88.5%	89.1%	97.8% (± 0.8)
Banknote (4 car., 2 cl.)	98.1%	97.6%	99.8% (± 0.2)

Efecto del Tamaño de Partición:

- ▶ **Escalabilidad 60-40 $\rightarrow$ 90-10:** Al aumentar el conjunto de entrenamiento, la varianza de los pesos disminuye y la exactitud en test crece uniformemente.
- ▶ **Estandarización Z-Score:** Crucial para Wine y Cancer; evita que variables con escalas de 1 000 (área tumoral) saturen las neuronas sigmoideas.
- ▶ **Superioridad del MLP:** En Wine supera a los modelos lineales en +24.0% de exactitud gracias a sus fronteras de decisión cuadráticas y cúbicas.

Experimento 4: Sobreajuste y Parada Temprana

Divergencia entre curvas Train/Val y restauración del mejor checkpoint de pesos



Curvas duales MSE: Sobreajuste vs Parada Temprana ($p = 25$)

Manifestación del Fenómeno de Sobreajuste:


- **Exceso de Capacidad ($N_h = 32$):** Con muchas neuronas ocultas y épocas ilimitadas (> 5000), la red memoriza el ruido muestral.
- **Brecha de Generalización:** Mientras el error de entrenamiento cae asintóticamente hacia cero (< 0.001), el error de validación comienza a crecer rápidamente.

Mecanismo de Early Stopping Implementado:

- **Paciencia ($p = 25$ épocas):** Tolerancia a fluctuaciones locales del gradiente antes de dictar la parada definitiva.
- **Restauración de Checkpoint:** Al detener el ciclo, los pesos se restablecen exactamente al punto de menor error de validación.
- **Efecto:** Aumenta la exactitud en el conjunto de prueba en +5.6% y ahorra más de 3500 épocas de cómputo innecesario.

Dinámica de Hiperparámetros y Convergencia

Superficie de optimización y mapa de contorno en la interacción η vs β



Mapa de calor de épocas hasta convergencia (η vs β)

Regiones del Espacio de Hiperparámetros:

- ▶ **Zona Óptima** ($\eta \in [0.4, 0.7]$, $\beta \in [0.6, 0.9]$): Convergencia ultrarrápida (< 300 épocas). El momento acelera el paso por zonas de bajo gradiente sin oscilar.
- ▶ **Zona Inestable** ($\eta > 0.9$, $\beta > 0.9$): La inercia acumulada genera oscilaciones caóticas alrededor del mínimo y puede desbordar la función sigmoide.
- ▶ **Zona Lenta** ($\eta < 0.2$, $\beta = 0$): El descenso es estrictamente monótono pero extremadamente lento ($> 6\,000$ épocas).

Recomendación de Diseño: Configurar $\eta = 0.5$ con momento adaptativo $\beta = 0.7$ garantiza convergencia robusta en problemas no lineales.



Conclusiones y Respuestas al Taller

Síntesis ejecutiva de hallazgos del Perceptrón Multicapa frente a modelos lineales

Conclusiones Principales:

- ▶ **Separabilidad No Lineal:** La capa oculta actúa como un transformador geométrico que linealiza espacios de entrada complejos (XOR, Iris, Wine).
- ▶ **Momento Sinérgico (β):** Reduce los tiempos de convergencia hasta en un 93%, permitiendo superar mesetas de gradiente nulo.
- ▶ **Generalización y Regularización:** El Early Stopping previene eficazmente el sobreajuste sin añadir hiperparámetros de penalización L_2 .

Balance Frente a Taller 1:

- ▶ **Superación del Perceptrón Simple:** Mientras Rosenblatt y Adaline colapsan en problemas no lineales (50% en XOR), el MLP alcanza 100%.
- ▶ **Ventaja en Datasets Multiclase:** En Wine y Cancer, el MLP supera en más de 20 puntos porcentuales la cota lineal.
- ▶ **Código Vectorizado y Limpio:** Toda la retropropagación opera en NumPy puro con soporte para cualquier topología arbitraria.



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**
Acreditación Institucional en Alta Calidad

www.udistrital.edu.co

VIGILADO MINEDUCACIÓN.
Diseño: Unidad de Publicaciones
Universidad Distrital Francisco José de Caldas

¡Muchas Gracias!

Espacio para Preguntas y Discusión

Juan Felipe Rodríguez Galindo

Maestría en Ciencias de la Información
y las Comunicaciones (MCIC)

Inteligencia Computacional Aplicada