



UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
MAESTRÍA EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES



Perceptrón Multicapa (MLP) y Retropropagación del Error

Taller 2: Fundamentos Analíticos, Aceleración Inercial β , Espacios Latentes y Regularización Espectral

Asignatura: Inteligencia Computacional Aplicada | **Docente:** Ph.D. Cesar Andrey Perdomo Charry

Estudiante: Juan Felipe Rodríguez Galindo | **Código:** 20261595004

Entregable Oficial: Presentación Ejecutiva y Defensa Técnica • Bogotá D.C., Septiembre 2026

Ruptura de la Barrera de Minsky-Papert y No-Linealidad

La Limitación Monocapa en XOR

- **Geometría Hiperplana:** Tanto el Perceptrón Simple como Adaline generan exclusivamente fronteras lineales: $w_1x_1 + w_2x_2 + b = 0$ en $\mathbb{R}^2$.
- **El Problema XOR:** Las clases $\{(0,1), (1,0)\}$ y $\{(0,0), (1,1)\}$ poseen correlación lineal nula ($\rho = 0$). Imposible de escindir con un solo hiperplano.
- **Colapso Cuantitativo:** El Perceptrón monocapa oscila indefinidamente sin converger, estancándose en exactitud $\leq 50.0\%$ (equivalente al azar).
- **El Invierno de la IA:** Minsky y Papert (1969) conjeturaron falsamente que extender redes a multicapas sería computacionalmente inviable o estéril.

Representación Latente y No-Linealidad

- **Mapeo a Espacio Latente:** Las capas ocultas actúan como proyectores no lineales $\Phi: \mathbb{R}^n \rightarrow [0, 1]^m$. Deforman el espacio tornando las clases linealmente separables.
- **Aproximación Universal:** Teorema de Cybenko (1989) y Hornik (1991): una capa oculta no lineal continua aproxima cualquier función boreliana acotada.
- **Activaciones Sigmoideas:** El uso de funciones suaves continuas y diferenciables (σ , $\tanh$) permite el cálculo exacto de gradientes analíticos.
- **Retropropagación (1986):** Rumelhart, Hinton y Williams formalizan el flujo inverso del gradiente mediante regla de la cadena, destrabando la IA moderna.

Arquitectura del MLP y Retropropagación con Momento

1. Forward Pass

- **Activación Afín:** Combinación lineal de entradas y sesgo:

$$z_{-j} = \sum w_{-ji} a_{-i} + b_{-j}$$

- **Sigmoide Logística:** Mapeo probabilístico no lineal:

$$a_{-j} = \sigma(z_{-j}) = 1 / (1 + e^{-(z_{-j})})$$

- **Derivada Elegante:** Cálculo computacional ultra eficiente:

$$\sigma'(z_{-j}) = a_{-j} (1 - a_{-j})$$

- **Costo Global (MSE):** Superficie de pérdida diferenciable:

$$E = \frac{1}{2} \sum_k (y_{-k} - t_{-k})^2$$

2. Retropropagación

- **Regla de la Cadena:** Descomposición analítica exacta:

$$\partial E / \partial w_{-kj} = \delta_{-k} \cdot a_{-j}$$

- **Gradiente en Salida:** Sensibilidad del nodo de salida:

$$\delta_{-k} = (y_{-k} - t_{-k}) \cdot y_{-k} (1 - y_{-k})$$

- **Retroceso a Ocultas:** Propagación hacia atrás del error:

$$\delta_{-j} = [\sum_k w_{-kj} \delta_{-k}] \cdot a_{-j} (1 - a_{-j})$$

- **Complejidad $O(N)$:** Cálculo en tiempo lineal respecto al número de sinapsis de la red.

3. Momento Inercial β

- **Regla Delta Generalizada:** $\Delta W^\wedge(t) = -\eta \nabla E + \beta \Delta W^\wedge(t-1)$, incorporando memoria histórica inercial.

- **Dinámica Hamiltoniana:** Análogo a partícula clásica con masa en potencial gravitatorio con fricción viscosa.

- **Filtro Pasa-Bajos:** Amortigua oscilaciones ortogonales de alta frecuencia en valles escarpados.

- **Evasión de Mesetas:** Acelera a lo largo de crestas con gradiente tenue, evitando estancamiento en saturación.

Validación Canónica XOR y Aceleración Inercial β

Superficie 3D: Épocas de Convergencia vs (η, β) para XOR




Figura: Superficie de épocas de convergencia en el plano (η, β) para XOR.

Resultados Cuantitativos en XOR

- **Convergencia Absoluta:** 100.0% de exactitud en XOR-2 y XOR-3 (paridad de 3 bits), frente al colapso del Perceptrón monocapa (50.0%).
- **Aceleración del 87.4%:** Con $\beta = 0.9$ frente a $\beta = 0.0$, las épocas requeridas caen drásticamente de 621 a 78 épocas (reducción masiva).
- **Óptimo Global Localizado:** Punto mínimo alcanzado en $\eta = 0.50$ y $\beta = 0.90$ con MSE final $< 10^{-4}$ en tan solo 78 épocas.
- **Estabilidad Numérica:** Para $\eta > 1.2$ sin momento se observa inestabilidad oscilatoria; β actúa como amortiguador inercial.

✓ **SÍNTESIS XOR:** El momento inercial β provee casi un orden de magnitud de aceleración computacional conservando la fidelidad analítica.

Demostración Geométrica en el Espacio Latente

Mapeo de Características del MLP: Linealización del Espacio de Decisión en XOR




Figura: Frontera no lineal en $\mathbb{R}^2$ (izq.) vs. Desdoblamiento lineal en espacio latente $\mathcal{H}$ (der.).

El Mecanismo de Desenredo

- Proyección Phi:** La capa oculta $[h_1, h_2]$ mapea los vértices $\{0,1\}^2$ a $[0,1]^2$.
- Colapso Topológico:** $(0,0)$ y $(1,1)$ se proyectan en regiones contiguas; $(0,1)$ y $(1,0)$ quedan agrupados.
- Separabilidad Lineal:** En $\mathcal{H}$, un único hiperplano lineal separa perfectamente ambas clases.
- Resolución de Paradoja:** Lo no lineal en $\mathbb{R}^2$ se convierte en trivialmente lineal en el espacio latente.

★ **CLAVE TEÓRICA:** Las capas intermedias no clasifican; aprenden representaciones donde el problema es separable.

Clasificación Multiclase: Benchmark Fisher's Iris

Matriz de Confusión - Mejor Modelo Iris (CONF-08: [4, 8, 4, 3], $\eta = 0.10$)

Exactitud de Prueba: 93.33% | F1-Score Macro: 0.9327




Figura: Curvas de convergencia y matriz de confusión en test para modelo CONF-08.

Modelo Óptimo CONF-08

- **Topología:** Red profunda [4, 8, 4, 3] con salida One-Hot multiclase.
- **Exactitud en Test:** 93.33% de exactitud global independiente.
- **F1-Score Macro:** 0.9327 reflejando equilibrio perfecto entre clases.
- **Setosa:** 100.0% de precisión y recall (separabilidad lineal total).
- **Versicolor / Virginica:** Frontera curva que desarticula el solapamiento morfológico.

DESGLOSE DE ACIERTO EN TEST (N=45):

- Setosa: 15/15 (100%) • Versicolor: 15/15 (100%)
- Virginica: 12/15 (80%) por traslape morfológico

Generalización Multivariable y Resiliencia a Particiones

Comparativa Multidimensional del Desempeño Generalizador (Test Accuracy)
Evolución en Función de la Partición Train-Test para los Tres Datasets




Figura: Exactitud en test a través de 4 particiones estratificadas (60-40 a 90-10).

Rendimiento por Dataset

- **Banknote:** 100.0% de exactitud (80-20). Clasificación perfecta de billetes auténticos vs. falsos.
- **Breast Cancer:** 98.25% exactitud ($F_1 = 0.9859$). Mínimo clínico de falsos negativos en diagnóstico.
- **Wine:** 100.0% exactitud (80-20) en clasificación de cepas químicas complejas.
- **Cero Fuga (Leakage):** Estandarización z-score calculada únicamente sobre entrenamiento en cada split.

✓ **RESILIENCIA:** Desempeño invariante ante el tamaño del test set, superando en +14.2% de F_1 a los clasificadores monocapa del Taller 1.

Patología del Sobreajuste y Divergencia de Varianza




Figura: Curvas de pérdida en red sobreparametrizada (4097 parámetros libres).

Las 4 Fases Temporales

- **Fase I: Subajuste:** Épocas 1–25: Alto sesgo, descenso paralelo de E_{train} y E_{val} .
- **Fase II: Óptimo:** Épocas 25–45: Mínimo de validación global. Compromiso sesgo-varianza ideal.
- **Fase III: Desacople:** Épocas 45–100: Estancamiento de E_{val} mientras E_{train} continúa decreciendo.
- **Fase IV: Memorización:** Épocas 100–1000: $E_{\text{train}} \rightarrow 0$ mientras E_{val} asciende patológicamente por varianza.
- **Ratio Parámetros:** 14.43 parámetros por muestra: memorización pura de ruido estocástico.

Regularización Espectral Mediante Early Stopping




Figura: Comparativa de errores y brecha de generalización: Sin Regularizar vs. Early Stopping.

Impacto Cuantitativo Medido

- **-16.65% en E_{test} :** El error cuadrático en prueba descende de 0.0435 a 0.0362 al restaurar el checkpoint óptimo.
- **-37.23% en Brecha:** La discrepancia de generalización $|E_{val} - E_{train}|$ se comprime de 0.0401 a 0.0252.
- **95.73% de Ahorro:** Entrenamiento detenido en época 43 en lugar de 1000: economía computacional y energética radical.
- **Equivalencia L_2 :** Actúa como decaimiento de peso implícito (weight decay), acotando la norma $\|W\|_2$ sin costo adicional.

Comparativa Multidimensional y Directrices de Ingeniería

Criterio	Perceptrón Simple (1958)	Adaline (1960)	MLP con Backprop (1986)
Capacidad de Frontera	Hiperplano lineal en $\mathbb{R}^n$	Hiperplano lineal en $\mathbb{R}^n$	Hipersuperficie no lineal continua
Función Activación	Escalón Heaviside (discontinua)	Identidad lineal $f(z) = z$	Sigmoide / Tanh (diferenciable)
Regla de Aprendizaje	Regla Perceptrón: $\Delta w = \eta(t-y)x$	Gradiente LMS: $\Delta w = \eta(t-z)x$	Delta Generalizada + Inercia β
Convergencia XOR	Fracaso (Exactitud = 50.0%)	Fracaso (Exactitud = 50.0%)	Convergencia Perfecta (100.0%)

Directrices Prácticas de Ingeniería Neuronal

- 1. **Normalización Rigurosa:** Estandarizar siempre z-score derivado exclusivamente del train set para evitar fugas de información.
- 2. **Inicialización Simétrica:** Pesos pequeños aleatorios $w \sim U(-r, r)$ o Xavier/Glorot para eludir saturación prematura de gradiente.
- 3. **Momento Inercial $\beta \in [0.7, 0.9]$:** Imprescindible para acelerar convergencia y atravesar cañones escarpados sin oscilación.
- 4. **Parada Temprana (Paciencia):** Monitorear E_{val} para restaurar checkpoint óptimo y evitar sobre costo de sobreajuste.

Conclusiones y Aportes del Taller 2

1. Superación de la Barrera Lineal

- **Desenredo Geométrico:** Las capas ocultas desdoblan variedades no separables, logrando 100% en XOR frente al 50% monocapa.
- **Aproximación Universal:** Se valida que neuronas sigmoideas intermedias aproximan cualquier frontera continua arbitraria.

2. Aceleración Inercial β

- **87.4% Más Rápido:** $\beta = 0.9$ reduce las épocas de 621 a 78 y suprime oscilaciones transversales en cañones estrechos.
- **Inercia Dinámica:** Actúa como filtro pasa-bajos que acumula velocidad en la dirección del gradiente persistente.

3. Resiliencia en Problemas Reales

- **Benchmarks Reales:** 100% en Banknote y Wine, 98.25% en Breast Cancer y 93.33% en Iris con estabilidad ante 4 particiones.
- **Generalización:** Previene data leakage mediante normalización z-score estricta dentro de cada partición de treino.

4. Regularización por Early Stopping

- **Control Espectral:** -16.65% en E_{test} , -37.23% en brecha de generalización y 95.73% de ahorro en épocas.
- **Equivalencia L_2 :** Funciona como penalización implícita de pesos, restringiendo el radio espectral sin hiperparámetros extra.