



UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS • MAESTRÍA EN CIENCIAS DE LA INFORMACIÓN

Perceptrón Multicapa (MLP) y Retropropagación del Error

Taller 2: Fundamentos Analíticos, Aceleración Inercial β , Espacios Latentes y Regularización Espectral

Asignatura: Inteligencia Computacional Aplicada | **Docente:** Ph.D. Cesar Andrey Perdomo Charry

Estudiante: Juan Felipe Rodríguez Galindo | **Código:** 20261595004

Entregable Oficial: Presentación Ejecutiva y Defensa Técnica • Bogotá D.C., Septiembre 2026

Ruptura de Minsky-Papert: Separabilidad con Capa Oculta

01. FUNDAMENTO HISTÓRICO

50.0% Exactitud

COLAPSO MONOCAPA (1958-1969)

- **Barrera Lineal:** Perceptrón y Adaline solo generan hiperplanos $w_1x_1 + w_2x_2 + b = 0$. Incapaces de separar XOR ($p = 0$).
- **Oscilación Permanente:** Sin convergencia; el algoritmo conmuta indefinidamente sin converger (azar puro).
- **Invierno de la IA:** Minsky & Papert (1969) conjeturaron falsamente la inviabilidad de redes multicapa.

100.0% Exactitud

SOLUCIÓN MULTICAPA (1986-PRESENTE)

- **Espacio Latente Φ :** Las neuronas ocultas proyectan $\mathbb{R}^2$ a un espacio intermedio donde las clases se tornan linealmente separables.
- **Aproximación Universal:** Cybenko (1989) demostró que 1 capa oculta no lineal continua aproxima cualquier función boreliana.
- **Backpropagation (1986):** Rumelhart, Hinton y Williams formalizan el flujo del gradiente analítico exacto vía regla de la cadena.

★ PRINCIPIO REVOLUCIONARIO DEL ESPACIO LATENTE

La capa intermedia NO toma la decisión de negocio; su función es deformar topológicamente la variedad de entrada para que la capa de salida resuelva el problema con un hiperplano trivial.

Formulación MLP: Regla de la Cadena y Aceleración Inercial β

02. FORMULACIÓN MATEMÁTICA

$$\sigma(z) \in [0, 1]$$

PROPAGACIÓN HACIA ADELANTE

Forward Pass Diferenciable

- **Combinación Afín:** $z_{-j} = \sum w_{-ji} a_{-i} + b_{-j}$ proyecta las activaciones precedentes de forma matricial.
- **Sigmoide Logística:** $a_{-j} = 1 / (1 + e^{-(z_{-j})})$ aporta no-linealidad suave con derivada $\sigma'(z) = a(1 - a)$.
- **Costo Cuadrático (MSE):** $E = \frac{1}{2} \sum_k (y_{-k} - t_{-k})^2$ define una superficie de error continua y diferenciable.

$$O(N) \text{ Lineal}$$

RETROPROPAGACIÓN DEL ERROR

Backward Pass Exacto

- **Gradiente en Salida:** $\delta_{-k} = (y_{-k} - t_{-k}) \cdot y_{-k}(1 - y_{-k})$ mide la discrepancia respecto al objetivo.
- **Retroceso a Ocultas:** $\delta_{-j} = [\sum_k w_{-kj} \delta_{-k}] \cdot a_{-j}(1 - a_{-j})$ transmite la responsabilidad a capas previas.
- **Regla de la Cadena:** $\partial E / \partial w_{-kj} = \delta_{-k} \cdot a_{-j}$ permite calcular gradientes exactos en tiempo lineal $O(\text{sinapsis})$.

$$+\beta \Delta W(t-1)$$

ACELERACIÓN INERCIAL

Filtro Pasa-Bajos Dinámico

- **Delta Generalizada:** $\Delta W^{\wedge}(t) = -\eta \nabla E + \beta \Delta W^{\wedge}(t-1)$ incorpora memoria inercial del paso anterior.
- **Filtro de Ruido:** Cancela oscilaciones ortogonales en cañones estrechos promediando gradientes.
- **Garantía de Estabilidad:** El factor β en $[0.7, 0.9]$ previene divergencias explosivas cuando η es elevado.

Validación XOR: 100% de Acierto y Aceleración del 87.4% con β

03. EXPERIMENTACIÓN CANÓNICA

Superficie 3D: Épocas de Convergencia vs (η, β) para XOR




Figura: Superficie empírica de épocas de convergencia en función de tasa η y momento β .

87.4%

ACELERACIÓN CON MOMENTO

De 621 ($\beta=0.0$) a 78 épocas ($\beta=0.9$)

100.0%

EXACTITUD XOR-2 Y XOR-3

Convergencia global sin estancamiento

- **Óptimo Global:** $\eta = 0.50$ y $\beta = 0.90$ minimizan las épocas con $MSE \text{ final} < 10^{-4}$.
- **Estabilidad Numérica:** Para $\eta > 1.2$ sin momento hay oscilaciones; β estabiliza la trayectoria.

✓ El momento inercial β provee casi 1 orden de magnitud de ahorro computacional.

Espacio Latente: Desenredo Topológico de Variedades No Lineales

04. INTERPRETACIÓN GEOMÉTRICA

Mapeo de Características del MLP: Linealización del Espacio de Decisión en XOR




Figura: Frontera no lineal en espacio de entrada $\mathbb{R}^2$ vs. Desdoblamiento lineal en espacio latente $\mathcal{H}$.

$$\Phi: \mathbb{R}^2 \rightarrow [0, 1]^2$$

PROYECCIÓN LATENTE
Deformación Continua

- **Colapso Coordinado:** (0,0) y (1,1) se proyectan agrupados; (0,1) y (1,0) quedan en el extremo opuesto.
- **Separación Trivial:** En el espacio latente $\mathcal{H}$, una recta $w_{h1} h_1 + w_{h2} h_2 + b = 0$ clasifica al 100%.
- **Resolución Teórica:** Lo no lineal en $\mathbb{R}^2$ se torna elementalmente lineal tras la transformación oculta.

★ Las capas ocultas aprenden representaciones donde el problema es separable.

Fisher's Iris: 93.3% de Exactitud y Desarticulación de Solapamiento

05. GENERALIZACIÓN MULTICLASE

Matriz de Confusión - Mejor Modelo Iris (CONF-08: [4, 8, 4, 3], $\eta = 0.10$)

Exactitud de Prueba: 93.33% | F1-Score Macro: 0.9327




Figura: Matriz de confusión en conjunto de prueba independiente (N=45) para CONF-08.

93.33%

EXACTITUD EN TEST

F1-Score Macro: 0.9327

100.0%

SETOSA & VERSICOLOR

15/15 aciertos exactos por clase

- **Topología:** Red profunda [4, 8, 4, 3] con One-Hot y $\eta = 0.10$.
- **Virginica:** 12/15 aciertos (80%); 3 errores explicados por traslape morfológico real.

✓ Las fronteras curvas del MLP desarticulan el solapamiento que colapsaba a los clasificadores lineales.

Robustez Empírica: Desempeño Resiliente en 4 Datasets Reales

06. ROBUSTEZ Y BENCHMARKS REALES

Comparativa Multidimensional del Desempeño Generalizador (Test Accuracy)
Evolución en Función de la Partición Train-Test para los Tres Datasets




Figura: Exactitud de generalización a través de 4 particiones estratificadas (60-40 a 90-10).

100.0%

BANKNOTE & WINE
Partición canónica 80-20

98.25%

BREAST CANCER
 $F_1 = 0.9859$ (Mínimo falso negativo)

- **Cero Data Leakage:** Normalización z-score calculada únicamente sobre entrenamiento en cada split.
- **Invarianza de Split:** Las oscilaciones entre splits 60-40 y 90-10 no superan el 1.5% de varianza.

★ El MLP supera en +14.2% de F_1 -Score a los clasificadores monocapa del Taller 1.

Sobreajuste: Desacople de Varianza y Memorización de Ruido

07. ANÁLISIS DE COMPLEJIDAD




Figura: Dinámica de error en red sobreparametrizada [30, 64, 32, 1] (4097 parámetros vs 284 muestras).

DINÁMICA DE 4 FASES

Fase I: Subajuste

Épocas 1-25: Alto sesgo, descenso paralelo de E_{train} y E_{val} .

Fase II: Óptimo Global

Épocas 25-45: Mínimo de validación ($E_{\text{val}}^* = 0.0127$ en ép. 24).

Fase III: Desacople

Épocas 45-100: Estancamiento de E_{val} mientras E_{train} decrece.

Fase IV: Memorización

Épocas 100-1000: $E_{\text{train}} \rightarrow 0$ y E_{val} asciende patológicamente.

Ratio: 14.4 parámetros por muestra → memorización espuria de ruido estocástico.

Early Stopping: -16.7% en Error de Prueba y 95.7% de Ahorro

08. MECANISMO DE CONTROL




Figura: Comparativa de error de test y brecha de generalización: Sin Regularizar vs. Con Early Stopping.

-16.65%

REDUCCIÓN DE ERROR EN TEST
0.0435 $\rightarrow$ 0.0362 (checkpoint óptimo)

-37.23%

COMPRESIÓN DE BRECHA
 $|E_{val} - E_{train}|$: 0.0401 $\rightarrow$ 0.0252

95.73%

AHORRO COMPUTACIONAL
Parada en época 43 en vez de 1000

★ EQUIVALENCIA L_2 (WEIGHT DECAY)

La parada temprana actúa matemáticamente como una penalización espectral de norma $\|W\|_2$, restringiendo el espacio de hipótesis sin costo computacional adicional.

Evolución Paradigmática: Del Perceptrón Monocapa al MLP

09. SÍNTESIS PARADIGMÁTICA

Criterio	Perceptrón Simple (1958)	Adaline (1960)	MLP con Backprop (1986)
Capacidad de Frontera	Hiperplano lineal en $\mathbb{R}^n$	Hiperplano lineal en $\mathbb{R}^n$	Hipersuperficie no lineal continua
Función Activación	Escalón Heaviside (discontinua)	Identidad lineal $f(z) = z$	Sigmoide / Tanh suave (diferenciable)
Regla de Aprendizaje	Regla Perceptrón: $\Delta w = \eta(t-y)x$	Gradiente LMS: $\Delta w = \eta(t-z)x$	Delta Generalizada + Momento β
Desempeño XOR	Fracaso (Exactitud = 50.0%)	Fracaso (Exactitud = 50.0%)	Convergencia Perfecta (100.0%)

1. Estandarización

Normalización z-score estricta ajustada solo en train.

2. Inicialización

Pesos pequeños aleatorios o Xavier/Glorot.

3. Momento Inercial

β en $[0.7, 0.9]$ para cruzar cañones sin oscilar.

4. Early Stopping

Paciencia $P=40$ para congelar en el óptimo.

Conclusiones: Principios Rectores del Perceptrón Multicapa

10. CONCLUSIONES EJECUTIVAS

1. Superación de la Barrera Lineal

100% XOR

Las capas ocultas actúan como proyectores no lineales que deforman variedades complejas, resolviendo la conjetura de Minsky & Papert.

2. Aceleración Inercial con Momento

87.4% MÁS VELOZ

El factor $\beta = 0.9$ amortigua vibraciones transversales en cañones estrechos, reduciendo de 621 a 78 épocas y evitando mesetas planas.

3. Robustez en Benchmarks Reales

100% SPLITS

Exactitud perfecta en Banknote y Wine, y 98.25% en Breast Cancer con estabilidad invariable ante 4 particiones estratificadas.

4. Control Espectral por Early Stopping

-16.7% TEST

La parada temprana restaura el punto óptimo de sesgo-varianza, recortando un 37.2% la brecha de generalización y ahorrando 95.7% de cómputo.