

UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional en Alta Calidad

Redes convolucionales sobre KMNIST

Taller 3: aprendizaje profundo

Juan Felipe Rodríguez Galindo
20261595004
Maestría en Ciencias de la Información y las Comunicaciones
Inteligencia Computacional Aplicada



Qué se pidió y qué se hizo

Mismo flujo del cuaderno del docente, con otro conjunto de datos

Núcleo (TODO 1 a 5)

Conteo por clase, `CNNPropia` ($< 200\,000$ parám.), bucle de entrenamiento, evaluación y par más confundido, aumento de datos. Todas las verificaciones en `[OK]`.

Extras

5 semillas con comparación pareada, ablación y profundidad, líneas base (MLP y CNN del docente), KMNIST vs MNIST vs FashionMNIST, barrido de η, filtros y mapas.

Hallazgo central

En KMNIST la prueba es más difícil que la validación (5,5 pts). El aumento de datos **no** mejoró la exactitud; un tercer bloque sí (2,11 pts).

KMNIST
60 000 + 10 000

→

CNNPropia
20 586 parám.

→

Adam
$\eta = 10^{-3}$,
5 ép.

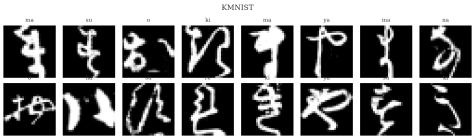
→

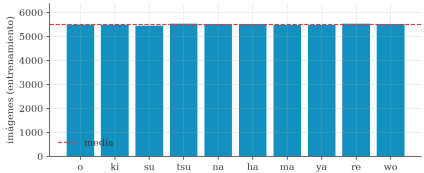
91,85 %
en prueba



Datos y protocolo

KMNIST: hiragana cursivo (*kuzushiji*), 10 clases, 28×28





Partición

55 000 entrenamiento / 5 000 validación / 10 000 prueba. Normalización con μ y σ **solo del entrenamiento**. Clases balanceadas (razón máx/mín 1,015).

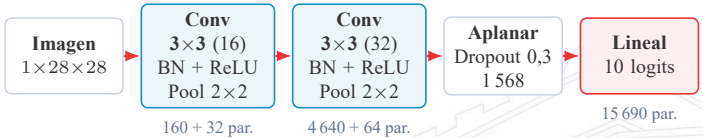
Comparaciones pareadas

El `DataLoader` del cuaderno base comparte un generador entre corridas: "la misma semilla" no repetía el orden de lotes. Aquí hay un cargador por corrida y 3 a 5 semillas.



CNNPropia: 20 586 parámetros

Dos bloques Conv--BN--ReLU--Pool, Dropout y capa lineal



Qué se esperaba de cada pieza

Conv: rasgos locales con pesos compartidos. **BN**: entrenar más estable. **Pool**: tolerar desplazamientos. **Dropout**: regularizar la capa final (76 % de los parámetros).

Qué se midió (ablación)

Dropout **sí** aporta. BN **no** mejoró la exactitud a 5 épocas, pero sí la estabilidad: con $\eta = 0{,}1$, 82,46 % con BN y 9,76 % sin ella. Un tercer bloque: 2,11 pts en prueba.

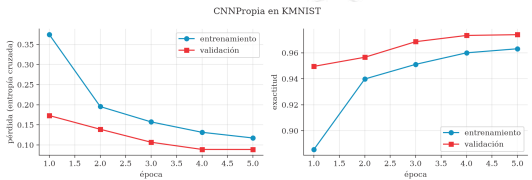


Entrenamiento: los cinco pasos

Adam, $\eta = 10^{-3}$, lotes de 64, 5 épocas

```
opt.zero_grad()
salida = modelo(xb)
perdida = F.cross_entropy(
   salida, yb)
perdida.backward()
opt.step()
```

Sin `zero_grad()` PyTorch **acumula** los gradientes y mezcla lotes. En los *logits*, $\partial L/\partial z = p - y$.

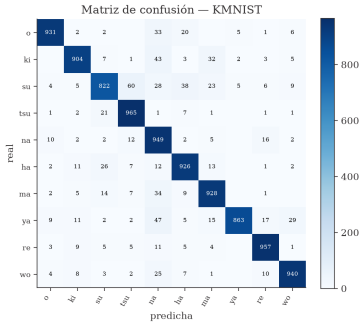


Validación 97,40 %; la brecha entrenamiento–validación es de unos 0,9 pts: no hay sobreajuste aún.



Resultado en prueba: 91,85 %

815 errores de 10 000; la validación daba 97,40 %



97,40 % validación

91,85 % prueba

5,5 pts brecha

La brecha no es un error

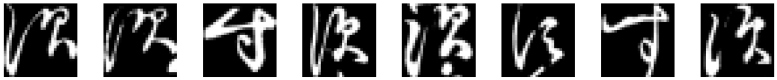
Se repite con 5 semillas y **no** aparece en MNIST ni FashionMNIST. La validación sale del mismo reparto que el entrenamiento; la prueba oficial de KMNIST es más difícil (hipótesis: variantes de escritura solo en prueba). Para reportar rendimiento, **la prueba**.



Los errores: variantes de un mismo carácter

Par más confundido: *su* → *tsu* (60 veces; al revés, 21)

error: real su, predicha tsu



correcto: su



correcto: tsu

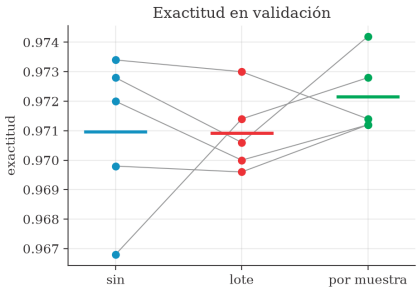


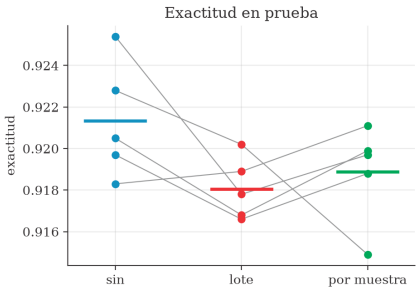
su es la clase más difícil (82,2 %). Los *su* mal leídos son una **variante cursiva** distinta de la dominante y se parecen a grafías de *tsu*: hay variación **dentro** de la clase, no desbalance. La confusión es asimétrica; *na* actúa también como "atractor" (*ya*, *ki*, *ma* → *na*).



Aumento de datos: regulariza, pero no mejora

Desplazamiento de ± 2 px, 5 semillas con el mismo orden de lotes





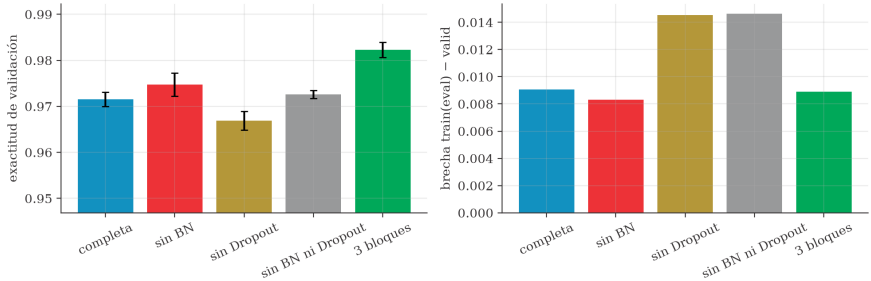
Prueba frente a "sin aumento": lote $-0{,}33$ pts, por muestra $-0{,}25$ pts. **Validación**: 0,00 pts y 0,12 pts. Dentro del ruido entre semillas.

La brecha entrenamiento–validación baja de 0,90 a $\approx$ 0,2 pts. Con 15 épocas: $-0{,}15$ pts en validación y $-0{,}19$ pts en prueba. **Resultado negativo, reportado tal cual.**



Extra: ablación y profundidad

3 semillas pareadas; Dropout ayuda y la red base estaba subajustada



Sin Dropout: validación −0,47 pts, prueba −0,52 pts, brecha 1,45 pts. Sin BatchNorm: cambios de 0,32 y 0,54 pts (ruido). **Tercer bloque: 1,07 en validación y 2,11 pts en prueba** con 8 704 parámetros más y sin crecer la brecha.



Extra: la convolución importa; KMNIST es particular

Mismas condiciones, 3 semillas

Líneas base (prueba)

MLP del docente (101 770 par.): **88,44 %**
CNN del docente (12 810 par.): **91,20 %**
CNNPropia (20 586 par.): **92,10 %**

La CNN pequeña supera al MLP con 8 veces menos parámetros, y el MLP memoriza (brecha 3,1 pts).

La misma red en tres conjuntos

	val.	prueba	brecha
MNIST	98,72	98,80	−0,1
FashionMNIST	90,34	90,27	0,1
KMNIST	97,15	92,10	**5,1**

Solo KMNIST tiene una brecha validación–prueba apreciable.

Tasa de aprendizaje (2 épocas, 1 semilla): 10^{-1}: 82,46 %, 10^{-2}: 96,70 %, 10^{-3}: 96,30 %, 10^{-4}: 92,38 %, 10^{-5}: 76,30 %. Control: con $\eta = 10^{-1}$ la misma red da 82,46 % con BatchNorm y 9,76 % sin ella.



Conclusiones

Lo que se aprendió, incluido lo que no funcionó

Lo que funcionó

- 91,85 % en prueba con 20 586 parámetros.
- Dropout y un tercer bloque (+2,11 pts).
- CNN pequeña $\gg$ MLP con menos parámetros.

Lo que hay que saber

- Validación $\neq$ prueba en KMNIST (5,5 pts).
- El aumento no mejoró; solo regularizó.
- Errores = variantes cursivas, no desbalance.

Limitaciones. 3 a 5 semillas, 5 épocas, una arquitectura base y una partición de validación fija: las diferencias de décimas de punto no son concluyentes. **Siguiente paso:** rotaciones o deformaciones elásticas y más épocas.

UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional en Alta Calidad

www.udistrital.edu.co

VIGILADO MINEDUCACIÓN.
Diseño: Unidad de Publicaciones
Universidad Distrital Francisco José de Caldas



Gracias

Preguntas y discusión

Juan Felipe Rodríguez Galindo
Maestría en Ciencias de la Información
y las Comunicaciones
Inteligencia Computacional Aplicada