Taller propuesto de lógica difusa

Revisión del script del profesor y desarrollo sobre el conjunto Wine

Taller 4 – Punto 3 – Informe de ejecución

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 10 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

1. Revisión del script del profesor

El script es el cuaderno `Taller_LogicaDifusa_RESUELTO_Colab.ipynb` (Python, con su equivalente `Taller_Resuelto_profesor.mlx` en MATLAB). Recorre los bloques básicos de la lógica difusa: funciones de pertenencia, operadores, un sistema Mamdani y uno Sugeno, un clasificador con reglas extraídas de los datos (Wang–Mendel simplificado) y Fuzzy C-Means (FCM), y los contrasta con `scikit-fuzzy`. Para comprobar que cada bloque quedó entendido se reprodujeron con código propio sus valores de referencia (tabla 1); los nueve coinciden.

La figura 1 muestra quién habla con quién. El **cuaderno** orquesta: pide grados de pertenencia, delega la inferencia en el motor (que repite el mismo ciclo por cada regla: fuzzificar, calcular la fuerza, recortar la salida), compara con `scikit-fuzzy` y construye reglas a partir de datos.

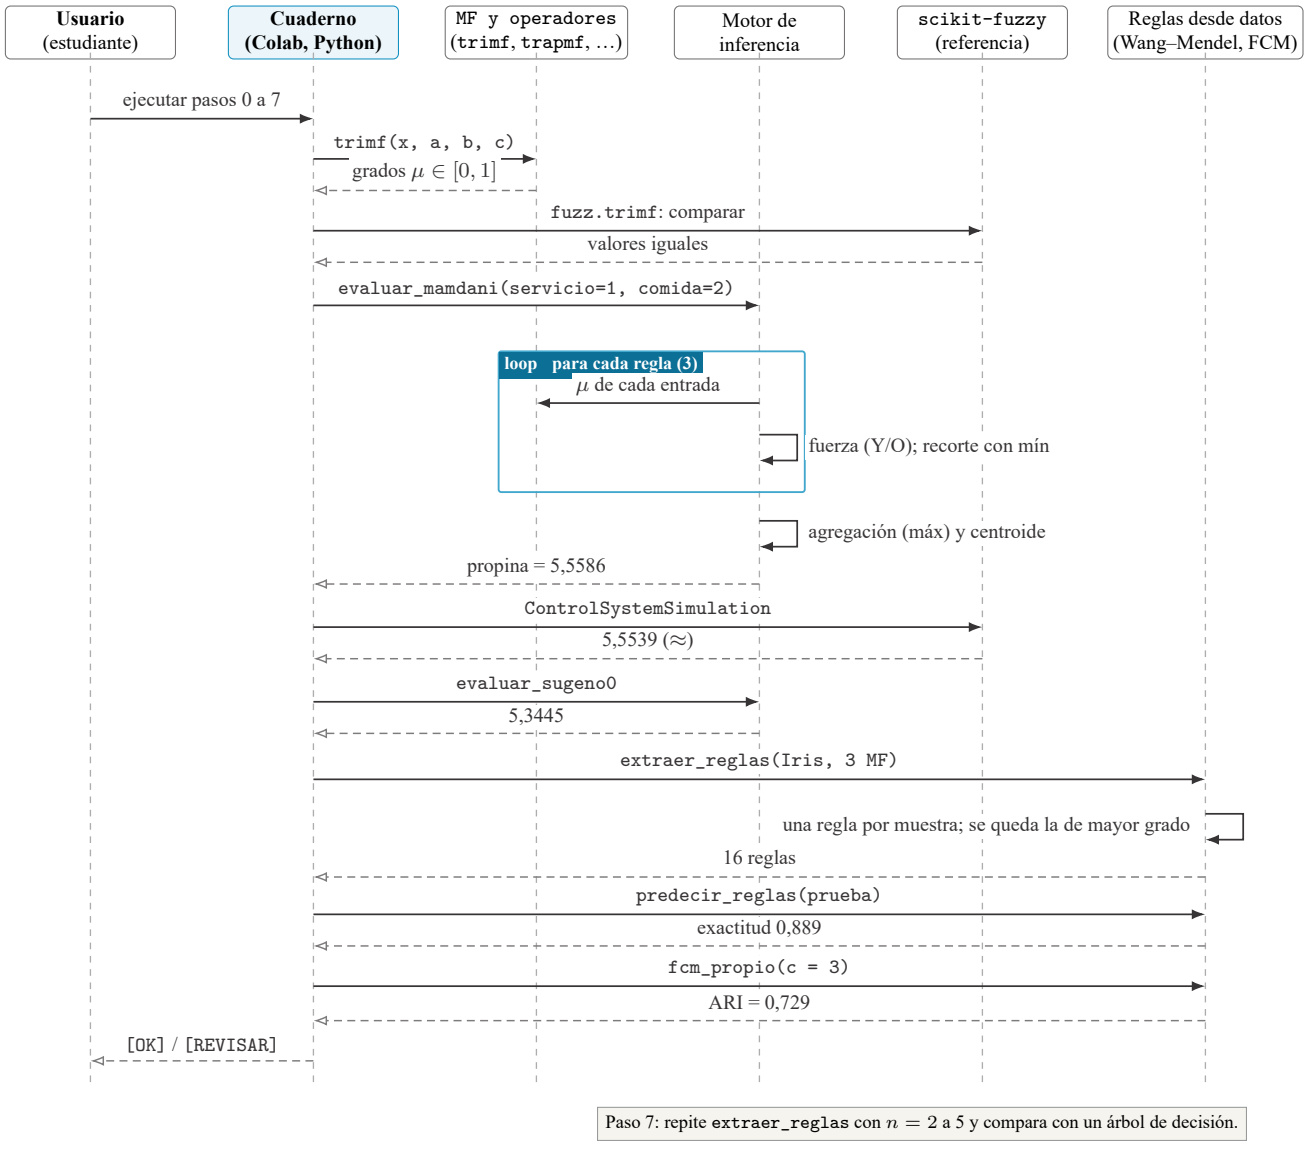


Figura 1: Diagrama de secuencia del cuaderno resuelto. Línea continua: llamada; línea discontinua: retorno.

Tabla 1: Qué hace cada paso del script, qué idea enseña y el valor de referencia que se reprodujo.

Paso	Qué hace	Idea que enseña	Referencia
1–2	`trimf`, `trapmf`, `gaussmf`; operadores Y (mín, producto) y O (máx, probor)	El grado de pertenencia no es una probabilidad	$\mu(5) = 1$
3	Mamdani «propina»: 3 reglas, implicación mínimo, agregación máximo, centroide	Fuzzificar, activar reglas, agregar, defuzzificar	5,5586
4	Sugeno de orden cero: $\sum w_i z_i / \sum w_i$	Sin agregación ni centroide; base de `tunefis`	5,3445
5	Wang–Mendel sobre *Iris*: una regla por muestra y se conserva la de mayor grado	Las reglas salen de los datos; hay menos que n^F	16 reglas, 0,889
6	FCM sobre *Iris* sin etiquetas	Cada punto tiene un grado en cada grupo (suman 1)	ARI 0,729
7	Varía las etiquetas n y compara reglas y exactitud con un árbol	Precisión frente a interpretabilidad	—

Tabla 2: Aciertos y límites encontrados al analizar el script.

Tipo	Observación
Acierto	Cada bloque se contrasta con una referencia externa (MathWorks, `scikit-fuzzy`) y con puntos de control `[OK]`; el cuaderno avisa de que la prueba de *Iris* es pequeña (un acierto $= 2{,}2$ puntos).
Acierto	Muestra la tensión entre precisión y número de reglas (la «explosión de reglas» n^F) y por qué `genfis` con rejilla se vuelve impracticable.
Límite	**La salida del Sugeno se redondea a un número de clase.** Eso supone que las clases están ordenadas a lo largo de las entradas; el script no lo dice (se mide en la sección 2.6).
Límite	Las reglas de Wang–Mendel que no se activan para una muestra caen a la clase 0 por defecto, y todas las cifras salen de **una sola partición** de 45 muestras de prueba.
Límite	`GridPartition` solo crea la estructura de reglas (no entrena las salidas); evaluar su exactitud sin ajustar da $\approx 1/3$. El script lo advierte; el taller propuesto repite la advertencia.

2. Taller propuesto sobre *Wine*

El `Taller_Propuesto.mlx` repite el flujo del profesor con **Wine** (178 vinos, 13 mediciones químicas, 3 cultivares), con partición estratificada 70/30 y semilla 42 (124 vinos de entrenamiento y 54 de prueba). Se resolvió en Python (`Taller_4_Propuesto_Wine.ipynb`). Equivalencias con MATLAB: `anova1` → `f_classif`; `wm_*` → `extraer_reglas` y `predecir_reglas`; `genfis(...,"SubtractiveClustering")` → `SugenoSustractivo` (agrupamiento de Chiu, primer orden); `fcm` → `fcm_propio`. La app *Fuzzy Logic Designer* y `tunefis` no se pudieron ejecutar (no hay MATLAB): se reprodujeron sus vistas y su idea.

2.1. TODO 1 y TODO 2: características y reglas desde datos

Con los vinos de entrenamiento, las cuatro características de mayor F de ANOVA son **flavanoids** ($F = 188$), **proline** (149), **OD280/OD315** (127) y **alcohol** (100); la selección es estable (solo 2 conjuntos distintos en 20 particiones) y se hace solo con el entrenamiento para no filtrar la prueba.

Tabla 3: TODO 2: reglas de Wang–Mendel con 2, 3 y 4 etiquetas frente a la rejilla completa n^4.

Etiquetas n	Reglas	Rejilla n^4	Exactitud prueba	Árbol (mismas hojas)
2	10	16	75,9 %	87,0 %
3	31	81	92,6 %	87,0 %
4	43	256	88,9 %	87,0 %

Las reglas salen de las combinaciones que existen en los datos: son el 62 %, el 38 % y el 17 % de la rejilla. En esta partición $n = 3$ supera a $n = 4$, pero es ruido de una prueba de 54 vinos (un acierto $= 1{,}85$ puntos); con 20 particiones el orden es monótono.

2.2. TODO 3: agrupamiento sustractivo

Tabla 4: TODO 3: `SugenoSustractivo` con $r = 0{,}3$, $0{,}5$ y $0{,}8$ (salida redondeada y acotada a 1..3, NaN $\to$ 1).

Radio r	Reglas	Exact. entren.	Exact. prueba	NaN en prueba
0,3	15	99,2 %	90,7 %	0
0,5	4	96,8 %	94,4 %	0
0,8	3	96,0 %	94,4 %	0

El número de reglas **baja al subir** r (radio: reglas): 0,2: 66, 0,3: 15, 0,4: 8, 0,5: 4, 0,6: 4, 0,7: 3, 0,8: 3, 0,9: 3, 1,0: 3; con $r \geq 0{,}7$ quedan 3, una por cultivar. Con $r = 0{,}3$ el sistema sobreajusta: 15 reglas con 5 coeficientes cada una (75 en total) para 124 vinos; en validación cruzada la exactitud cae a 45,1 % con salidas de hasta $2 \cdot 10^6$, y con regularización *ridge* de 0,1 sube a 90,3 % (96,3 % en prueba).

2.3. TODO 4: Fuzzy C-Means

FCM sobre las 4 características normalizadas, sin etiquetas, agrupa con **pureza 0,927**, ARI 0,794 y coeficiente de partición 0,690 (13 vinos fuera de su cultivar); k-means da la misma pureza (0,927). La versión difusa no mejora el agrupamiento, pero aporta información: **20 de los 178 vinos tienen un grado máximo menor de 0,6** (están en una frontera). Coincide con `skfuzzy.cluster.cmeans`.

2.4. TODO 5: equivalente de *Fuzzy Logic Designer*

El mejor sistema se eligió por validación cruzada de 5 pliegues **solo con el entrenamiento**: $r = 0,8$ (3 reglas; CV de 96,0 % frente a 95,2 % con $r = 0{,}5$ y 45,1 % con $r = 0{,}3$), con 94,4 % de exactitud en prueba.

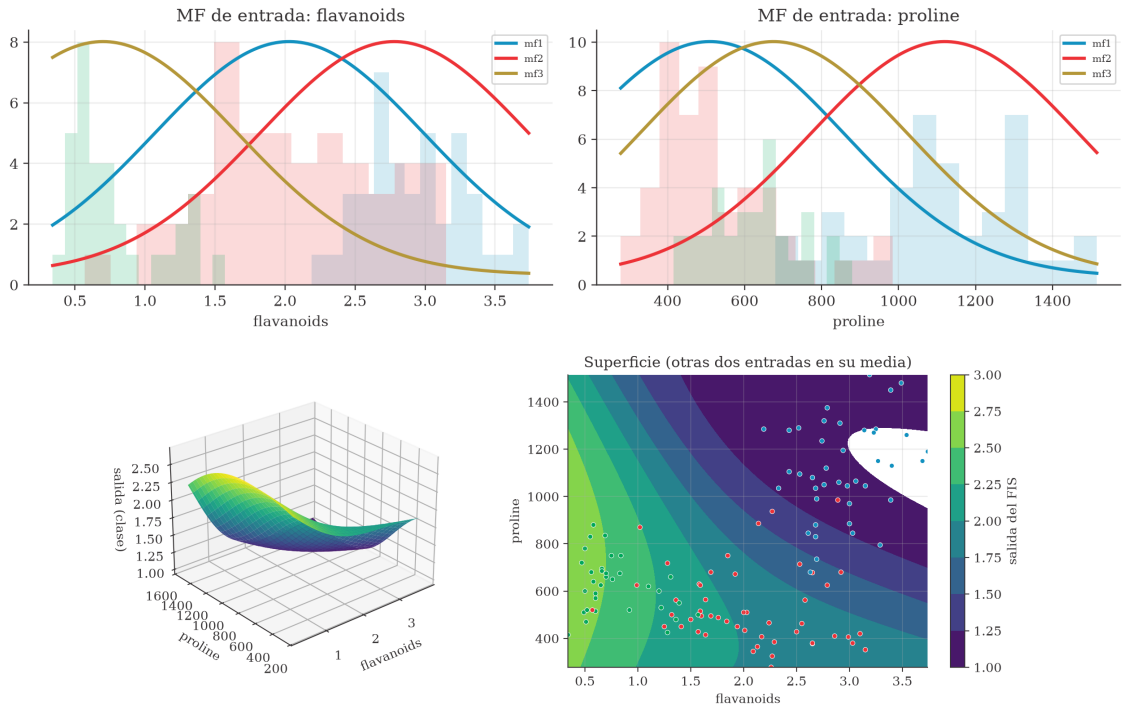


Figura 2: Vistas de la app: funciones de pertenencia de dos entradas (sobre el histograma por clase) y superficie de flavonoides × prolina.

Tabla 5: Las 3 reglas de `fisSub` (centro de cada MF) y la clase que cada una representa.

Regla	flavanoids	proline	OD280	alcohol	Vinos	Clase	Pureza
R1	2,03	510	3,17	12,25	44	2	0,98
R2	2,78	1120	3,03	13,56	42	1	0,95
R3	0,70	675	1,75	12,96	38	3	0,87

¿Qué regla es más fácil de leer? R2 (*flavonoides, prolina, OD280 y alcohol altos → clase 1*, pureza 0,95): las cuatro condiciones apuntan en el mismo sentido, como anticipaba el ranking de F. R3 (flavonoides y OD280 bajos → clase 3) también se lee bien. R1 (clase 2, pureza 0,98) es la más precisa pero se define por contraste (prolina y alcohol bajos). Las gaussianas de cada entrada se traslapan casi por completo: suavizan la superficie pero obligan a nombrar las etiquetas a mano.

2.5. Extra: ajuste de parámetros (*Tune FIS*)

El enunciado remite al ejemplo de MathWorks (`openExample("fuzzy/TuneAFuzzyInferenceSystemExample")`), que no se pudo ejecutar. Se adaptó su protocolo: sobre `fisSub`, entrenado con las filas impares, se ajustan centros y anchos de las MF y se mide el RMSE en las filas pares.

Tabla 6: Efecto del ajuste sobre el RMSE (en unidades de clase).

	RMSE entrenamiento	RMSE validación
Antes del ajuste	0,1452	0,2604
Con parada temprana (iteración 1)	0,0947	0,2543
Sin parada (40 iteraciones)	0,0006	0,3840

Sin control el optimizador **memoriza**: el RMSE de validación sube de 0,260 a 0,384 (+47 %) porque hay 31 parámetros para 62 filas. Con parada temprana (iteración 1) baja a 0,254 y la exactitud en prueba pasa de 90,7 % a 94,4 %. Es la lección del Taller 2: sin validación, optimizar más no es mejorar.

2.6. Extra: 20 particiones y numeración de las clases

Tabla 7: Exactitud en prueba (media ± desviación) en 20 particiones; la selección de características se rehace en cada una.

Método	Reglas	Exactitud en prueba
Wang-Mendel n = 2	9,7 ± 1,2	0,806 ± 0,049
Wang-Mendel n = 3	24,1 ± 3,4	0,865 ± 0,047
Wang-Mendel n = 4	41,9 ± 2,9	0,931 ± 0,036
Sustractivo r = 0,3	14,8 ± 2,8	0,881 ± 0,078
Sustractivo r = 0,5	5,0 ± 0,9	0,956 ± 0,024
Sustractivo r = 0,8	3,0 ± 0,0	0,946 ± 0,024
Árbol de 8 hojas	8	0,894 ± 0,044

El sustractivo con $r = 0{,}5$ a $0{,}8$ es el mejor y el más pequeño (3 a 5 reglas frente a unas 42); su diferencia es menor que la desviación y $r = 0{,}3$ es el más inestable. Las desviaciones de 0,03 a 0,05 equivalen a 2 o 3 vinos, así que una sola partición no es confiable. Además, redondear la salida del Sugeno supone clases ordenadas: al permutar las etiquetas (6 numeraciones), el sustractivo logra 95,6 % con la numeración natural o la inversa y baja hasta 90,4 % con las otras cuatro, mientras que Wang–Mendel no cambia (86,5 %). Funciona en *Wine* porque su numeración ya es ordinal.

3. Lectura honesta y reproducibilidad

- **No se ejecutó MATLAB:** la app *Fuzzy Logic Designer*, `tunefis` y el ejemplo de MathWorks se reprodujeron en Python (vistas e idea).
- **Prueba pequeña:** con 54 vinos, las diferencias de una partición no son concluyentes; se confirmaron con 20 particiones.
- **Reproducir:** `make notebooks` (menos de 2 minutos); semilla 42; 29 verificaciones `[OK]`.