Lógica difusa para el movimiento de un robot

Modelos de 4 y de 2 sensores a partir del análisis de datos

Taller 4 – Punto 4 – Informe de ejecución

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 10 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

1. Enunciado y datos

A partir del análisis de datos se piden **dos modelos de lógica difusa** para clasificar el movimiento de un robot, uno con 4 sensores de entrada y otro con 2. Las funciones de pertenencia (MF) de cada variable se deben definir con histogramas, histogramas con clase y nube de puntos; el número de reglas es el producto de las MF por variable, con un **máximo de 100**.

Los datos son 5456 lecturas de un robot que sigue una pared (los archivos no traen encabezado; los nombres *frente*, *izquierda*, *derecha* y *atrás* se toman del conjunto original de la UCI, y el análisis es coherente con esa lectura). La salida son cuatro movimientos, ordenados de giro cerrado a la derecha a giro leve a la izquierda: *Sharp-Right-Turn* (2097), *Slight-Right-Turn* (826), *Move-Forward* (2205) y *Slight-Left-Turn* (328). Hay 50 filas duplicadas (279 en el archivo de 2 sensores) y lecturas saturadas en 5,0.

Son una serie en el tiempo: hay solo 395 cambios de clase y una racha típica dura 6,5 lecturas, es decir, las lecturas vecinas son casi idénticas. Por eso la prueba se forma con **bloques completos de 100 lecturas consecutivas** (30 % de los bloques: 3856 lecturas de entrenamiento y 1600 de prueba) y no con lecturas sueltas.

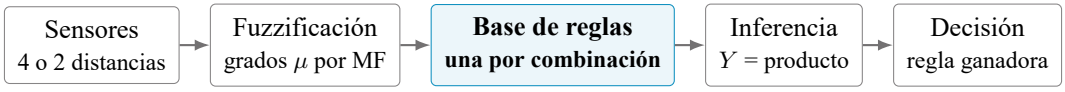


Figura 1: Esquema del sistema difuso construido (para 4 y para 2 sensores).

2. Análisis de datos

Histogramas con clase (figura 2). En *frente*, *Sharp-Right-Turn* ocupa todo el pico de la izquierda y termina de forma abrupta en 0,9; a la derecha de ese valor no aparece. En *izquierda*, *Slight-Right-Turn* se acumula por debajo de 0,5, *Move-Forward* ocupa de 0,5 a 0,9 y *Slight-Left-Turn* queda aislado en valores altos. En *derecha* y *atrás* las cuatro curvas se superponen: no hay un valor donde cambie la clase.

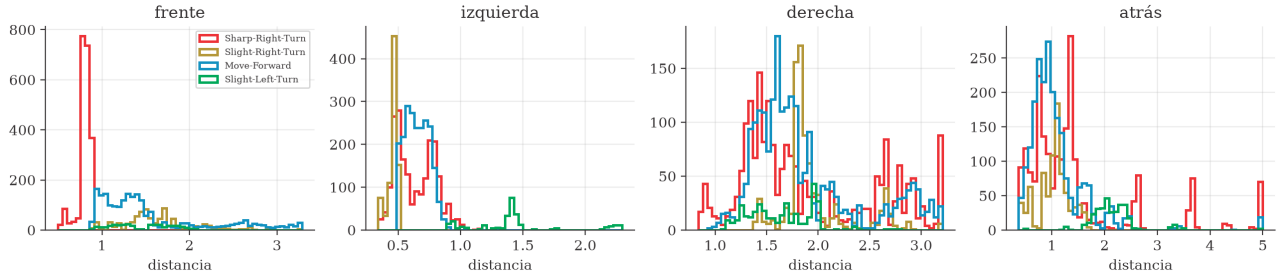


Figura 2: Histograma con clase de cada sensor.

Nube de puntos (figura 3). El histograma marginal de *izquierda* engaña: *Sharp-Right-Turn* se reparte por todos sus valores y tapa el corte de 0,9. Solo en el histograma **condicionado a frente** $> 0{,}9$ (derecha de la figura) se ven tres bloques separados, y la nube *frente* contra *izquierda* muestra que las clases forman **regiones rectangulares**: la frontera depende de una variable a la vez, son umbrales.

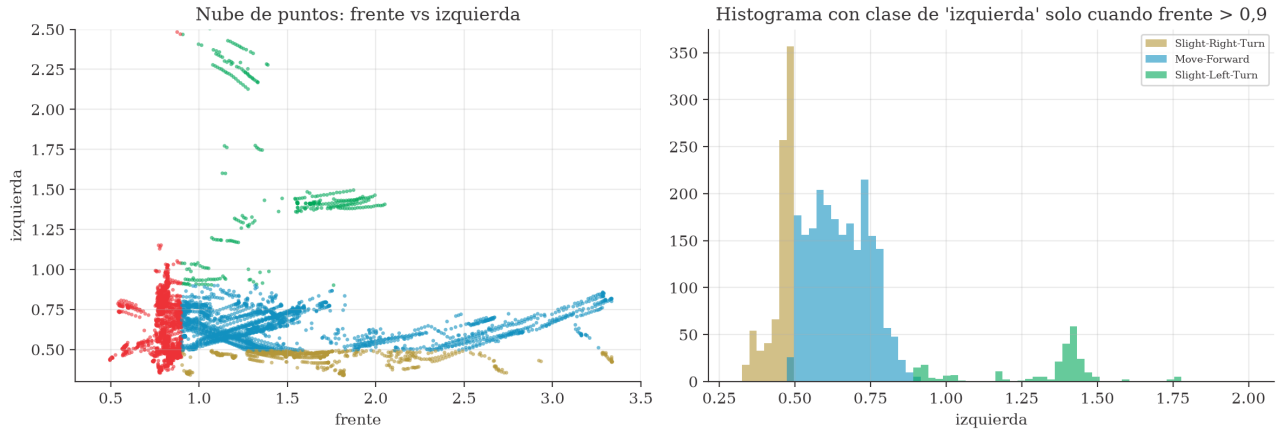


Figura 3: Nube de puntos *frente* contra *izquierda* e histograma con clase de *izquierda* condicionado a *frente* $> 0{,}9$.

Tabla 1: Relevancia de cada sensor (solo con entrenamiento).

Sensor	F de ANOVA	Información mutua	Importancia en árbol
frente	774	0,793	0,556
izquierda	2715	0,577	0,444
derecha	9	0,310	0,000
atrás	119	0,329	0,000

Un árbol pequeño solo usa **frente** (corte 0,9005) e **izquierda** (cortes 0,4945 y 0,9015) y deja *derecha* y *atrás* con importancia 0. La información mutua de esos dos no es cero porque cada uno, solo, tiene alguna relación con la clase, pero es redundante: **4 reglas nítidas con solo frente e izquierda clasifican el 100 % de la prueba**. Las clases parecen provenir de un controlador por umbrales: *frente* $\leq 0{,}9 \rightarrow$ giro cerrado; si no, *izquierda* $\leq 0{,}49 \rightarrow$ giro leve a la derecha, $\leq 0{,}9 \rightarrow$ avanzar y $> 0{,}9 \rightarrow$ giro leve a la izquierda.

3. Diseño de los modelos

Los cruces de las MF (donde dos etiquetas valen 0,5) se colocan en los cortes del análisis y cada MF es un **trapecio con meseta**: vale 1 en su zona y baja a 0 en una franja de ancho $2w$ alrededor de cada corte. El parámetro w es el grado de difusividad: con $w = 0$ el sistema es nítido. La base de reglas es **completa** (una por combinación) y la clase de cada una sale de los datos de entrenamiento, ponderando las clases para que la rara no se pierda; el peso de la regla es su pureza.

Tabla 2: Funciones de pertenencia por variable y número de reglas.

Variable	MF	Etiquetas	Puntos de cruce
frente	2	cerca, lejos	0,9005
izquierda	3	muy cerca, cerca, lejos	0,4945 y 0,9015
derecha (solo en el modelo de 4)	2	cerca, lejos	mediana
atrás (solo en el modelo de 4)	2	cerca, lejos	mediana
Reglas: **2 sensores** $= 2 \times 3 = 6$; **4 sensores** $= 2 \times 3 \times 2 \times 2 = 24$ (máximo permitido: 100).			

La difusividad w se eligió por validación cruzada por bloques solo con el entrenamiento: la mayor w que pierde como máximo 0,2 puntos de exactitud balanceada frente al mejor valor, que resultó $w = 0,02$ para ambos modelos (una franja de 0,04 alrededor de cada corte). Derecha y atrás llevan 2 MF cada una (cruce en la mediana) solo para cumplir con tener las 4 entradas; el análisis indica que podrían omitirse.

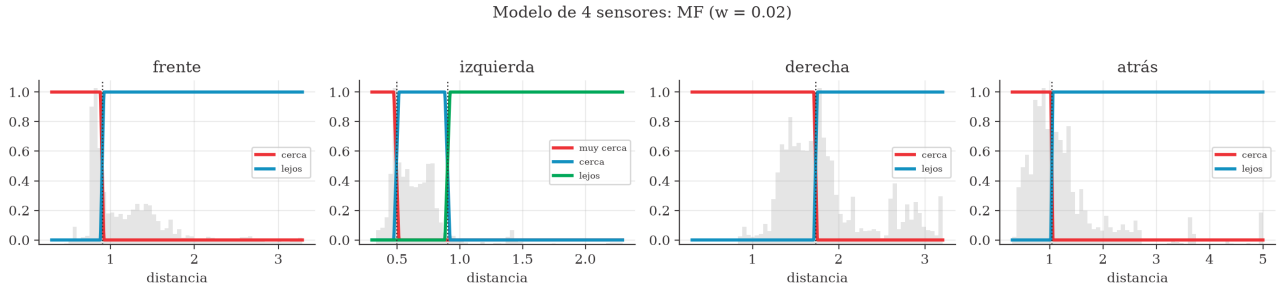


Figura 4: Funciones de pertenencia del modelo de 4 sensores sobre el histograma de cada variable (el de 2 sensores usa las dos primeras).

Tabla 3: Las 6 reglas del modelo de 2 sensores.

Si frente es	y izquierda es	Entonces	Peso
cerca	muy cerca	Sharp-Right-Turn	0,98
cerca	cerca	Sharp-Right-Turn	0,99
cerca	lejos	Sharp-Right-Turn	0,94
lejos	muy cerca	Slight-Right-Turn	0,97
lejos	cerca	Move-Forward	0,90
lejos	lejos	Slight-Left-Turn	1,00

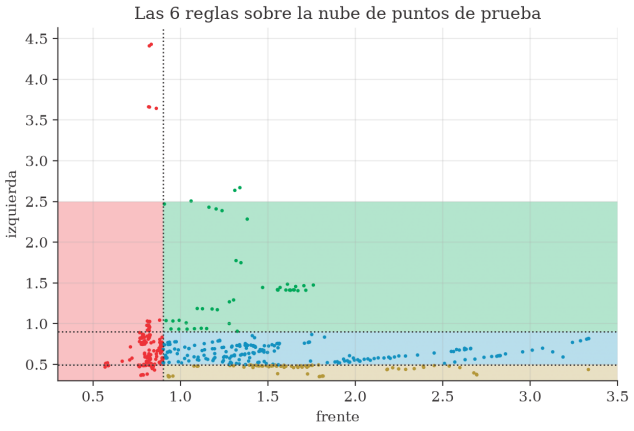


Figura 5: Región que gana cada regla en el plano *frente–izquierda*, sobre la nube de puntos de prueba.

4. Resultados

Tabla 4: Resultados en los bloques de prueba (1600 lecturas).

Modelo	MF por variable	Reglas	w	Exactitud	Exact. balanceada	F1 macro
2 sensores	2×3	6	0,02	99,81 %	99,88 %	99,88 %
4 sensores	$2 \times 3 \times 2 \times 2$	24	0,02	99,50 %	99,39 %	99,45 %

El modelo de **2 sensores** (6 reglas) acierta 99,81 % y el de **4 sensores** (24 reglas) 99,50 %. Los errores están a menos de 0,002 de un corte en la variable que decide (por ejemplo, *frente* $= 0{,}901$ cuando el corte es $0{,}9005$), justo donde las dos etiquetas valen casi lo mismo. El modelo de 4 sensores es ligeramente peor porque sus dos variables extra no aportan información y solo multiplican las reglas por 4.

El análisis importa. Con el mismo límite de 100 reglas, los diseños automáticos (uniformes, por cuantiles o por Fuzzy C-Means, con el número de MF elegido por validación cruzada) logran de 91,4 % a 96,1 % con 2 sensores y de 78,7 % a 95,2 % con 4, usando de 48 a 100 reglas.

Tabla 5: Diseños de MF con el límite de 100 reglas (CV = exactitud balanceada en validación cruzada por bloques).

Modelo	Diseño de las MF	MF	Reglas	CV	Exactitud	Exact. bal.
2 sensores	uniforme (auto.)	6-10	60	95,4 %	91,4 %	94,2 %
2 sensores	cuantiles (auto.)	6-8	48	96,7 %	94,4 %	96,3 %
2 sensores	fcm (auto.)	8-10	80	95,6 %	96,1 %	97,3 %
2 sensores	cortes del análisis	2-3	6	99,8 %	99,8 %	99,9 %
4 sensores	uniforme (auto.)	5-5-2-2	100	86,7 %	78,7 %	80,8 %
4 sensores	cuantiles (auto.)	3-4-3-2	72	95,4 %	95,2 %	96,3 %
4 sensores	fcm (auto.)	5-5-2-2	100	90,0 %	83,6 %	83,0 %
4 sensores	cortes del análisis	2-3-2-2	24	99,8 %	99,5 %	99,4 %

Cuidado con la partición. Con lecturas sueltas en lugar de bloques, kNN pasa de 85,6 % a 94,0 % en el modelo de 4 sensores (**+8,3 pts** de fuga entre lecturas vecinas); los modelos con cortes del análisis casi no cambian porque no memorizan: aprenden umbrales.

Tabla 6: Exactitud en prueba con partición por bloques frente a partición muestra a muestra.

Modelo	Método	Por bloques	Muestra a muestra	Diferencia
2 sensores	difuso con cortes del análisis	99,8 %	99,8 %	0,01 pts
2 sensores	difuso cuantiles	94,4 %	96,5 %	2,08 pts
2 sensores	kNN (k = 15)	95,0 %	97,0 %	1,95 pts
2 sensores	árbol (60 hojas)	100,0 %	100,0 %	0,00 pts
4 sensores	difuso con cortes del análisis	99,5 %	99,6 %	0,13 pts
4 sensores	difuso cuantiles	95,2 %	94,0 %	−1,30 pts
4 sensores	kNN (k = 15)	85,6 %	94,0 %	8,33 pts
4 sensores	árbol (60 hojas)	100,0 %	100,0 %	0,00 pts

5. Difusividad y variante Mamdani

Con **regla ganadora** la exactitud cae poco y de forma gradual al aumentar w (92,6 % con $w = 0{,}2$, 2 sensores). Con **Mamdani y centroide** (las clases ordenadas de giro cerrado a la derecha a giro leve a la izquierda, salida redondeada) la caída es mucho más rápida: 97,8 % con $w = 0{,}005$ y 58,2 % con $w = 0{,}2$. Las clases son categorías y el centroide mezcla reglas vecinas en un número intermedio que, al redondear, puede caer en una tercera clase. Para **clasificar** conviene la regla ganadora; la salida Mamdani tiene sentido como señal de dirección continua. Nuestro Mamdani coincide con `scikit-fuzzy` (diferencia menor de 0,02 en 150 puntos).

Tabla 7: Exactitud en prueba según la difusividad w y la forma de producir la salida.

w	2 sens. ganadora	2 sens. Mamdani	4 sens. ganadora	4 sens. Mamdani
0,000	100,0 %	100,0 %	100,0 %	100,0 %
0,005	100,0 %	97,8 %	99,9 %	97,8 %
0,010	100,0 %	95,9 %	99,8 %	95,9 %
0,020	99,8 %	94,5 %	99,5 %	94,2 %
0,050	98,8 %	89,2 %	98,2 %	89,0 %
0,100	96,8 %	81,9 %	96,0 %	82,1 %
0,200	92,6 %	58,2 %	91,0 %	57,9 %

6. Conclusiones y límites

1. El análisis de datos define las MF: las clases separan por **umbrales sobre dos sensores** (frente en 0,9; izquierda en 0,49 y 0,9); derecha y atrás no aportan.
2. **2 sensores:** $2 \times 3 = 6$ reglas, 99,81 % de exactitud y 99,88 % de exactitud balanceada. **4 sensores:** $2 \times 3 \times 2 \times 2 = 24$ reglas, 99,50 % y 99,39 %. Ambos respetan el máximo de 100.
3. Más reglas no es mejor: los diseños automáticos con hasta 100 reglas rinden de 78,7 % a 96,1 %; con series de tiempo, la partición muestra a muestra infla los resultados.
4. **Límites:** nombres de sensores tomados del conjunto original; la regla parece de un controlador por umbrales, así que no se extrapola a otro robot sin repetir el análisis; una sola partición por bloques (semilla 42).

Reproducir: `make notebooks` (menos de 2 minutos); semilla 42; 19 verificaciones `[OK]`. Reglas en `resultados/reglas_2_sensores.csv` y `reglas_4_sensores.csv`.