

UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional en Alta Calidad

Lógica difusa: reglas desde datos y modelos para un robot

Taller 4: propuesto (Wine) y adicional (robot)

Juan Felipe Rodríguez Galindo
20261595004
Maestría en Ciencias de la Información y las Comunicaciones
Inteligencia Computacional Aplicada



Qué se pidió y qué se hizo

Dos entregas con la misma fecha: Taller Propuesto (punto 3) y Taller Adicional (punto 4)

Punto 3 · Taller Propuesto

Revisar el script resuelto del profesor (Mamdani, Sugeno, Wang–Mendel, FCM) y repetir su flujo con **Wine**: TODO 1 a 5 y el ejemplo *Tune FIS*. Hecho en Python.

Punto 4 · Taller Adicional

Dos modelos difusos (4 y 2 sensores) para clasificar el movimiento de un robot, con las MF salidas del análisis de datos y máximo 100 reglas.

Revisar script del profesor → **Reproducir** 9 referencias → **Wine** TODO 1 a 5 → **Robot** 6 y 24 reglas



El script del profesor: qué hace y qué supone

Se reprodujeron sus 9 valores de referencia con código propio

Lo que recorre

MF y operadores → **Mamdani** (propina 5,5586) → **Sugeno 0** (5,3445) → **Wang–Mendel** en *Iris* (16 reglas, 0,889) → **FCM** (ARI 0,729) → reglas frente a un árbol.

Supuestos que no se dicen

1. La salida del Sugeno se redondea a un número de clase: supone clases **ordenadas**.
2. Si ninguna regla se activa, la clase por defecto es 0.
3. Todo sale de **una** partición pequeña (45 pruebas en *Iris*).

Estos tres puntos guiaron el desarrollo propio: se midió el efecto de la numeración de clases, se evitó confiar en una sola partición (20 particiones) y se usó validación para elegir parámetros.



Wine: TODO 1 y TODO 2

Selección de 4 características con ANOVA y reglas de Wang--Mendel

TODO 1 · ANOVA (solo entrenamiento)

flavanoids (F = 188), proline (149), OD280/OD315 (127), alcohol (100). En 20 particiones, solo 2 conjuntos distintos: la selección es estable.

TODO 2 · reglas desde datos

Etiquetas n	Reglas	Rejilla n^4	Exactitud prueba	Árbol (mismas hojas)
2	10	16	75,9 %	87,0 %
3	31	81	92,6 %	87,0 %
4	43	256	88,9 %	87,0 %

Las reglas son el 62 %, 38 % y 17 % de la rejilla n^4: salen solo de las combinaciones que existen. En esta partición $n = 3$ supera a $n = 4$, pero con 54 vinos de prueba un acierto vale 1,85 puntos: es ruido (en 20 particiones el orden es monótono).



TODO 3: agrupamiento sustractivo

Menos reglas al subir r, y un sobreajuste que una sola partición no muestra

Reglas y exactitud

Radio r	Reglas	Exact. entren.	Exact. prueba	NaN en prueba
0,3	15	99,2 %	90,7 %	0
0,5	4	96,8 %	94,4 %	0
0,8	3	96,0 %	94,4 %	0

Con $r \geq 0{,}7$ quedan 3 reglas, una por cultivar.

El fallo de r = 0,3

15 reglas $\times$ 5 coeficientes $\approx$ 75 parámetros para 124 vinos. En validación cruzada: 45,1 % y salidas de hasta $2 \cdot 10^6$. Con *ridge* 0,1: 90,3 %.



TODO 4 y TODO 5

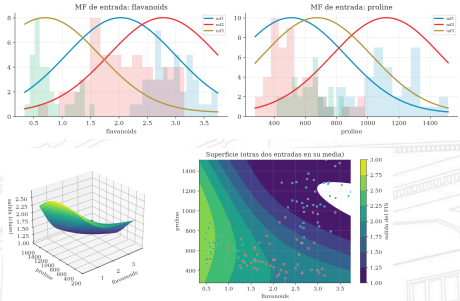
Fuzzy C-Means y el equivalente de la app Fuzzy Logic Designer

FCM sin etiquetas

Pureza 0,927, ARI 0,794; k-means da la misma pureza. Lo que aporta lo difuso: 20 de 178 vinos tienen grado máximo $< 0{,}6$ (frontera).

Mejor sistema (validación cruzada)

$r = 0{,}8$: 3 reglas, exactitud en prueba 94,4 %. R2 (todo alto $\rightarrow$ clase 1) es la más fácil de leer.





Extra: Tune FIS y numeración de clases

Dos advertencias sobre procedimientos que parecen inocentes



Sin parada, el RMSE de validación sube 47 %; con parada temprana baja y la exactitud pasa de 90,7 % a 94,4 %.

Redondear la clase

El Sugeno redondeado supone clases ordenadas. Al permutar las etiquetas de *Wine*: 95,6 % (natural) y 90,4 % (otras). Wang–Mendel no cambia.



20 particiones: lo que una sola partición no dice

Media ± desviación de la exactitud en prueba

Wine, 20 particiones

Método	Reglas	Exactitud en prueba
Wang-Mendel n = 2	9,7 ± 1,2	0,806 ± 0,049
Wang-Mendel n = 3	24,1 ± 3,4	0,865 ± 0,047
Wang-Mendel n = 4	41,9 ± 2,9	0,931 ± 0,036
Sustractivo r = 0,3	14,8 ± 2,8	0,881 ± 0,078
Sustractivo r = 0,5	5,0 ± 0,9	0,956 ± 0,024
Sustractivo r = 0,8	3,0 ± 0,0	0,946 ± 0,024
Árbol de 8 hojas	8	0,894 ± 0,044

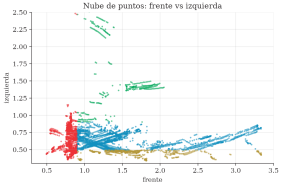
Lectura

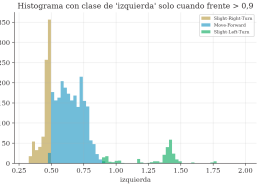
El sustractivo con $r = 0{,}5$ a $0{,}8$ es el mejor y el más pequeño (3 a 5 reglas frente a $\approx$ 42). La diferencia entre los dos es menor que la desviación. Desviaciones de 0,03 a 0,05 son 2 o 3 vinos: una partición no basta.



Robot: qué dicen los datos

5456 lecturas; 4 clases ordenadas de giro cerrado a la derecha a giro leve a la izquierda





Lo que se ve

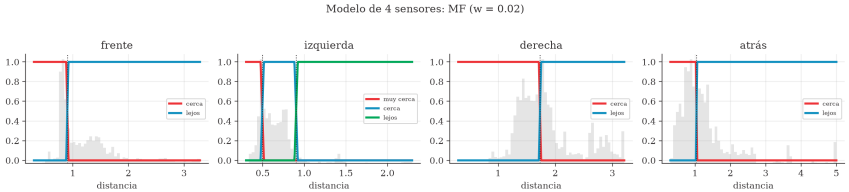
Las clases forman **rectángulos**: son umbrales sobre dos sensores. Frente en 0,9005; izquierda en 0,4945 y 0,9015. Derecha y atrás no aportan.

Es una serie en el tiempo (racha típica de 6,5 lecturas): se prueba con bloques de 100.



Robot: funciones de pertenencia y modelos

Los cruces van donde cambia la clase; w = ancho de la zona difusa



2 sensores

$2 \times 3 =$ **6 reglas**; exactitud **99,81 %**, balanceada 99,88 %.

4 sensores

$2 \times 3 \times 2 \times 2 =$ **24 reglas**; exactitud **99,50 %**, balanceada 99,39 %.



Robot: el análisis importa, y también cómo se evalúa

Mismo límite de 100 reglas

Diseños de MF

Modelo	Diseño de las MF	MF	Reglas	CV	Exactitud	Exact. bal.
2 sensores	uniforme (auto.)	6-10	60	95,4 %	91,4 %	94,2 %
2 sensores	cuantiles (auto.)	6-8	48	96,7 %	94,4 %	96,3 %
2 sensores	fcm (auto.)	8-10	80	95,6 %	96,1 %	97,3 %
2 sensores	cortes del análisis	2-3	6	99,8 %	99,8 %	99,9 %
4 sensores	uniforme (auto.)	5-5-2-2	100	86,7 %	78,7 %	80,8 %
4 sensores	cuantiles (auto.)	3-4-3-2	72	95,4 %	95,2 %	96,3 %
4 sensores	fcm (auto.)	5-5-2-2	100	90,0 %	83,6 %	83,0 %
4 sensores	cortes del análisis	2-3-2-2	24	99,8 %	99,5 %	99,4 %

Dos lecciones

Más reglas $\neq$ mejor: los diseños automáticos rinden de 78,7 % a 96,1 %.

Series de tiempo: con lecturas sueltas, kNN pasa de 85,6 % a 94,0 % (+8,3 pts de fuga).



Conclusiones

Lo que funcionó y lo que hay que saber

Lo que funcionó

- Reproducir el script: 9 de 9 referencias.
- Sustractivo ($r = 0{,}5$ a $0{,}8$): 3 a 5 reglas y $\approx$ 95 %.
- Robot: 6 y 24 reglas con $>$ 99 %.

Lo que hay que saber

- r pequeño sobreajusta; validar cruzado.
- Ajustar sin validación memoriza.
- Redondear clases supone un orden.
- Series de tiempo: evaluar por bloques.

Límites: no se ejecutó MATLAB (se reprodujeron sus vistas y su idea en Python); una partición 70/30 en Wine; nombres de sensores tomados del conjunto original.

UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional en Alta Calidad

www.udistrital.edu.co

VIGILADO MINEDUCACIÓN.
Diseño: Unidad de Publicaciones
Universidad Distrital Francisco José de Caldas



Gracias

Preguntas y discusión

Juan Felipe Rodríguez Galindo
Maestría en Ciencias de la Información
y las Comunicaciones
Inteligencia Computacional Aplicada