Clasificador difuso con reglas extraídas de datos

Wine: funciones de pertenencia, t-normas, árbol de decisión y Fuzzy C-Means

Taller 5 – Informe

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 17 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

1. Introducción

En este taller construí un clasificador difuso cuyas reglas salen directamente de los datos y lo probé en el conjunto Wine (178 vinos, 13 características químicas, 3 cultivares); para ello seguí el cuaderno *Taller6B_LogicaDifusa_Propuesto_Colab.ipynb* y resolví sus seis TODO: selección de 4 características sin fuga de información, la función de pertenencia sigmoidal, la fuerza de las reglas con las t-normas mínimo y producto, la evaluación con matriz de confusión, el experimento del número de etiquetas contra un árbol de decisión y el agrupamiento con Fuzzy C-Means, desarrollando solo la parte en Python; la parte en MATLAB (*Taller_Propuesto.mlx*) no la hice porque no tengo MATLAB, aunque el cuaderno deja exportados los dos CSV que esa parte usa.

Entregables: el cuaderno `taller5_logica_difusa.ipynb` ejecutado, `requirements.txt`, los archivos `wine_4car_train.csv` y `wine_4car_test.csv` que genera el cuaderno y este informe; antes de programar presenté el plan y mis hipótesis, quedando todo grabado en video (sección 7).

2. Marco teórico

Funciones de pertenencia. Un conjunto difuso asigna a cada valor un grado entre 0 y 1, donde la triangular $\mathrm{trimf}(x; a, b, c)$ sube de 0 en a a 1 en b y baja a 0 en c; en contraste, la sigmoidal posee pendiente a y cruce c:

$$\mathrm{sigmf}(x; a, c) = \frac{1}{1 + e^{-a(x-c)}},$$

vale 0,5 en $x = c$ y es estrictamente creciente si $a > 0$, así que resulta apropiada para etiquetas abiertas como "alto".

Reglas y t-normas. Una regla adopta la forma "SI x_1 es A_1 Y … Y x_4 es A_4 ENTONCES clase $= k$", calculándose la conjunción con una t-norma sobre los grados de las cuatro condiciones, sea el mínimo, $\min_f \mu_{A_f}(x_f)$, o el producto, $\prod_f \mu_{A_f}(x_f)$. Dado que los grados yacen en $[0, 1]$, siempre se cumple producto $\leq$ mínimo; la muestra, por su parte, se asigna a la clase de la regla con mayor grado de disparo.

Extracción de reglas (Wang-Mendel simplificado). Cada característica se divide en n_{mf} triangulares uniformes y para cada muestra de entrenamiento se toma la etiqueta de mayor grado en cada variable, conformando el antecedente mientras el consecuente corresponde a su clase. Si dos muestras producen antecedentes idénticos se conserva la de mayor grado, alcanzando con 4 características un tope teórico de n_{mf}^4 reglas.

Fuzzy C-Means y ARI. FCM agrupa sin recurrir a etiquetas: cada muestra pertenece a cada grupo con un grado, sumando 1 los grados de cada observación y minimizando con exponente $m = 2$ la función $J = \sum_i \sum_k u_{ik}^m \, \|x_k - c_i\|^2$. El índice de Rand ajustado (ARI) contrasta el agrupamiento con las clases reales; vale 1 si coinciden plenamente y ronda 0 cuando el acuerdo equivale al azar, con la ventaja de no depender de cómo se numeren los grupos.

3. Metodología

Entorno. Se empleó Python 3.12 bajo un entorno de `uv` con numpy, matplotlib, scikit-learn y scikit-fuzzy (requiriendo networkx); las funciones de pertenencia, el clasificador y FCM fueron desarrollados directamente en el cuaderno, mientras scikit-fuzzy solo se utilizó para comprobar la sigmoidal. La semilla (`SEMILLA = 42`) y el conjunto (`DATASET = "wine"`) se fijan al inicio; cada TODO cuenta con un punto de control que reporta `[OK]` o `[REVISAR]`, quedando los 16 verificados en `[OK]`.

Datos. Se aplicó una partición estratificada 70-30 con semilla 42, asignando 124 vinos a entrenamiento (41, 50 y 33 por clase) y 54 a prueba (18, 21 y 15), ajustando `SelectKBest(f_classif, k=4)` estrictamente sobre el entrenamiento. De haberse ajustado sobre la totalidad de los datos, las muestras de prueba habrían sesgado la selección hacia un desempeño optimista por fuga de información; así, las cuatro variables se normalizan a $[0, 1]$ con los extremos del entrenamiento, recortando en prueba cualquier valor que desborde dicho rango.

Experimentos. Fijando $n_{mf} = 3$ se extraen las reglas para comparar ambas t-normas (TODO 3), evaluando luego con producto la exactitud y la matriz de confusión (TODO 4); posteriormente, en el TODO 5 se varía $n_{mf} \in \{2, 3, 4\}$ contrastándolo con un `DecisionTreeClassifier` acotado en `max_leaf_nodes` al número de reglas extraídas sobre las mismas cuatro características. Finalmente, en el TODO 6, FCM agrupa los 178 vinos en $c = 3$ conglomerados con $m = 2$ prescindiendo de las etiquetas de clase para computar el ARI.

4. Resultados

4.1. Características y t-normas (TODO 1 a 3)

La tabla 1 muestra las cuatro características elegidas con su estadístico F en el entrenamiento.

Tabla 1: Características elegidas por `SelectKBest` (ajustado solo con entrenamiento).

Característica	F (ANOVA)	Rango en entrenamiento
Flavonoides (*flavanoids*)	187,7	0,34 – 3,74
Prolina (*proline*)	149,4	278 – 1515
OD280/OD315 de vinos diluidos	126,6	1,27 – 3,92
Alcohol	100,3	11,03 – 14,83

La sigmoidal superó los tres controles: vale 0,5 en $x = c$, es creciente con $a > 0$ y coincide con `skfuzzy.sigmf`, que recibe los parámetros en el orden (x, c, a); con $n_{mf} = 3$ salieron 31 reglas de las 81 posibles (12 de la clase 0, 11 de la 1 y 8 de la 2), resumiéndose en la tabla 2 la comparación entre t-normas.

Tabla 2: Clasificador difuso con $n_{mf} = 3$ según la t-norma. La regla ganadora es la misma en los 54 vinos de prueba.

T-norma	Reglas	Exactitud en prueba
Producto	31	92,6 %
Mínimo	31	92,6 %

4.2. Evaluación con producto (TODO 4)

La tabla 3 corresponde a la matriz de confusión en prueba; se registran 4 errores en 54 vinos, donde el par más confundido corresponde a la clase 1 $\rightarrow$ clase 2 con 2 instancias.

Tabla 3: Matriz de confusión en prueba ($n_{mf} = 3$, producto).

Real \ Predicha	Clase 0	Clase 1	Clase 2
Clase 0	**17**	1	0
Clase 1	1	**18**	2
Clase 2	0	0	**15**

Las tres reglas con mayor grado son:

1. SI alcohol es medio Y flavonoides es medio Y OD280/OD315 es medio Y prolina es media ENTONCES clase 1 (grado 0,60).
2. SI alcohol es bajo Y flavonoides es medio Y OD280/OD315 es medio Y prolina es baja ENTONCES clase 1 (grado 0,58).
3. SI alcohol es medio Y flavonoides es medio Y OD280/OD315 es medio Y prolina es baja ENTONCES clase 1 (grado 0,54).

4.3. Etiquetas contra árbol (TODO 5)

La tabla 4 y la figura 1 muestran el experimento con 2, 3 y 4 etiquetas por característica.

Tabla 4: Número de reglas y exactitud en prueba según n_{mf}. El árbol se limita a tantas hojas como reglas.

n_{mf}	Máximo (n_{mf}^4)	Reglas	Difuso	Hojas del árbol	Árbol
2	16	10	75,9 %	10	87,0 %
3	81	31	92,6 %	13	87,0 %
4	256	43	88,9 %	13	87,0 %

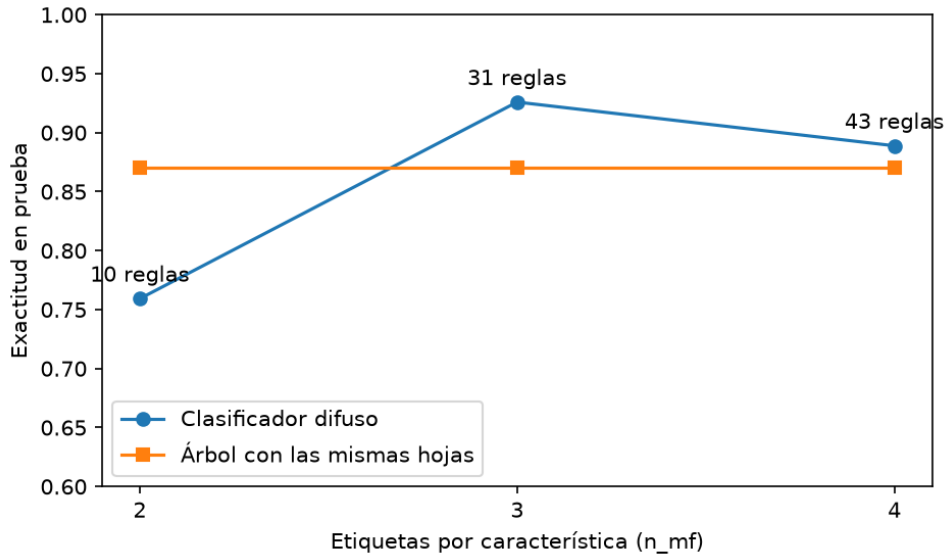


Figura 1: Exactitud en prueba del clasificador difuso y del árbol según el número de etiquetas.

4.4. Fuzzy C-Means (TODO 6)

FCM convergió en 19 iteraciones tras reducir J de 15,7 a 7,4 y arrojando un ARI de 0,794 frente a las etiquetas reales. Al asignar cada vino al grupo de máxima pertenencia, cada conglomerado refleja predominantemente una clase: la clase 2 se agrupa íntegramente (48 de 48), la clase 0 casi en su totalidad (57 de 59) y la clase 1 en el tercero (60 de 71), quedando 10 vinos de la clase 1 dentro del grupo de la clase 2. El coeficiente de partición es 0,69, entre el valor de $1/3$ de una partición totalmente borrosa y el valor de 1 de una nítida.

5. Análisis

Tres etiquetas es el punto medio. Con 2 etiquetas cada variable solo discrimina entre "bajo" y "alto", de modo que 10 reglas resultan insuficientes para separar la clase 1, que queda en una franja intermedia en flavonoides y OD280/OD315, lo cual degrada la exactitud al 75,9 %; en cambio, con 4 etiquetas se generan 43 reglas donde muchas provienen de un único vino de entrenamiento sin repetirse en prueba (incluso una muestra de prueba queda sin regla activa), cayendo la exactitud a 88,9 %.

Hay muchas menos reglas que combinaciones. Las reglas se manifiestan únicamente donde existen datos: con 3 etiquetas aparecen 31 de 81 antecedentes y con 4 apenas 43 de 256; esto ocurre porque varias características están correlacionadas (flavonoides con OD280/OD315, 0,77; alcohol con prolina, 0,66), de modo que muchas combinaciones de etiquetas nunca se presentan en los datos.

El árbol no cambia. Con 10 hojas el árbol alcanza 87,0 %, pero al autorizarle 31 o 43 hojas utiliza únicamente 13, puesto que a esa profundidad todas las hojas son homogéneas en entrenamiento y carece de impureza por escindir; por este motivo su exactitud permanece fija en 87,0 % a partir de $n_{mf} = 3$, volviendo inocuo el techo de hojas.

Mínimo y producto coinciden. Aunque el producto genera grados sistemáticamente menores o iguales al mínimo, la decisión final depende exclusivamente de la regla dominante; en los 54 vinos de prueba la regla ganadora coincide bajo ambas t-normas, derivando en una exactitud idéntica.

Los errores son esperables. Tres de los cuatro fallos son vinos de la clase 1, que queda entre las otras dos en flavonoides y OD280/OD315 y se parece a la clase 2 en alcohol y prolina (medias de 12,24 frente a 13,07 y de 531 frente a 624), patrón que FCM replica de forma no supervisada al ser la clase 1 la que se bifurca entre dos grupos.

La muestra de prueba es pequeña. Al contar con 54 vinos cada observación representa 1,85 puntos porcentuales, de modo que la brecha entre 92,6 % y 88,9 % obedece a apenas 2 vinos y entre 92,6 % y 87,0 % a 3, por lo que una partición distinta podría alterar dicho escalonamiento.

Hipótesis contra resultados. Antes de ejecutar escribí cuatro hipótesis en la presentación del plan:

1. *"Con más etiquetas habrá más reglas y al principio funcionará mejor, pero se sobreentrenará."* Se cumplió: las reglas crecen (10, 31, 43) y la exactitud sube de 2 a 3 etiquetas y baja con 4.
2. *"En algunos casos más etiquetas degradarán la exactitud."* Se cumplió: de 3 a 4 etiquetas bajó de 92,6 % a 88,9 %.
3. *"Casi no cambia la regla ganadora, así que la exactitud será parecida."* Se cumplió del todo: la regla ganadora es la misma en los 54 vinos.
4. *"El árbol se puede complejizar hasta desempeñarse mejor que el difuso."* Se cumplió solo con 2 etiquetas (87,0 % contra 75,9 %); con 3 y 4 el árbol se estanca al saturar la pureza de sus hojas y el difuso lo supera.

Interpretabilidad. Las reglas difusas se formulan de manera natural en términos del dominio (“alcohol medio y prolina baja”), especificando el grado de pertenencia con el que disparan; si bien el árbol también resulta legible, sus particiones trazan fronteras rígidas donde una pequeña variación desplaza la muestra de rama, mientras el enfoque difuso modula gradualmente su pertenencia compartida.

6. Conclusiones

1. La selección sin fuga ajustada en entrenamiento aisló flavonoides, prolina, OD280/OD315 y alcohol como las variables más discriminantes según el estadístico F.
2. Con 3 etiquetas por variable, Wang-Mendel extrajo 31 reglas y clasificó correctamente el 92,6 % del conjunto de prueba (50 de 54 vinos), arrojando igual exactitud con mínimo y producto al no variar la regla ganadora.
3. La principal confusión se produjo en la transición clase 1 $\rightarrow$ clase 2 (2 vinos), explicada porque la clase 1 se parece a la clase 2 en alcohol y prolina y queda entre las otras dos en flavonoides y OD280/OD315.
4. Incrementar etiquetas no garantiza mejoría: ante 2, 3 y 4 etiquetas la exactitud fue 75,9 %, 92,6 % y 88,9 %, mientras el árbol se limitó a 87,0 % al copar 13 hojas puras.
5. De modo no supervisado, Fuzzy C-Means reconstruyó los tres cultivares con un ARI de 0,794, reproduciendo la misma ambigüedad entre las clases 1 y 2.

7. Declaración de uso de IA

Usé Claude (Anthropic) para revisar y corregir errores y para redactar este informe a partir de los resultados del cuaderno. Todo el desarrollo quedó grabado (cerca de 1 hora y 15 minutos):

https://youtu.be/sCQziT3QukI