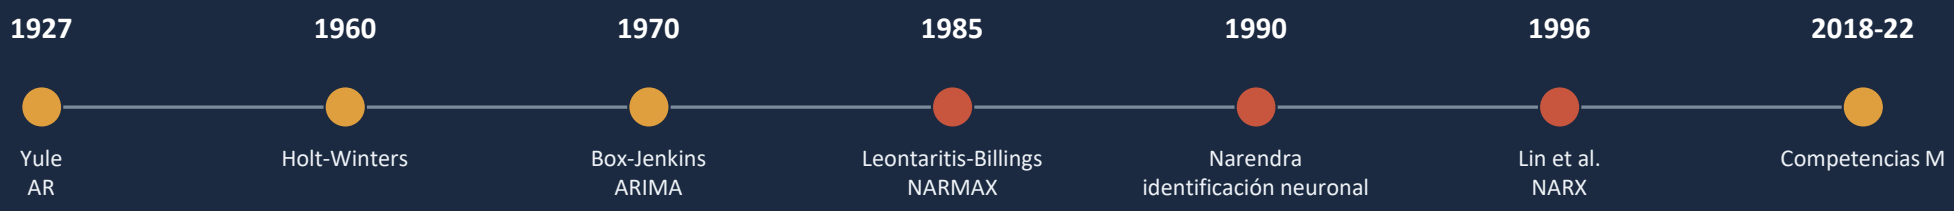
Series de tiempo: del modelo lineal a la red NARX

Métodos estadísticos clásicos y redes neuronales NAR/NARX · Sesión de 4 horas con taller práctico | ¿Cuándo una red no lineal supera de verdad a un modelo estadístico bien especificado?



Ruta de la sesión: cuatro horas, cuatro momentos

0:00	Apertura y conceptos previos	35 min
0:35	Momento 1 · Fundamentos teóricos	50 min
1:35	Momento 2 · Taller 1 en subgrupos	75 min
3:00	Momento 3 · Del laboratorio al mundo real	40 min
3:40	Momento 4 · Lanzamiento del Taller 2	20 min

Incluye dos pausas de 10 minutos (1:25 y 2:50)

PRODUCTOS

Hoy

Taller 1 ejecutado en clase: tabla de resultados por subgrupo

En 7 días

Taller 2: código + informe IEEE, entrega el viernes 30 de octubre

Conceptos previos: ¿qué es una serie de tiempo?

Serie de tiempo: mediciones de una misma variable ordenadas en el tiempo (demanda diaria, temperatura horaria)

El orden importa: el valor de hoy se parece al de ayer; no se puede barajar

Tendencia: dirección de largo plazo

Estacionalidad: patrón que se repite con periodo fijo (semana, año)

Ruido: variación que no se puede anticipar

Exógena: otra variable que influye (la temperatura sobre la demanda)

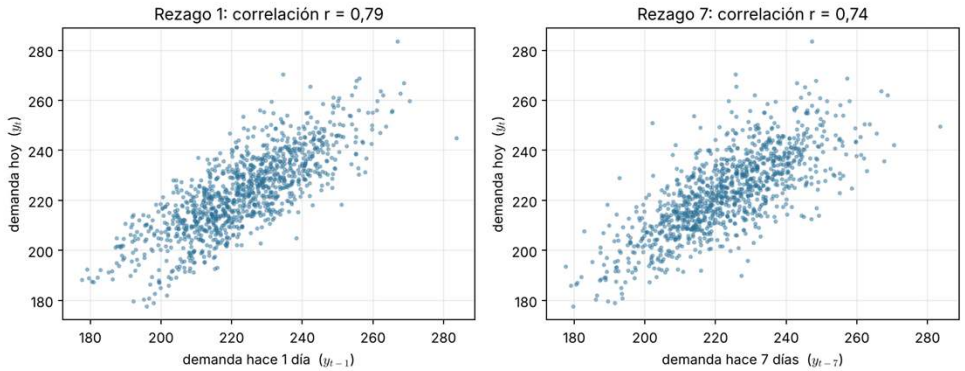


Conceptos previos: media, varianza, correlación y rezago

TRES MEDIDAS BÁSICAS

$$\bar{y} = \frac{1}{n}\sum_{t=1}^{n} y_t, \qquad s^2 = \frac{1}{n-1}\sum_{t=1}^{n}(y_t - \bar{y})^2$$

$$r_k = \mathrm{corr}(y_t,\ y_{t-k}) \in [-1,\ 1]$$



Media: nivel típico de la serie

Varianza: cuánto se aleja la serie de su media

Rezago k: comparar la serie con ella misma k pasos atrás

Autocorrelación: correlación entre y_t y y_{t-k}; cerca de 1 = el pasado ayuda a predecir

Conceptos previos: pronosticar y medir el error

PARTICIÓN EN EL TIEMPO



Entrenamiento: el modelo aprende

Validación: elegimos ajustes (cuándo parar de entrenar, qué configuración)

Prueba: examen final con datos nunca vistos

Fuga de información: usar el futuro para preparar el pasado; invalida la evaluación

RMSE

castiga más los errores grandes

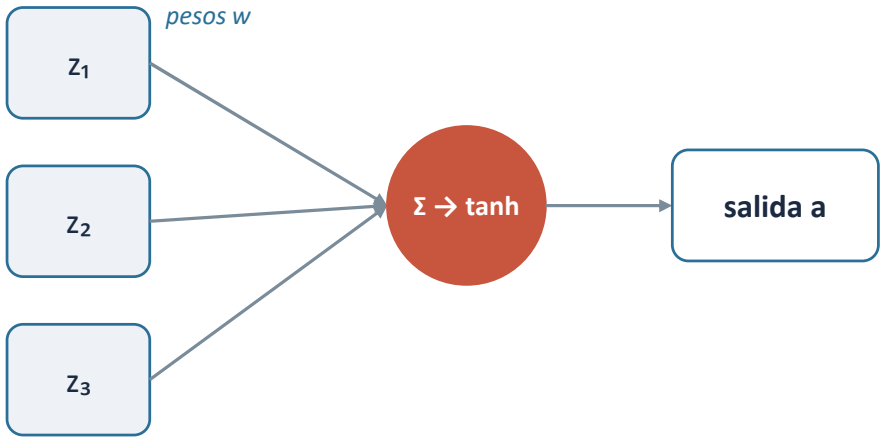
MAE

error promedio en las mismas unidades de la serie

ERROR DE PRONÓSTICO

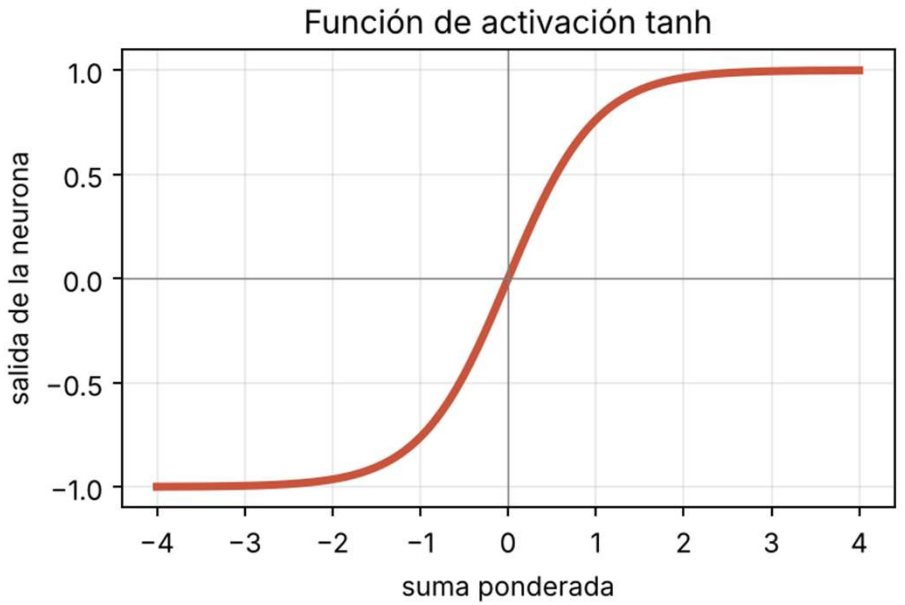
$$e_t = y_t - \hat{y}_t, \qquad \mathrm{MAE} = \tfrac{1}{T}\sum |e_t|, \qquad \mathrm{RMSE} = \sqrt{\tfrac{1}{T}\sum e_t^2}$$

Conceptos previos: una red neuronal en una diapositiva



UNA NEURONA

$$a = \tanh\left(w_1 z_1 + w_2 z_2 + \cdots + w_m z_m + b\right)$$



Muchas neuronas en capas aproximan relaciones curvas

Entrenar = ajustar los pesos para reducir el error, paso a paso

tanh deja pasar señales pequeñas casi sin cambio y satura las grandes en ±1: es lo que permite modelar curvas

La serie de tiempo como proceso estocástico

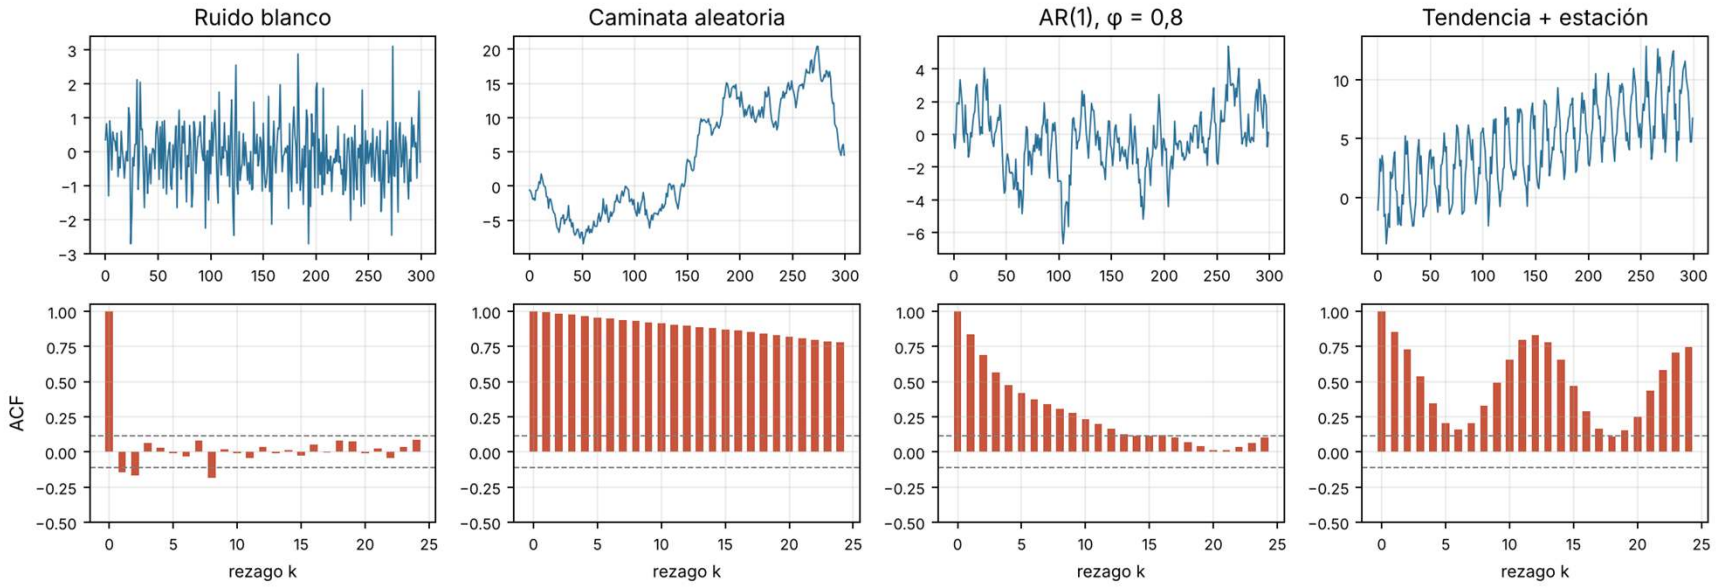
Observamos una sola realización $y_1,\ldots,y_n$ de un proceso $\{Y_t\}$

Estacionariedad débil: media, varianza y autocovarianza que dependen solo del rezago k

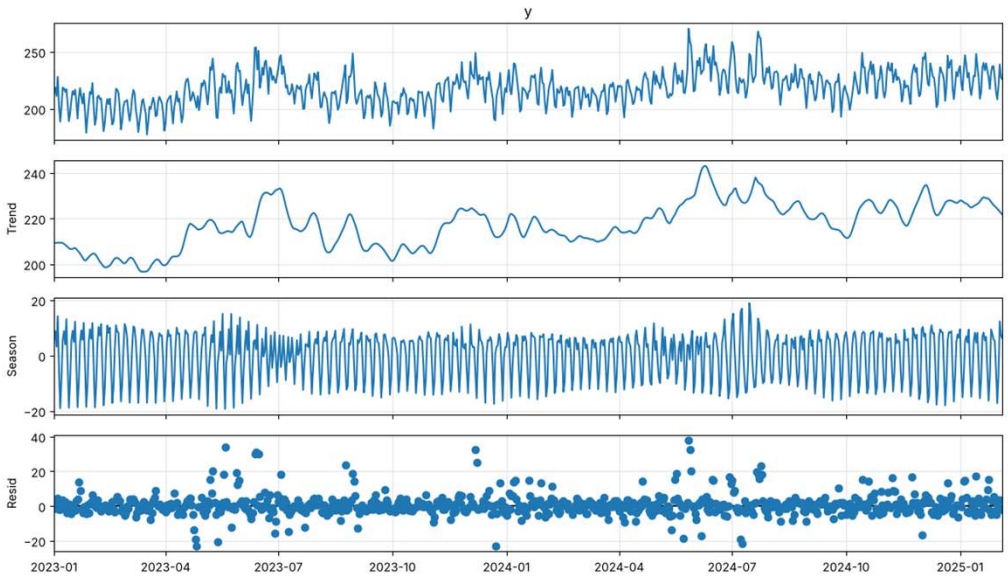
Ruido blanco: ρ(k) = 0 para k ≠ 0, la meta de todo residuo

MOMENTOS

$$\mathbb{E}[Y_t] = \mu, \quad \gamma(k) = \mathrm{Cov}(Y_t, Y_{t+k}), \quad \rho(k) = \gamma(k)/\gamma(0)$$



Diagnóstico: descomposición STL y raíz unitaria



FUERZA Y PRUEBA ADF

$$y_t = T_t + S_t + R_t, \qquad F_S = \max\left(0,\ 1 - \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(S_t + R_t)}\right)$$

$$\Delta y_t = \alpha + \beta t + \gamma\, y_{t-1} + \sum_{j=1}^{k} \delta_j \Delta y_{t-j} + \varepsilon_t, \qquad H_0 : \gamma = 0$$

DECISIÓN CONJUNTA ADF / KPSS

ADF rechaza H_0	KPSS rechaza H_0	Conclusión
Sí	No	Estacionaria
No	Sí	Raíz unitaria: diferenciar
Sí	Sí	Estacionaria en tendencia
No	No	Datos insuficientes

Modelos AR, MA y ARMA

FORMA GENERAL ARMA

$$\phi(B)\, y_t = c + \theta(B)\, \varepsilon_t$$

$$\phi(B) = 1 - \sum_{i=1}^{p} \phi_i B^i, \qquad \theta(B) = 1 + \sum_{j=1}^{q} \theta_j B^j$$

Estacionariedad: raíces de ϕ(z) fuera del círculo unitario

Invertibilidad: raíces de θ(z) fuera del círculo unitario

Analogía: AR es un filtro IIR y MA un filtro FIR; la estabilidad del filtro es la estacionariedad

FIRMAS PARA IDENTIFICAR

Modelo	ACF	PACF
AR(p)	Decae (exponencial o sinusoidal)	Se corta en p
MA(q)	Se corta en q	Decae
ARMA(p,q)	Decae desde q	Decae desde p

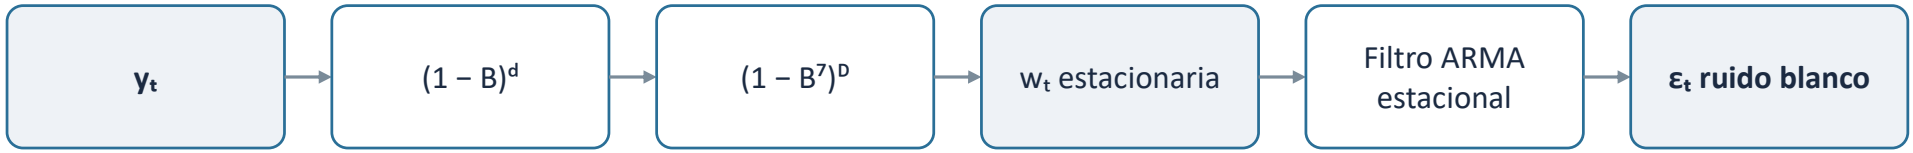
φ(B) / θ(B)

Polinomios que filtran la serie: IIR para AR, FIR para MA

ARIMA y SARIMA multiplicativo

SARIMA MULTIPLICATIVO

$$\phi_p(B)\,\Phi_P(B^s)\,(1-B)^d(1-B^s)^D\,y_t = c + \theta_q(B)\,\Theta_Q(B^s)\,\varepsilon_t$$

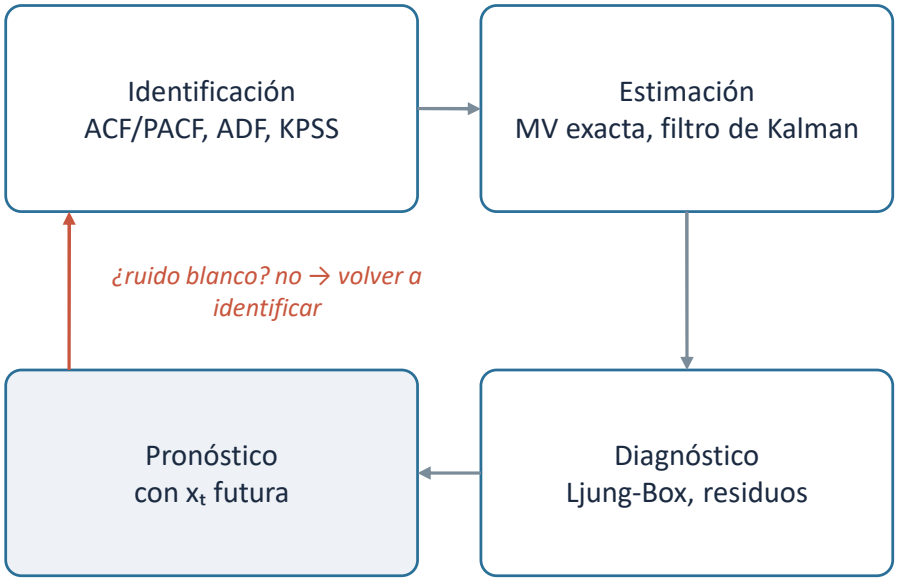


d y D: diferencias que vuelven estacionaria la serie; la estructura multiplicativa crea interacciones en rezagos s ± 1

Sobrediferenciar introduce una raíz unitaria en la parte MA (θ ≈ −1)

Taller 1: SARIMA(2,0,1)(1,1,1)$_7$ con $\Theta_1 \approx -1$, ¿sobrediferenciación estacional?

SARIMAX: estimación, selección y validación



SELECCIÓN Y VALIDACIÓN

$$\mathrm{AIC} = -2\log \hat{L} + 2k, \qquad \mathrm{BIC} = -2\log \hat{L} + k\log n$$

$$Q_{LB} = n(n+2)\sum_{k=1}^{m} \frac{\hat{\rho}_k^2}{n-k} \sim \chi^2_{m-p-q}$$

p > 0,30

Ljung-Box de residuos SARIMAX en los rezagos 7, 14 y 21

β ≈ 0,43

Efecto lineal estimado de la temperatura (el verdadero es parabólico)

$y_t = \beta^T x_t + \eta_t$, con $\eta_t \sim$ SARIMA: la exógena entra de forma lineal

Suavizamiento exponencial y Holt-Winters (ETS)

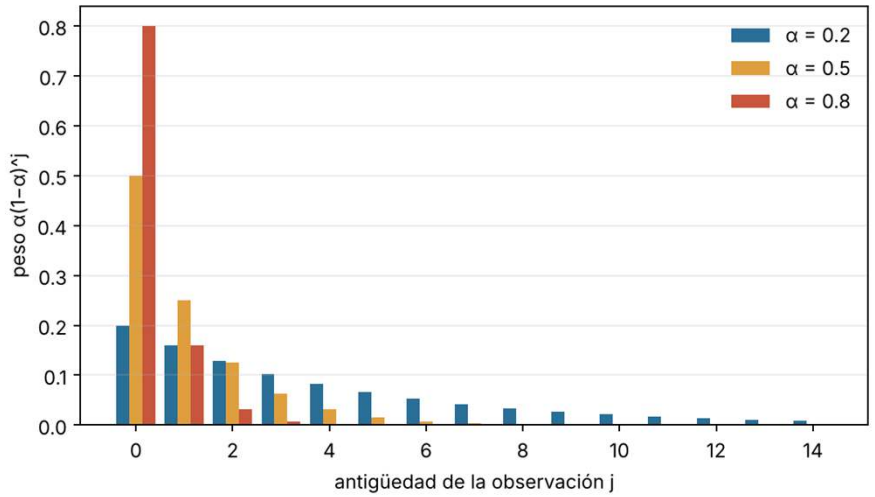
ECUACIONES DE ESTADO

$$\ell_t = \alpha(y_t - s_{t-m}) + (1-\alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)\, b_{t-1}$$

$$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1-\gamma)\, s_{t-m}$$

$$\hat{y}_{t+h|t} = \ell_t + h\, b_t + s_{t+h-m(k+1)}$$



Formulación en espacio de estados con innovaciones: verosimilitud, AIC e intervalos

Varios ETS lineales equivalen a casos particulares de ARIMA

$\alpha \approx 0{,}83$

El nivel se adapta rápido

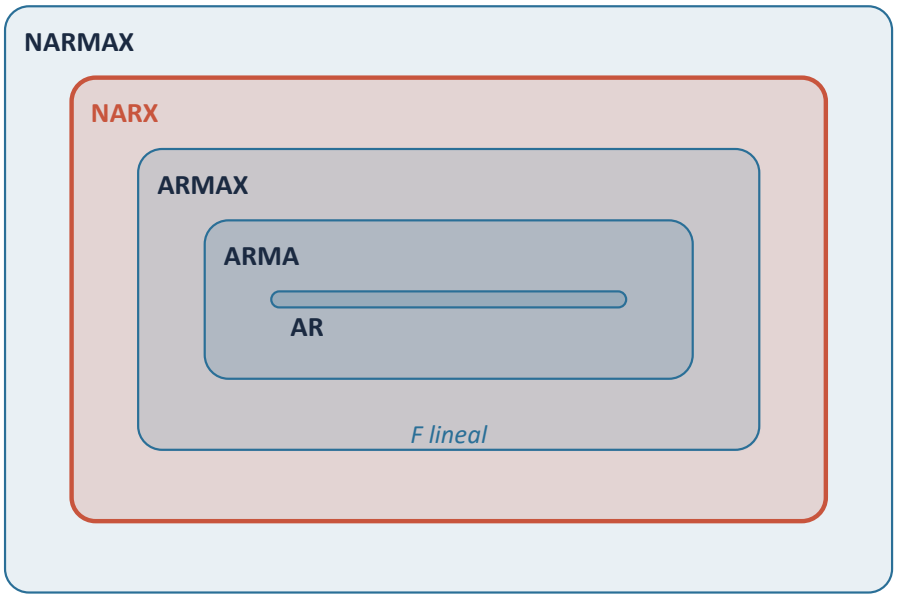
$\gamma \approx 0$

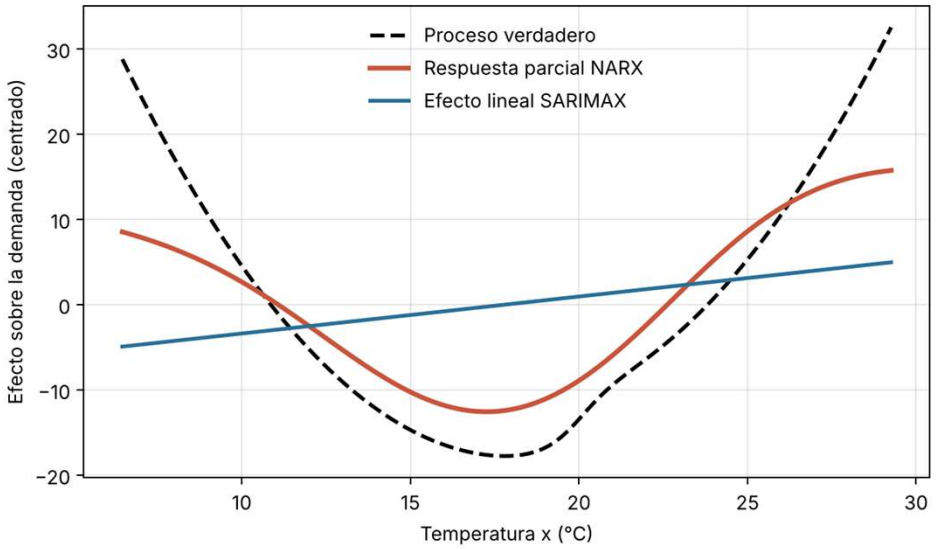
Patrón semanal fijo; no usa la temperatura

Del mundo lineal al no lineal: NARMAX

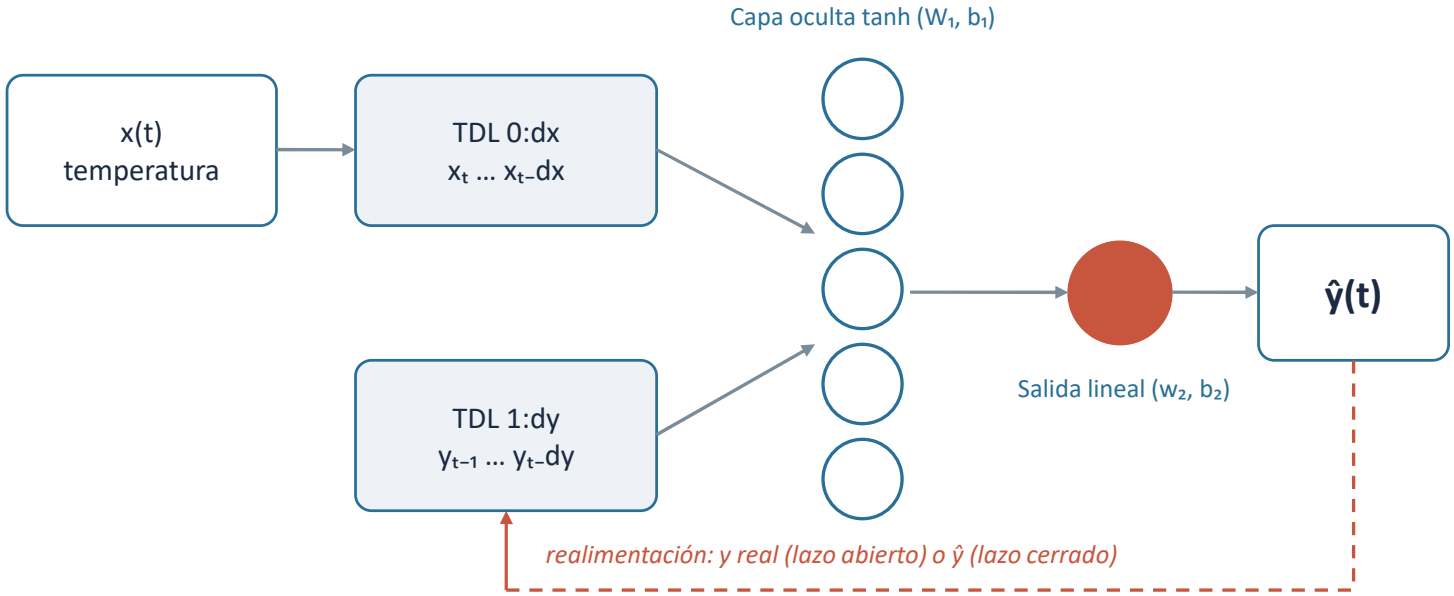
NARMAX

$$y_t = F(y_{t-1}, \ldots, y_{t-d_y},\ x_t, \ldots, x_{t-d_x},\ \varepsilon_{t-1}, \ldots) + \varepsilon_t$$





Arquitecturas NAR y NARX



REGRESORES Y SALIDA

$$\mathbf{z}_t = [\, y_{t-1}, \ldots, y_{t-d_y} \,|\, x_t, \ldots, x_{t-d_x} \,]^\top$$

$$\hat{y}_t = \mathbf{w}_2^\top \, \sigma(\mathbf{W}_1 \mathbf{z}_t + \mathbf{b}_1) + b_2$$

229

parámetros de la NARX del taller frente a 8 del SARIMAX

NAR: solo retardos de y

NARX: añade la exógena x y sus retardos

Retardos candidatos: los de PACF significativa

Lazo abierto vs. lazo cerrado

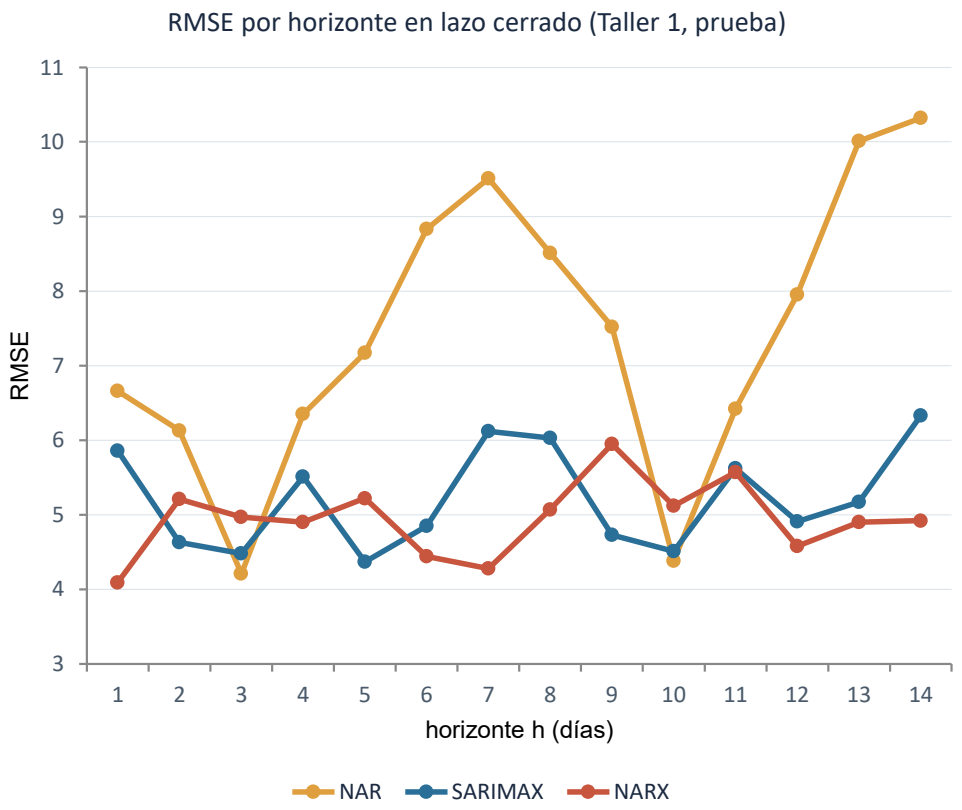
Lazo abierto (serie-paralelo)
entradas con y real · regresión estática
entrenamiento estable (teacher forcing)

Lazo cerrado (paralelo)
entradas con ŷ previas · pronóstico
multipaso recursivo: el error se acumula

RECURSIÓN

$$\hat{y}_{t+h} = f(\hat{y}_{t+h-1}, \ldots, \hat{y}_{t+1}, y_t, \ldots; x_{t+h}, \ldots)$$

Alternativas: estrategia directa (un modelo por h) y MIMO



Entrenamiento: optimización, regularización y no fuga

PÉRDIDA Y LEVENBERG-MARQUARDT

$$\mathcal{L}(\mathbf{W}) = \frac{1}{N}\sum_{t}(y_t - \hat{y}_t)^2 + \lambda\|\mathbf{W}\|_2^2$$

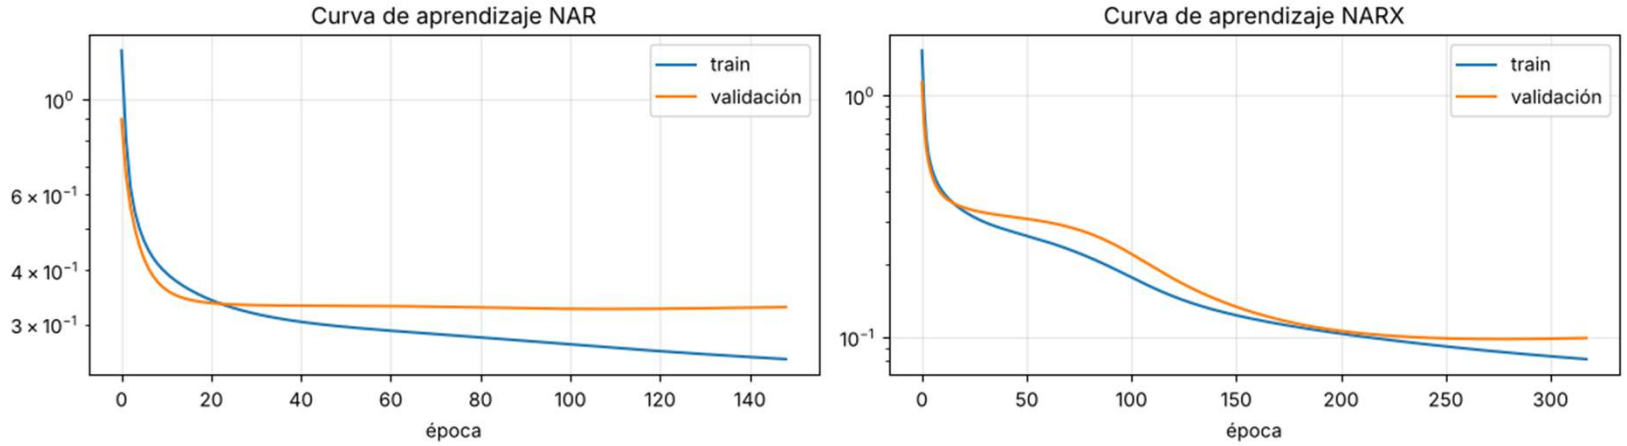
$$\Delta\mathbf{W} = -(\mathbf{J}^\top\mathbf{J} + \mu\mathbf{I})^{-1}\mathbf{J}^\top\mathbf{e}$$

Python: Adam + L2 + parada temprana

MATLAB: trainlm (LM) o trainbr (bayesiana)

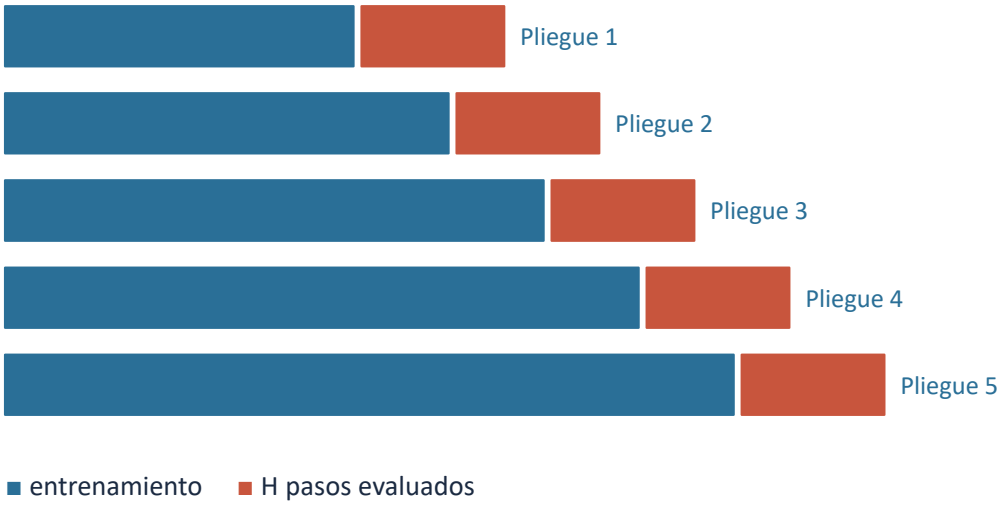
Reinicios: la pérdida no es convexa; val_loss de 0,10 a 0,33 entre semillas

Sin fuga: escalado y tendencia solo con train; desactivar mapminmax interno



Evaluación rigurosa de pronósticos

VALIDACIÓN DE ORIGEN MÓVIL



MASE Y DIEBOLD-MARIANO

$$\mathrm{MASE} = \mathrm{MAE} \;/\; \left(\frac{1}{n-s} \sum_{t=s+1}^{n} |y_t - y_{t-s}| \right)$$

$$DM^{*} = \frac{\bar{d}}{\sqrt{\hat{\gamma}_0 / T}} \sqrt{\frac{T+1-2h+h(h-1)/T}{T}}, \qquad d_t = e_{1,t}^2 - e_{2,t}^2$$

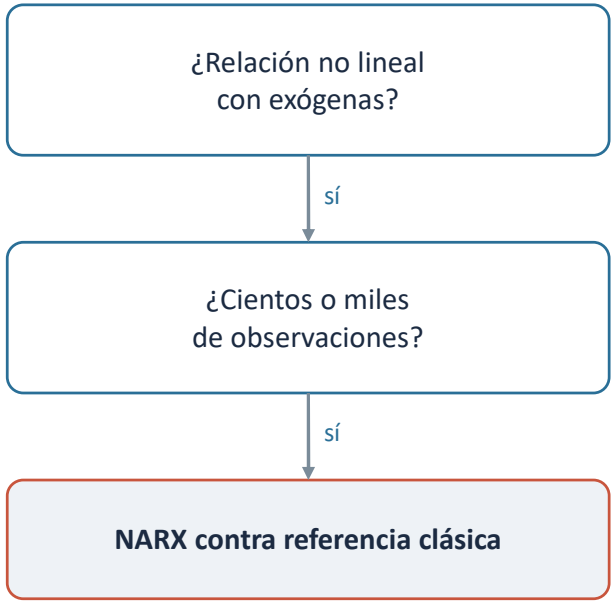
Comparación (h = 1)	DM*	p	Resultado
SARIMAX vs NARX	3,08	0,002	NARX mejor
NAR vs NARX	6,08	< 0,001	NARX mejor
Holt-Winters vs SARIMAX	0,52	0,60	Sin diferencia

Nunca barajar el eje del tiempo; MAPE es inestable cerca de cero

MASE < 1: mejor que el ingenuo estacional

Síntesis y paso al Taller 1

Criterio	SARIMAX / ETS	NAR / NARX
Forma de F	Lineal, especificada	No lineal, aprendida
Parámetros	Pocos (8–12)	Cientos (≈ 200)
Interpretabilidad	Alta: coeficientes e IC	Baja: requiere XAI
Incertidumbre	Intervalos analíticos	Bootstrap, ensambles, conformal
Datos necesarios	Pocos	Muchos
Riesgo principal	Sesgo de especificación	Sobreajuste, fuga, inestabilidad



si no: SARIMAX/ETS con ingeniería de variables

CONSIGNA DEL TALLER 1

Ejecutar el cuaderno, cambiar un parámetro de la celda 0 y defender una conclusión con Diebold-Mariano (75 min en salas)

Taller 1 en subgrupos: 75 minutos

1. Abrir el cuaderno en Google Colab (CPU)
2. Ejecutar todo con la configuración base (≈ 4 min)
3. Cambiar solo la celda 0 según su subgrupo
4. Volver a ejecutar y copiar la tabla final
5. Preparar 3 minutos de conclusiones con Diebold-Mariano

Subgrupo	Cambio en la celda 0	Pregunta
1	EXOG_CUADRATICA = True	¿La ingeniería de variables iguala a NARX?
2	NO_LINEALIDAD = 0.0	Si el proceso es lineal, ¿gana la red?
3	DY ∈ {3, 7, 14, 28}	¿Cuánta memoria necesita la red?
4	NEURONAS y L2	¿Cuándo aparece el sobreajuste?
5	SIGMA_RUIDO ∈ {1, 3, 6}	¿Resiste la ventaja con más ruido?
6	QUITAR_TENDENCIA = False	¿Por qué la red no extrapola?
7	SEMILLA ∈ {1,…,5}	¿Es robusta la diferencia?

Lo que el laboratorio ocultó

4,08 vs 5,32

RMSE a un paso: NARX frente a SARIMAX

p = 0,002

Diebold-Mariano: diferencia significativa

p = 0,0018

Ljung-Box residuos NARX (rezago 14): queda estructura

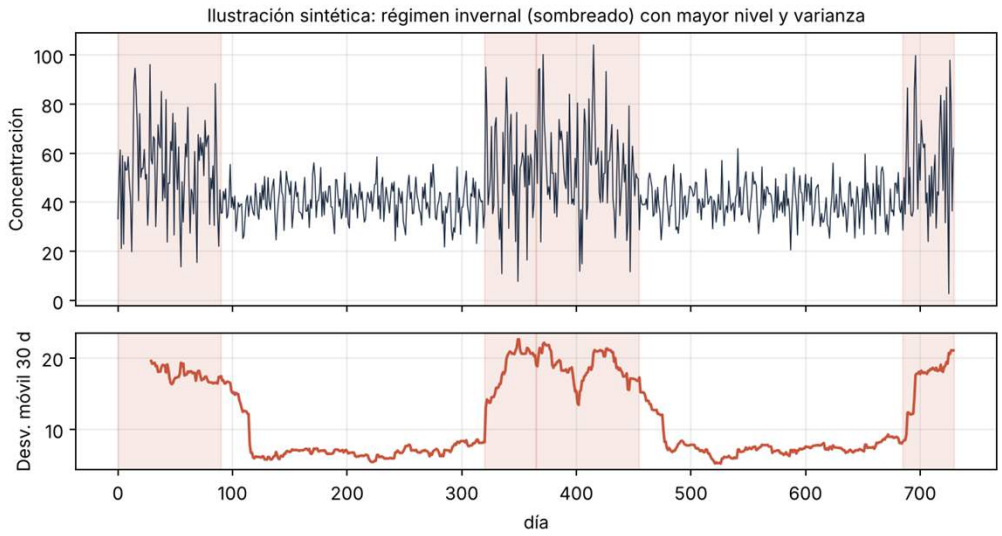
Supuesto del laboratorio	Realidad	Consecuencia
Proceso generador conocido	Proceso desconocido y cambiante	Regímenes, deriva
x futura conocida	x pronosticada con error	Ventaja de NARX sobreestimada
Serie completa y limpia	Faltantes y atípicos	Imputación sin fuga
Una sola serie	Miles de series	Costo y modelos globales

No estacionariedad y cambio de régimen

Tipos: raíz unitaria, quiebre estructural, deriva de concepto (cambia p(y|x)), heterocedasticidad

Respuestas clásicas: diferenciación, Box-Cox, indicadoras de régimen, GARCH

Respuestas neuronales: ventana deslizante, reentrenamiento periódico, normalización por ventana



TRANSFORMACIÓN BOX-COX

$$y_t^{(\lambda)} = (y_t^{\lambda} - 1)/\lambda \quad (\lambda \neq 0), \qquad y_t^{(0)} = \log y_t$$

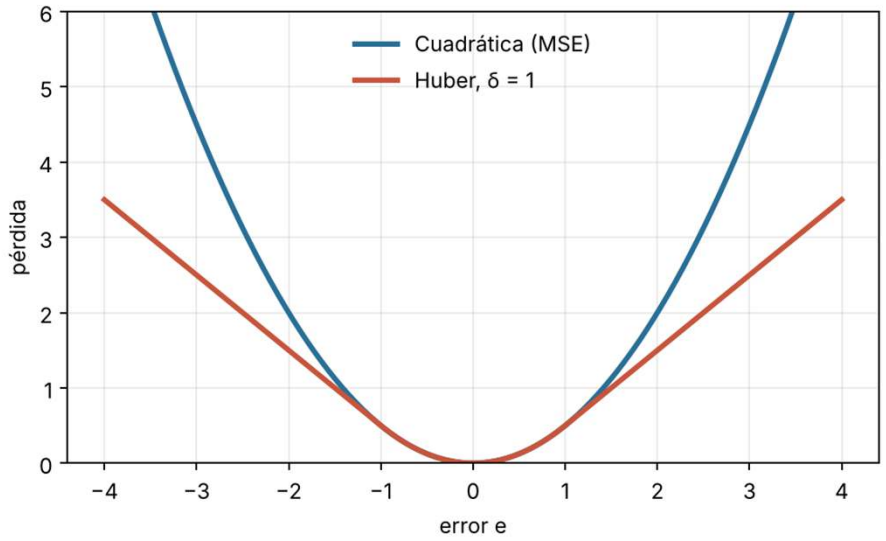
Ruido, atípicos y datos faltantes

Faltantes: interpolación temporal local; nunca imputar con estadísticos de toda la serie

Atípicos: STL robusta, recorte por cuantiles de train, pérdida de Huber

Ruido en la exógena: atenúa el efecto estimado

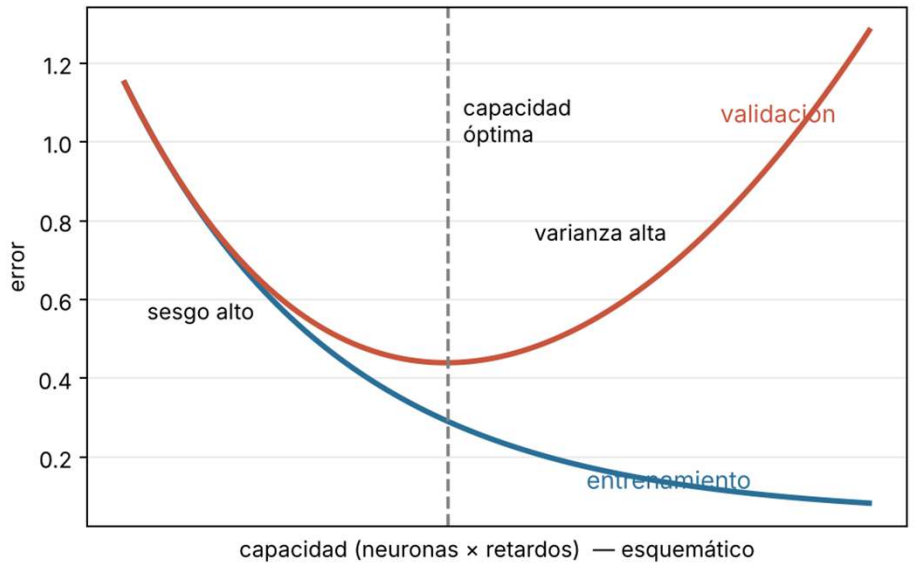
Reporte RMSE y MAE: RMSE castiga los picos, MAE no



PÉRDIDA DE HUBER

$$\ell_\delta(e) = \tfrac{1}{2}e^2 \quad \text{si } |e| \le \delta; \qquad \delta(|e| - \tfrac{1}{2}\delta) \quad \text{si } |e| > \delta$$

Sobreajuste y las trampas de la evaluación



DESCOMPOSICIÓN DEL ERROR

$$\mathbb{E}[(y-\hat{f})^2] = (f-\mathbb{E}\hat{f})^2 + \mathrm{Var}(\hat{f}) + \sigma^2$$

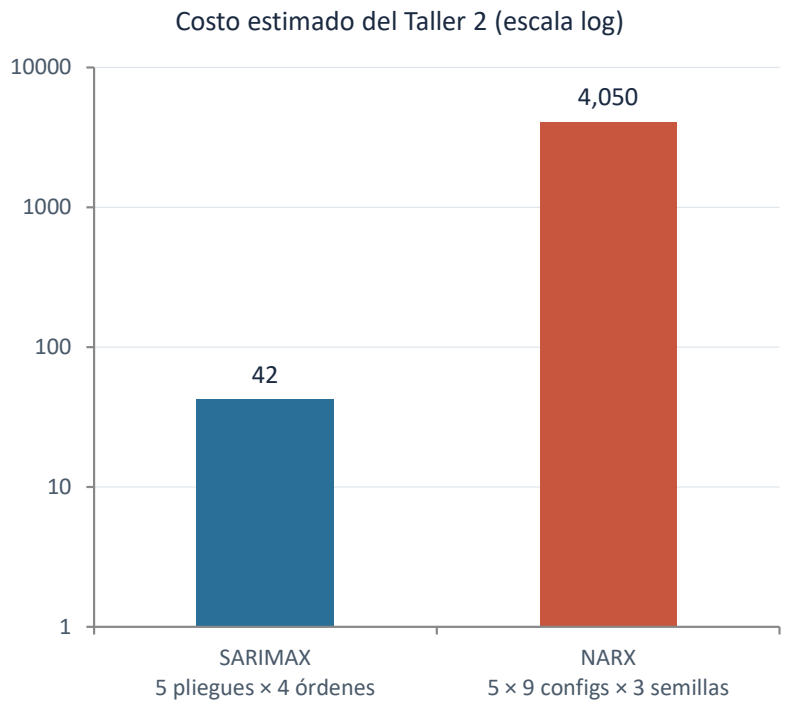
FUGAS TÍPICAS

1. Escalar o quitar tendencia con toda la serie
2. Elegir hiperparámetros mirando la prueba
3. Barajar antes de partir en el tiempo
4. Usar una x futura que no estará disponible
5. Reportar la mejor de 50 configuraciones

Regla de oro: la prueba externa se toca una sola vez

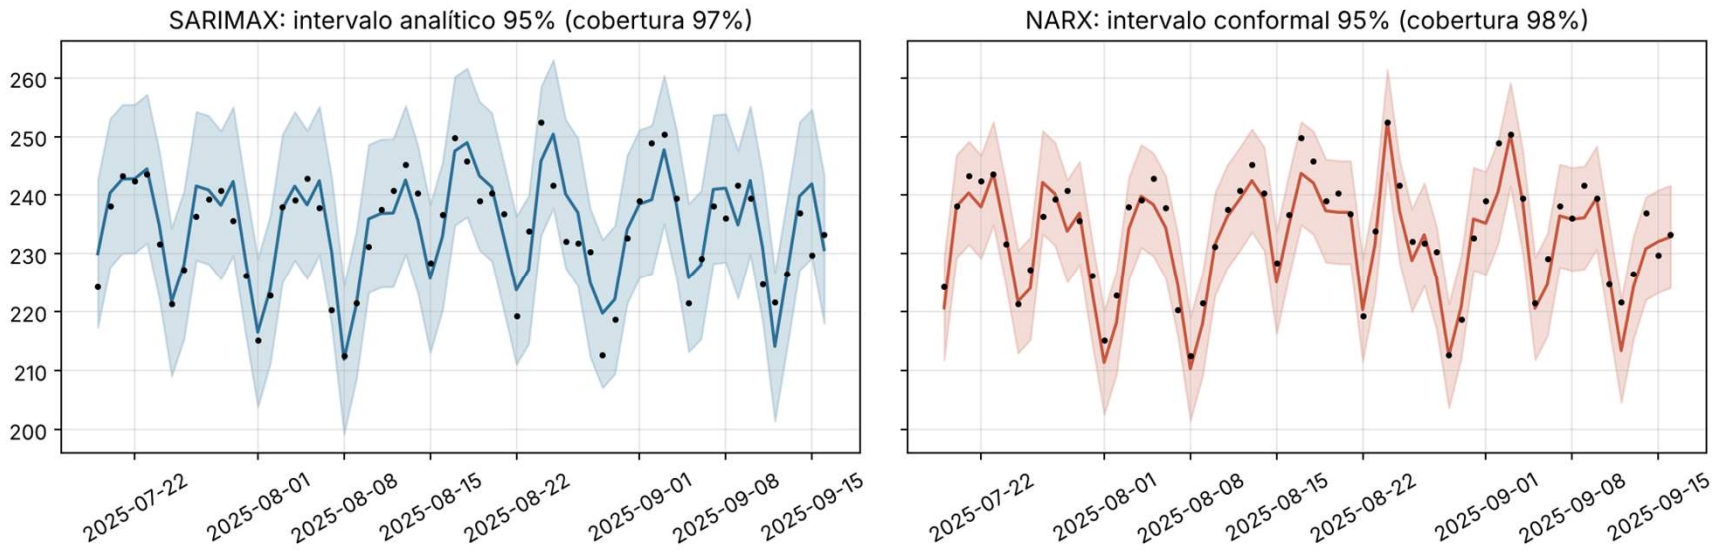
Costo computacional y escalabilidad

Aspecto	SARIMAX	NAR / NARX (MLP)
Ajuste en el Taller 1	≈ 2 s	≈ 20–45 s por reinicio (CPU)
Costo por iteración	Kalman, lineal en n	Retropropagación, lineal en n × W
Levenberg-Marquardt	—	Memoria O(W^2)
Miles de series	Un modelo por serie	Un modelo global
Búsqueda	Rejilla pequeña por AIC	Rejilla × reinicios × pliegues



5 × 9 × 3 = 135 entrenamientos ≈ más de 1 hora en Colab

Interpretabilidad, incertidumbre y ética



INTERVALO CONFORMAL

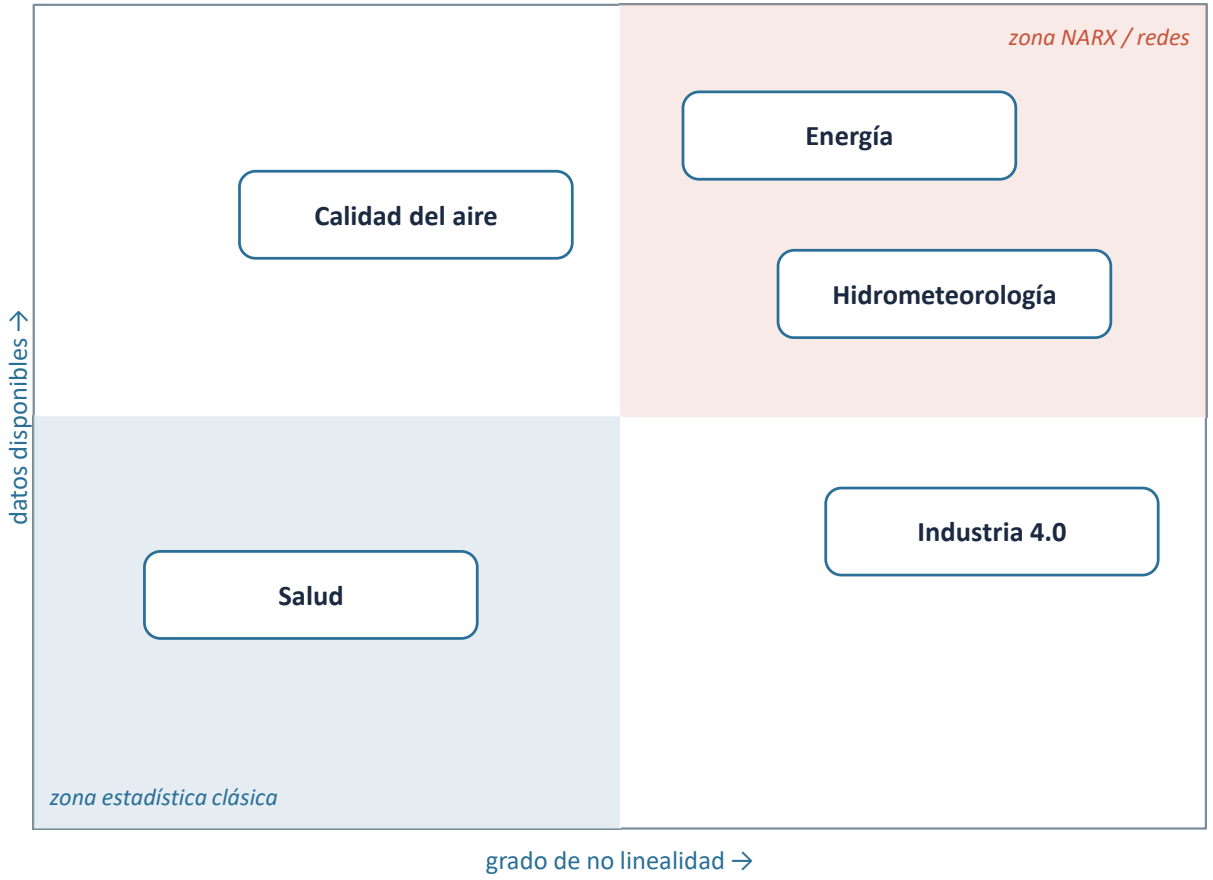
$$\hat{C}_{1-\alpha}(t) = [\,\hat{y}_t - \hat{q}_{1-\alpha},\ \hat{y}_t + \hat{q}_{1-\alpha}\,]$$

SARIMAX: coeficientes con error estándar e intervalos analíticos

NARX: respuesta parcial o SHAP; incertidumbre por bootstrap, ensambles o conformal

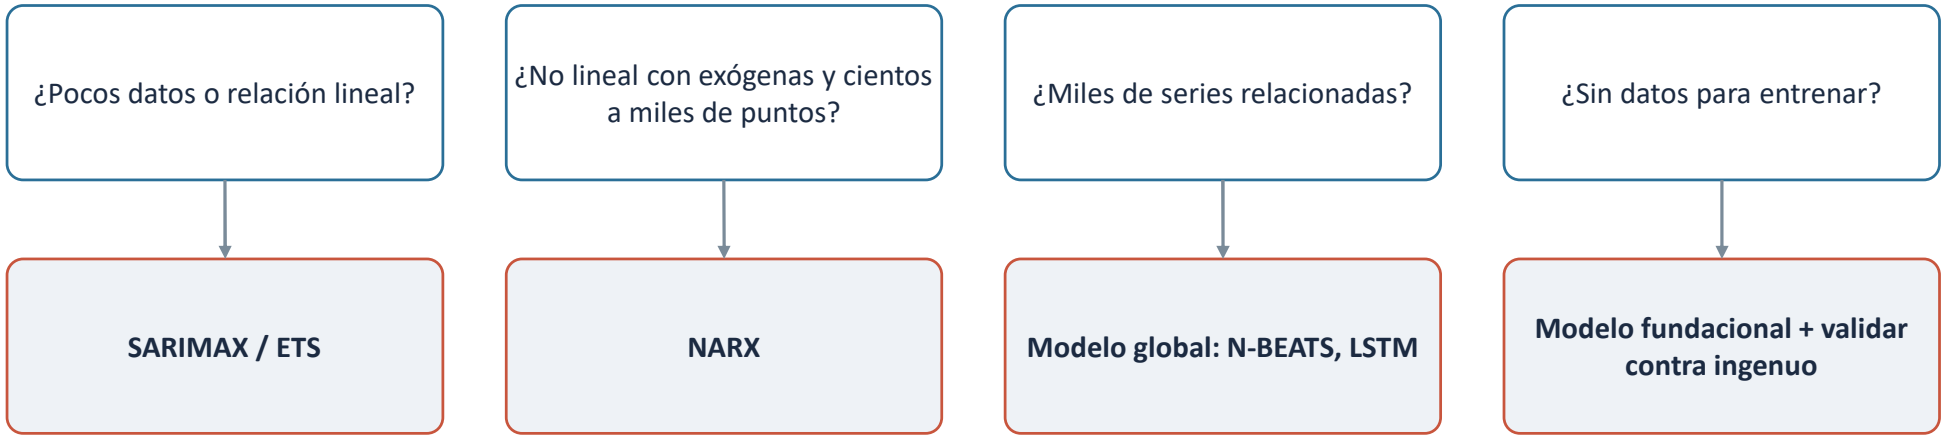
Ética: ¿quién asume el costo del error? sesgos, privacidad, reproducibilidad

Casos de aplicación industrial y académica



Dominio	Desafío dominante
Energía	Varias estacionalidades, festivos
Calidad del aire	Heterocedasticidad, faltantes
Hidrometeorología	No linealidad lluvia-escorrentía
Salud	Variabilidad entre sujetos
Industria 4.0	Deriva, mantenimiento predictivo

Más allá de NARX: cuándo sí y cuándo no



LSTM/GRU: memoria con compuertas; NARX ya mitiga dependencias largas con sus retardos de salida (Lin et al., 1996)

N-BEATS: neuronal e interpretable; superó a los estadísticos en M4

Transformers: modelos lineales simples los superan en varias tareas de largo plazo (Zeng et al., 2023)

Chronos (2024): pronóstico sin entrenamiento específico; la referencia clásica sigue siendo obligatoria

Taller 2: siete días, código e informe



RETO

Benchmark de un modelo clásico y una red NAR/NARX sobre una serie real

MÍNIMOS

Origen móvil ≥ 5 pliegues, sensibilidad ≥ 2 hiperparámetros, Diebold-Mariano, residuos

ENTREGA

Informe IEEE de 6–8 páginas + cuaderno o script ejecutado

EVALUACIÓN

Rúbrica de 5 criterios (100 puntos) en Google Classroom

Tres ideas para llevar

1. El modelo clásico es la referencia obligatoria: la red debe ganarle con evidencia estadística.
2. Sin una evaluación en el tiempo y sin fugas, ninguna cifra es confiable.
3. La complejidad se justifica con datos, costo e interpretación, no por moda.