Modelo clásico frente a redes NAR y NARX

Pronóstico de PM2.5 diario en Beijing con validación de origen móvil y prueba de Diebold-Mariano

Taller 6 – Informe

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 11 de noviembre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

1. Introducción

El objetivo del taller es comparar un modelo estadístico clásico con una red neuronal autorregresiva no lineal sobre una serie real, y decidir con evidencia estadística si la red pronostica mejor. Usé la plantilla del curso, que ya trae la carga, la validación del conjunto, el diagnóstico, la validación cruzada de origen móvil, las métricas, el análisis de residuos y la prueba de Diebold-Mariano. Resolví sus tres `TODO-EQUIPO`: `modelo_clasico`, `modelo_neuronal` y `REJILLAS`. No modifiqué el motor de evaluación y ejecuté la prueba externa una sola vez, al final. Desarrollé solo la versión en Python; la versión en MATLAB no la hice porque no tengo MATLAB.

Elegí el conjunto *Beijing Multi-Site Air Quality* (UCI), estación Aotizhongxin: la contaminación por partículas finas PM2.5 se relaciona físicamente con el clima (el viento la dispersa), que es el escenario en que una NARX con variables exógenas debería aportar. El uso de inteligencia artificial se declara en la sección 8.

2. Marco teórico

Estacionariedad y estacionalidad. La prueba ADF tiene como hipótesis nula una raíz unitaria y la KPSS, estacionariedad; usarlas juntas evita decidir con una sola. La descomposición STL separa tendencia, estacionalidad y residuo, y la fuerza estacional $F_S = \max\{0,\ 1 - \mathrm{Var}(R)/\,\mathrm{Var}(S+R)\}$ mide qué tan marcado es el ciclo, con s el número de pasos de un periodo (aquí $s = 7$ días).

SARIMAX. Un modelo SARIMAX$(p,d,q)(P,D,Q)_s$ combina una parte autorregresiva de orden p, d diferencias, una media móvil de orden q, sus análogos estacionales y regresores exógenos lineales $\beta^\top x_t$. El orden se elige con los criterios de información

$$\mathrm{AIC} = 2k - 2\ln L, \qquad \mathrm{BIC} = k\ln n - 2\ln L,$$

que premian la verosimilitud L y castigan los k parámetros (BIC con más fuerza). La prueba de Ljung-Box verifica si a los residuos les queda autocorrelación.

NAR y NARX. Una red NAR aproxima $y_t = f(y_{t-1}, \ldots, y_{t-d_y}) + \varepsilon_t$ con un perceptrón multicapa; la NARX agrega las exógenas, $f(y_{t-1}, \ldots, y_{t-d_y},\ x_t, \ldots, x_{t-d_x})$. Se entrena en **lazo abierto**, con los retardos reales como entradas, y pronostica en **lazo cerrado**: cada pronóstico vuelve como retardo del paso siguiente, por lo que el error puede acumularse con el horizonte (figura 1).

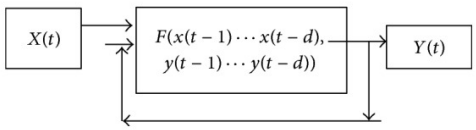


Figura 1: Estructura de una NARX: la salida $Y(t)$ se calcula con los retardos de la entrada $X(t)$ y de la propia salida, que se realimenta (Manikandan y Subha, 2016, CC BY).

Origen móvil. La validación de series de tiempo nunca baraja el orden: cada pliegue entrena solo con lo anterior a su origen y evalúa los H pasos siguientes (figura 2; Bergmeir y Benítez, 2012; Hyndman y Athanasopoulos, 2021).

Evaluación. Con errores $e_t = y_t - \hat{y}_t$, se usan $\mathrm{RMSE} = \sqrt{\overline{e^2}}$, $\mathrm{MAE} = \overline{|e|}$ y el error absoluto escalado $\mathrm{MASE} = \mathrm{MAE}/\mathrm{MAE}_{\text{ingenuo}}$, donde el denominador es el error del ingenuo estacional $\hat{y}_t = y_{t-s}$ en el desarrollo; $\mathrm{MASE} < 1$ indica un modelo mejor que repetir la semana anterior. La prueba de Diebold-Mariano contrasta $H_0 : \mathrm{E}[d_t] = 0$ con $d_t = e_{1,t}^2 - e_{2,t}^2$, con la varianza corregida por la autocorrelación hasta el horizonte h y el ajuste de Harvey, Leybourne y Newbold para muestras pequeñas.

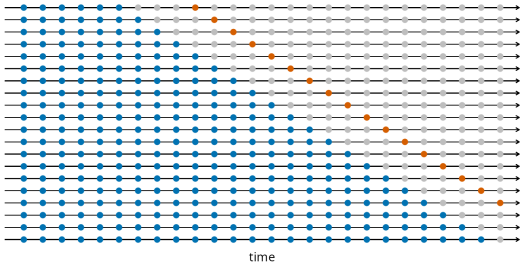


Figura 2: Evaluación de origen móvil con pronóstico de varios pasos: en cada fila, los puntos azules entrenan y el naranja se evalúa; los grises quedan sin usar (adaptado de Hyndman y Athanasopoulos, 2021, §5.10, CC BY-NC-SA 4.0). En el taller el horizonte es de 24 días.

3. Metodología

Datos. La plantilla promedia por día los registros horarios de marzo de 2013 a febrero de 2017 (1461 días) y rellena por interpolación temporal los 15 días sin PM2.5. La serie objetivo es PM2.5 en μg/m^3 y las exógenas son temperatura (TEMP), punto de rocío (DEWP), presión (PRES) y velocidad del viento (WSPM). Cumple los criterios C1 a C6 de la plantilla. La partición es temporal: 1168 días de desarrollo (80 %) y 293 de prueba externa (20 %). Como en el taller resuelto en clase, el clima de los días a pronosticar se toma como conocido.

Validación. El motor usa origen móvil con ventana expandible: 5 orígenes repartidos en el último 40 % del desarrollo y horizonte $H = 24$ días; cada pliegue entrena con todo lo anterior a su origen. La prueba externa usa 12 orígenes sobre los 293 días finales. Todos los modelos cumplen el mismo contrato `pronosticar(y_hist, X_hist, X_fut, H, **hp)` y todo lo que depende de los datos se ajusta dentro de cada llamada, solo con `y_hist` y `X_hist`.

Modelo clásico. PM2.5 es positiva y muy asimétrica (asimetría 1,77 en el desarrollo), así que modelé $z_t = \log(1 + y_t)$, que la reduce a $-0{,}28$, y devolví $\exp(\hat{z}) - 1$. Las pruebas ADF y KPSS indicaron una serie estacionaria en nivel ($d = 0$) y la STL una estacionalidad semanal débil ($F_S = 0{,}07$). Comparé con AIC y BIC los órdenes $p, q \in \{0, 1, 2\}$ con y sin término estacional $(1, 0, 1)_7$, con constante y las cuatro exógenas.

Red neuronal. Implementé una NARX en Keras: entradas $y_{t-1}, \ldots, y_{t-d_y}$ y las cuatro exógenas en t, $t-1$ y $t-2$ ($d_x = 2$); una capa oculta `tanh` con regularización L2 (10^{-4}) y una salida lineal; Adam con tasa 10^{-3}, lotes de 32 y hasta 300 épocas con parada temprana (paciencia 20, con los mejores pesos) sobre el 15 % final de la historia. La serie se transforma con $\log(1 + y)$ y se estandariza con la media y la desviación de `y_hist`; las exógenas, con las de `X_hist`. La NAR es la misma función sin exógenas.

Sensibilidad. La rejilla del clásico recorre $p \in \{1, 2, 3\} \times q \in \{0, 1, 2\}$; la de la red, $d_y \in \{7, 14, 28\} \times$ neuronas $\in \{5, 10, 20\} \times$ semilla $\in \{1, 2, 3\}$, es decir 27 configuraciones y 135 entrenamientos. Para la red promedié el RMSE de validación sobre las tres semillas y elegí la combinación de menor media. Los hiperparámetros se eligieron solo con la validación cruzada, antes de mirar la prueba externa.

4. Resultados

4.1. Identificación del clásico

La tabla 1 resume los mejores órdenes. AIC y BIC eligen el mismo modelo, ARIMAX$(1, 0, 1)$ sin parte estacional, coherente con $F_S = 0{,}07$.

Tabla 1: Mejores órdenes según AIC sobre el desarrollo (con constante y exógenas, $s = 7$).

Orden	Estacional	AIC	BIC
$(1,0,1)$	$(0,0,0)_7$	**1991,2**	**2031,7**
$(1,0,2)$	$(0,0,0)_7$	2003,7	2049,3
$(1,0,2)$	$(1,0,1)_7$	2006,4	2062,1

Los coeficientes del modelo elegido tienen el signo esperado: el punto de rocío sube la contaminación ($+0{,}110$, con $p < 0{,}001$), mientras el viento ($-0{,}123$) y la temperatura ($-0{,}061$) la bajan; la presión no resulta significativa ($p = 0{,}58$). La parte ARMA es $\phi_1 = 0{,}854$ y $\theta_1 = -0{,}352$. Aun así, Ljung-Box rechaza la ausencia de autocorrelación en los residuos en los rezagos 7, 14 y 21: queda estructura que un modelo lineal no captura.

4.2. Validación cruzada

La tabla 2 compara los modelos en los 5 pliegues, con los hiperparámetros iniciales ($p = q = 1$; $d_y = 14$ y 10 neuronas) y con los elegidos por la rejilla.

Tabla 2: Validación cruzada de origen móvil (5 pliegues, $H = 24$). RMSE y MAE en μg/m^3.

	Iniciales		Elegidos	
Modelo	RMSE	MASE	RMSE	MASE
Ingenuo estacional	110,53	1,005	110,53	1,005
Clásico (ARIMAX)	52,50	0,521	52,50	0,521
NARX	43,33	0,421	42,81	0,446
NAR	59,75	0,608	61,38	0,622

4.3. Sensibilidad

En el clásico, el mejor orden de la rejilla vuelve a ser $p = 1$, $q = 1$ (RMSE medio 50,66), el mismo que eligieron AIC y BIC. En la red (figura 3), la mejor combinación es $d_y = 7$ con 20 neuronas: RMSE medio de 38,80 con desviación de 0,20 entre semillas. El factor que más mueve el error son los retardos: con $d_y = 28$ el RMSE sube a entre 45 y 50, mientras que con d_y fijo cambiar el número de neuronas lo mueve entre 1 y 5 puntos. La semilla también pesa: con $d_y = 28$ y 5 neuronas la desviación entre semillas llega a 7 puntos, lo que justifica promediar.

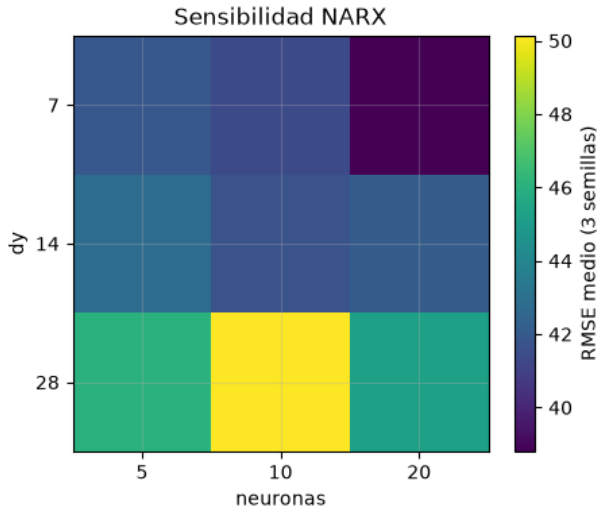


Figura 3: RMSE medio de validación de la NARX (3 semillas) según retardos d_y y neuronas.

4.4. Prueba externa

Con los hiperparámetros elegidos ($p = q = 1$; $d_y = 7$, 20 neuronas), la prueba externa se ejecutó una sola vez (tabla 3, figuras 4 y 5).

Tabla 3: Prueba externa: 12 orígenes, $H = 24$. Tiempo total de ajuste y pronóstico.

Modelo	RMSE	MAE	MASE	Tiempo (s)
Ingenuo estacional	96,24	69,49	0,974	0,0
Clásico (ARIMAX)	68,47	43,55	0,610	6,3
NARX	**49,61**	**29,33**	**0,411**	62,4
NAR	76,04	48,30	0,677	39,7

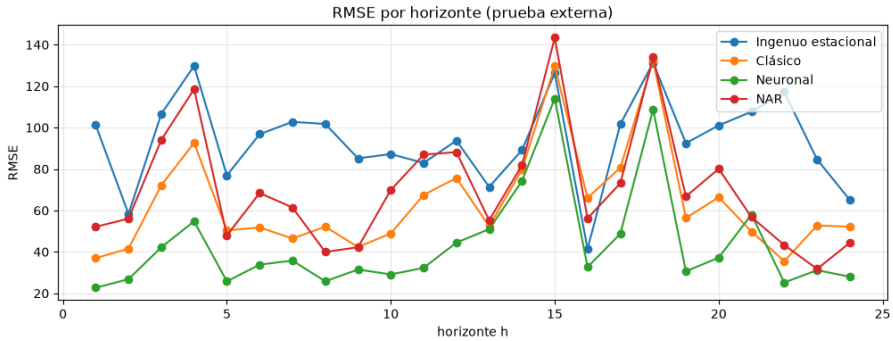


Figura 4: RMSE por horizonte en la prueba externa.

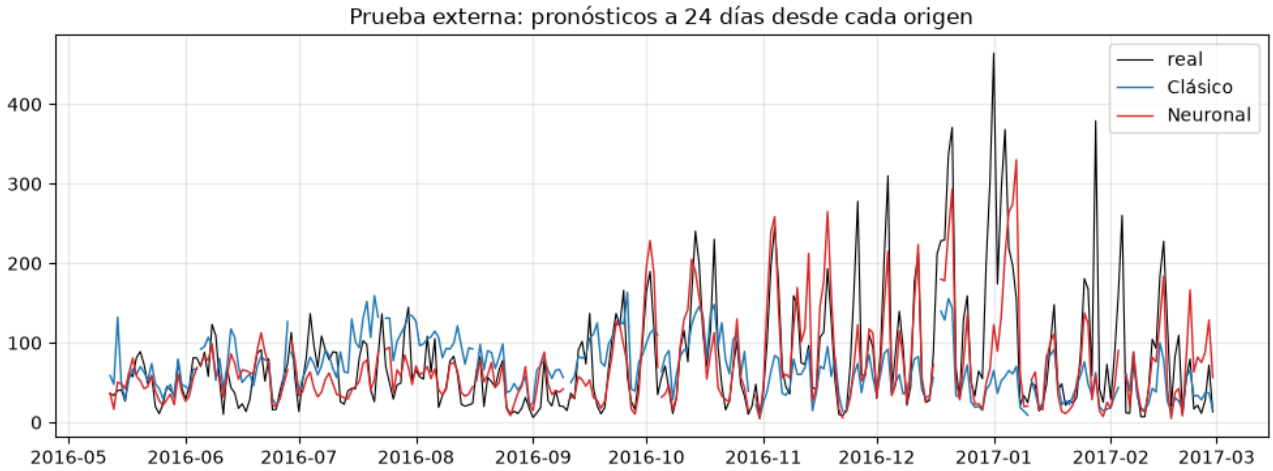


Figura 5: Prueba externa: serie real y pronósticos a 24 días desde cada origen del clásico y la NARX.

4.5. Residuos y Diebold-Mariano

Ljung-Box rechaza la ausencia de autocorrelación en los residuos de todos los modelos: ninguno extrae toda la estructura de la serie, algo esperable al pronosticar 24 días con errores que se encadenan. La tabla 4 resume la prueba de Diebold-Mariano sobre la prueba externa.

Tabla 4: Diebold-Mariano con corrección HLN ($h = 24$, pérdida cuadrática). Un estadístico positivo indica que el segundo modelo tiene menor error.

Comparación	DM*	p
Ingenuo frente a clásico	2,608	0,010
Ingenuo frente a NARX	2,807	0,005
Ingenuo frente a NAR	2,340	0,020
Clásico frente a NARX	2,246	**0,026**
Clásico frente a NAR	−1,357	0,176
NARX frente a NAR	−1,943	0,053

5. Análisis

La NARX gana, y la diferencia es significativa. En la prueba externa la NARX reduce el MASE de 0,610 a 0,411 frente al clásico y Diebold-Mariano rechaza la igualdad ($p = 0{,}026$). La NARX tiene el menor RMSE en casi todos los horizontes, con la mayor ventaja en los primeros 12 días; en los horizontes 13 a 15 y 18 los cuatro modelos se acercan, porque ahí caen los picos que ninguno anticipa (figura 4). Con solo 12 orígenes la curva es irregular y no crece de forma monótona con h. En la figura 5 se ve dónde gana: entre noviembre y enero el clásico se queda muy por debajo de los episodios de smog, mientras la NARX, que recibe el clima de esos días, sube con ellos.

Buena parte de la ventaja viene del clima. Sin exógenas, la NAR (0,677) queda peor que el clásico, que sí usa el clima, y la diferencia entre NARX y NAR roza la significancia ($p = 0{,}053$). La conclusión depende del

supuesto de clima futuro conocido: con un pronóstico meteorológico real, con error, la ventaja de la NARX y del ARIMAX sería menor.

Más memoria no es mejor. Con 28 días de retardos la red tiene más entradas que información útil: el error de validación sube de cerca de 40 a entre 45 y 50. Una semana basta, coherente con la memoria corta que sugiere el $\phi_1 = 0{,}854$ del ARIMAX.

La validación anticipó la prueba. El orden de los modelos en validación (NARX, clásico, NAR, ingenuo) se mantuvo en la prueba externa. El ingenuo incluso mejora en la prueba (MASE 0,974 frente a 1,005), mientras el clásico y la NAR empeoran más que la NARX al pasar de validación a prueba.

Costo e interpretabilidad. La red tarda casi 10 veces más que el clásico en la prueba (62 s frente a 6 s) y sus pesos no se interpretan; el ARIMAX, en cambio, cuantifica el efecto de cada variable del clima. Es un intercambio: precisión con la NARX, explicación con el clásico.

6. Contraste con una segunda implementación

Para comprobar que el resultado no depende de mis decisiones, lo contrasté con una segunda implementación hecha por separado, con otras elecciones y con apoyo de Claude (sección 8). La tabla 5 compara la prueba externa de ambas.

Tabla 5: Prueba externa de las dos implementaciones (RMSE en μg/m^3).

	Este informe	Segunda implementación
Clásico	ARIMAX$(1,1)$, escala log	SARIMAX$(3,3)(0,0,1)_7$, escala original
NARX	$d_y = 7$, 20 neuronas	$d_y = 3$, 5 neuronas
RMSE ingenuo	96,2	96,2
RMSE clásico	68,5	61,3
RMSE NARX	49,6	45,8
RMSE NAR	76,0	74,2
DM clásico frente a NARX (p)	0,026	0,029
DM NARX frente a NAR (p)	0,053	0,073

Las conclusiones coinciden: el ingenuo da exactamente lo mismo, la NARX supera al clásico de forma significativa, la NAR no supera al clásico, y la diferencia entre NARX y NAR queda en el borde de la significancia. Los valores absolutos cambian porque el clásico es sensible a cómo se ajusta: en la segunda implementación, el SARIMAX logarítmico con los regresores escalados no convergía del todo (RMSE de validación de 77,2) y con los regresores sin escalar daba 52,5, mientras que en escala original daba 47,1. Es decir, el clásico de este informe, en logaritmo, probablemente es algo conservador: con un clásico mejor ajustado la brecha entre el clásico y la NARX se reduce (de 18,9 a 15,5 μg/m^3 de RMSE, aunque con otros hiperparámetros de la red), sin cambiar la conclusión.

Límites. (i) El clima futuro se toma como conocido, lo que favorece a los modelos con regresores. (ii) La prueba externa tiene 293 días y 12 orígenes: el RMSE por horizonte resume solo 12 puntos, y Diebold-Mariano se aplicó sobre los errores agrupados de todos los orígenes, que no son independientes. (iii) Varios óptimos quedaron en el borde de la rejilla ($d_y = 7$, $p = q = 1$), por lo que podría haber valores mejores fuera de ella. (iv) La red de la prueba usa una sola semilla y no se midió su efecto en la prueba externa.

7. Conclusiones

1. PM2.5 diario en Beijing es estacionaria en nivel, con estacionalidad semanal débil ($F_S = 0{,}07$); el logaritmo reduce su asimetría de 1,77 a $-0{,}28$.
2. AIC, BIC y la rejilla de validación coinciden en el mismo clásico, ARIMAX$(1, 0, 1)$ con clima: el punto de rocío aumenta la contaminación y el viento la reduce.
3. En la red pesan más los retardos que las neuronas: una semana de retardos ($d_y = 7$) y 20 neuronas dio el menor error medio entre semillas (RMSE 38,80, desviación 0,20).
4. En la prueba externa la NARX supera al clásico (MASE 0,411 frente a 0,610) y la diferencia es significativa ($p = 0{,}026$); sin clima, la NAR no supera al clásico.
5. La ventaja de la NARX depende del clima futuro conocido y cuesta casi 10 veces más tiempo de cómputo, con menos interpretabilidad que el ARIMAX.

Referencias

- Bergmeir, C. y Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192–213.
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/
- Manikandan, N. y Subha, S. (2016). Software design challenges in time series prediction systems using parallel implementation of artificial neural networks. *The Scientific World Journal*, 2016, 6709352.

8. Declaración de uso de IA

Desarrollé este taller sin usar inteligencia artificial: el cuaderno, los resultados y el texto del informe son míos. Usé Claude (Anthropic) solo para contrastar y complementar mi trabajo: preparó por separado una segunda implementación completa, con la que comparé mis resultados en la sección 6; buscó las imágenes de la web de las figuras 1 y 2; y ayudó a redactar, con ese material, la sección de contraste, los límites y las referencias. La elección del conjunto de datos (Beijing) y del alcance (solo la parte en Python) fue mía. No se modificó el motor de evaluación de la plantilla y la prueba externa se ejecutó una sola vez, con los hiperparámetros ya elegidos en validación.