

UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional en Alta Calidad

Taller 6: series de tiempo
Plan de trabajo

Modelo clásico frente a una red NARX sobre una serie real

Juan Felipe Rodríguez Galindo
20261595004
Maestría en Ciencias de la Información y las Comunicaciones

Inteligencia Computacional Aplicada · 2026



¿Qué pide el taller?

Plantilla del profesor: `TallerST_Plantilla.ipynb`

El objetivo

Comparar un **modelo estadístico clásico** con una **red NARX** pronosticando una serie real, y decidir con evidencia estadística si la red gana.

Lo que ya viene hecho

Carga, validación, diagnóstico, validación cruzada de origen móvil, métricas, Diebold-Mariano y exportación. **El motor de evaluación no se toca.**

Tres TODO-EQUIPO

1. `modelo_clasico`: SARIMAX justificado
2. `modelo_neuronal`: NARX, escalado solo con entrenamiento
3. `REJILLAS`: 2 hiperparámetros $\times$ 3 niveles, 3 semillas

Regla de oro

La **prueba externa se ejecuta una sola vez**, al final, con los hiperparámetros ya elegidos.

Alcance: la plantilla en Python. La versión MATLAB (`.m`) es equivalente y no la uso porque no tengo MATLAB.



Los datos: calidad del aire en Beijing

UCI Machine Learning Repository, estación Aotizhongxin

- **Objetivo**: PM2.5, partículas finas en μg/m^3.
- **Exógenas** (clima): temperatura, punto de rocío, presión y velocidad del viento.
- Datos horarios de mar. 2013 a feb. 2017, promediados por día: **1461 días**, periodo estacional $s = 7$.
- **Desarrollo**: 1168 días (80 %). **Prueba externa**: 293 días (20 %).
- Cumple los criterios C1 a C6 de la plantilla; 15 días sin dato se interpolan.

¿Por qué Beijing?

Probé los tres conjuntos. Beijing es diario y corre rápido en CPU, y el clima tiene una relación física con la contaminación: **el viento la dispersa**. Es el caso en que una NARX debería aportar.

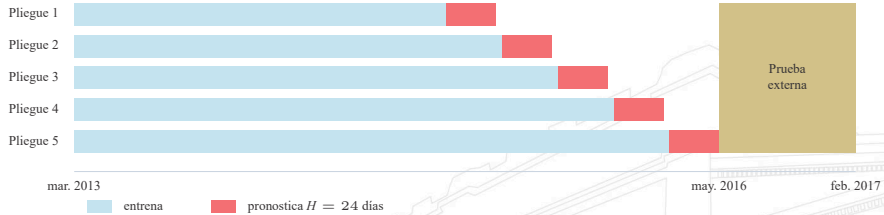
Supuesto

Como en el Taller 1, el clima futuro se toma como **conocido**. En la realidad vendría de un pronóstico con error.



Cómo se evalúa: origen móvil

Nunca se baraja el tiempo



Cada pliegue entrena con todo lo anterior a su origen (**ventana expandible**) y pronostica los 24 días siguientes. Así se eligen los hiperparámetros.

Métricas: RMSE, MAE y **MASE** (MASE < 1 = mejor que el ingenuo estacional). Al final, **Diebold-Mariano** dice si la diferencia entre dos modelos es significativa.



Los modelos que comparo

Todos cumplen el mismo contrato: `pronosticar(y_hist, X_hist, X_fut, H, **hp)`

Ingenuo estacional

Repite la última semana: $\hat{y}_t = y_{t-7}$. Es la referencia que hay que superar.

Clásico: SARIMAX

Sobre $\log(1+y)$, con el clima como regresor **lineal**. El orden $(p,d,q)(P,D,Q)_7$ lo elijo con el diagnóstico, AIC y BIC, y reviso los residuos con Ljung-Box.

Neuronal: NARX

Una capa oculta `tanh`. Entra la historia $y_{t-1} \dots y_{t-d_y}$ y el clima $x_t \dots x_{t-2}$. Se entrena en **lazo abierto** y pronostica en **lazo cerrado**.

Sin fuga

Dentro de cada llamada se ajusta todo lo que depende de los datos: el escalado sale solo de `y_hist` y `X_hist`, y la parada temprana usa el 15 % final de `y_hist`. También corro la misma red **sin clima (NAR)** para ver cuánto aporta.



Plan de trabajo

Qué hago y cómo sé que está bien

	Qué hago	Cómo lo verifico
0	Corro la plantilla sin cambios	Pasa la validación y sale la tabla del ingenuo
1	Logaritmo y AIC/BIC para el clásico	La asimetría baja; coeficientes y Ljung-Box
2	`modelo_clasico` y `modelo_neuronal`	Devuelven 24 valores; MASE < 1 en validación
3	Rejillas: clásico 3×3; red $3 \times 3 \times 3$ semillas	Media y desviación del RMSE; mapa de calor
4	Elijo con la validación y corro la prueba una vez	Tabla final, RMSE por horizonte
5	Residuos y Diebold-Mariano	p-valores de cada par de modelos

La rejilla de la red son 135 entrenamientos (unos 10 minutos en CPU). Hago un commit después de cada bloque para que git muestre el avance.



Lo que aprendí de las entregas anteriores

Y que esta vez cuido desde el principio

Alcance justo

Lo que pide la plantilla y nada más: los dos modelos, las rejillas y la prueba final. La NAR es la misma función sin clima.

Entrega autocontenida

El cuaderno ejecutado con sus salidas, la carpeta `resultados/` y `requirements.txt`. Los datos los descarga el propio cuaderno.

Nombre correcto

Todo rotulado como **Taller 6**.

IA declarada

Uso Claude como tutor: me ayudó a planear y me propone código que yo escribo, ejecuto y explico. Todo queda grabado y declarado.



Mis hipótesis, antes de ejecutar

Las comparo con los resultados al final del video

1. **¿La NARX le gana al SARIMAX en la prueba externa?**
   Creo que: …
2. **¿El clima ayuda? (NARX frente a la NAR sin clima)**
   Creo que: …
3. **¿Qué mueve más el error de la red: los retardos d_y o las neuronas?**
   Creo que: …
4. **¿La diferencia entre los dos modelos será significativa con Diebold-Mariano?**
   Creo que: …



Orden del video

Planear, programar, contrastar

1 Enunciado → 2 Este plan → 3 Entorno y plantilla → 4 Modelos y rejillas → 5 Prueba externa → **6 Hipótesis vs. resultados**

Después del video

El informe con la plantilla UD (6 a 8 páginas): metodología con la tabla de validación, resultados, sensibilidad, Diebold-Mariano, conclusiones con mis números y la declaración de uso de IA con el enlace al video.

UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional en Alta Calidad

www.udistrital.edu.co

VIGILADO MINEDUCACIÓN.
Diseño: Unidad de Publicaciones
Universidad Distrital Francisco José de Caldas



Gracias

Preguntas y discusión

Juan Felipe Rodríguez Galindo
Maestría en Ciencias de la Información
y las Comunicaciones
Inteligencia Computacional Aplicada