

# Informe de Revisión Estadística Rigurosa de Variables: Conjunto de Datos Bank Marketing (UCI & Additional)

---

Guía metodológica de pruebas de hipótesis, comprobación de supuestos paramétricos, multicolinealidad y preprocesamiento para Inteligencia Computacional

**Asignatura:** Inteligencia Computacional

**Metodología:** Skill classification-variable-stats-review (Harness)

**Datasets:** Bank UCI (N=45,211; muestra 4,521) y Bank Additional (N=41,188; muestra 4,119)

**Directorio de Trabajo:** 3.Trabajos/1.en-casa-limpieza/bank/

**[RESUMEN EJECUTIVO]** Este informe documenta la revisión exploratoria y formal de las variables del dataset Bank Marketing. Se demuestra mediante pruebas de Shapiro-Wilk, Kolmogorov-Smirnov y Levene el incumplimiento total de normalidad y homocedasticidad, justificando el uso de pruebas no paramétricas (Mann-Whitney U y Chi-cuadrado). Asimismo, se diagnostica multicolinealidad crítica ( $VIF > 60$ ) en indicadores macroeconómicos y se formula el plan de preprocesamiento.

## 1. Introducción y Contexto del Dataset

El dataset Bank Marketing recoge el resultado de campañas de telemarketing directo realizadas por un banco comercial portugués (Moro et al., 2011, 2014). La tarea analítica consiste en predecir si un cliente suscribirá un depósito a plazo fijo (variable objetivo binaria  $y \in \{\text{'yes'}, \text{'no'}\}$ ).

La carpeta analizada contiene dos versiones con diferente alcance de atributos:

- **Bank UCI Estándar (bank.csv / bank-full.csv):** 16 predictores (7 continuos y 9 categóricos) correspondientes a datos demográficos del cliente, saldo bancario anual y métricas operativas de la llamada actual y campañas previas (N=45,211; muestra del 10%: N=4,521).
- **Bank Additional (bank-additional.csv / bank-additional-full.csv):** 20 predictores (10 continuos y 10 categóricos) sobre 41,188 instancias (muestra del 10%: N=4,119). Incorpora 5 indicadores macroeconómicos nacionales trimestrales y mensuales del Banco de Portugal.

## 2. Marco Metodológico y Flujo de Decisión Estadística

El análisis sigue estrictamente el árbol de decisión metodológico para datasets de clasificación previo al modelado:

1. **Tipificación y Exploración:** Clasificación de variables en numéricas y categóricas; estimación de media, mediana, dispersión, asimetría y curtosis.
2. **Pruebas de Normalidad:** Shapiro-Wilk ( $n \leq 5,000$ ) o K-S Lilliefors y D'Agostino-Pearson global y por clase ( $y=\text{'yes'}$  vs.  $y=\text{'no'}$ ).
3. **Homocedasticidad:** Test de Levene y Fligner-Killeen para evaluar homogeneidad de varianzas entre clases.
4. **Comparación entre Clases:** Selección rigurosa entre t-test paramétrico (Student/Welch) o test no paramétrico de Mann-Whitney U según los supuestos anteriores.
5. **Correlación y Multicolinealidad:** Coeficientes de Pearson y Spearman, Factor de Inflación de Varianza (VIF) e Índice de Condición.
6. **Asociación Categórica:** Chi-cuadrado de independencia (con Fisher de respaldo) y tamaño del efecto con V de Cramér.
7. **Relevancia de Features:** Ranking mediante ANOVA F-score, Kruskal-Wallis H e Información Mutua.
8. **Detección de Outliers y Desbalance:** Z-score ( $|z| > 3$ ), regla IQR 1.5x, Mahalanobis multivariado y Test Binomial de clase.

## 3. Tipificación y Estadística Descriptiva Univariada

A continuación se detallan los estadísticos descriptivos univariados de las variables continuas en Bank Additional y las variables exclusivas del Bank UCI estándar:

**Tabla 1. Estadísticos Descriptivos — Bank Additional (N=4,119)**

| Variable       | Media  | Mediana | Desv. Est. | Asimetría | Curtosis | Diagnóstico de Forma                 |
|----------------|--------|---------|------------|-----------|----------|--------------------------------------|
| age            | 40.11  | 38.0    | 10.31      | 0.715     | 0.436    | Sesgo moderado a la derecha          |
| duration       | 256.8  | 181.0   | 254.7      | 3.294     | 20.74    | Cola derecha muy pesada              |
| campaign       | 2.54   | 2.0     | 2.57       | 4.002     | 25.25    | Concentrado en 1-2 llamadas          |
| pdays          | 960.4  | 999.0   | 191.9      | -4.773    | 20.79    | Inflada en 999 (sin contacto previo) |
| previous       | 0.19   | 0.0     | 0.54       | 4.022     | 22.09    | Inflada en 0 (85% sin historial)     |
| emp.var.rate   | 0.08   | 1.1     | 1.56       | -0.727    | -1.042   | Bimodal / Indicador macro            |
| cons.price.idx | 93.58  | 93.75   | 0.58       | -0.217    | -0.824   | Distribución multimodal              |
| cons.conf.idx  | -40.50 | -41.80  | 4.59       | 0.287     | -0.315   | Valores negativos de confianza       |
| euribor3m      | 3.62   | 4.86    | 1.73       | -0.715    | -1.396   | Bimodal (tasas bajas vs altas)       |
| nr.employed    | 5166.0 | 5191.0  | 73.67      | -1.075    | 0.060    | Discreta / Trimestral                |

**Tabla 2. Variables Exclusivas de Bank UCI Estándar (N=4,521)**

| Variable | Media  | Mediana | Desv. Est. | Asimetría | Curtosis | Diagnóstico de Forma         |
|----------|--------|---------|------------|-----------|----------|------------------------------|
| balance  | 1422.7 | 444.0   | 3009.6     | 6.594     | 88.29    | Cola extrema (máx 71,188 €)  |
| day      | 15.92  | 16.0    | 8.25       | 0.095     | -1.040   | Plano / Multimodal (día mes) |

## 4. Comprobación de Supuestos: Normalidad y Homocedasticidad

Se ejecutaron pruebas de Shapiro-Wilk y D'Agostino-Pearson globalmente y estratificadas por clase, junto con el test de Levene de varianzas:

**Tabla 3. Pruebas de Normalidad y Homocedasticidad (Bank Additional)**

| Variable       | p Shapiro (Global) | p Shapiro (y='no') | p Shapiro (y='yes') | p Levene (Varianza) | Homocedasticidad   |
|----------------|--------------------|--------------------|---------------------|---------------------|--------------------|
| age            | 5.64e-33           | 2.85e-29           | 1.38e-13            | 4.22e-15            | Heterogénea        |
| duration       | 1.03e-63           | 3.56e-59           | 1.21e-20            | 1.97e-76            | Heterogénea        |
| campaign       | 4.30e-71           | 2.69e-68           | 3.61e-27            | 7.28e-06            | Heterogénea        |
| pdays          | 5.96e-86           | 2.95e-85           | 2.38e-33            | 1.44e-106           | Heterogénea        |
| previous       | 1.31e-79           | 7.62e-78           | 8.77e-30            | 1.73e-62            | Heterogénea        |
| emp.var.rate   | 1.44e-60           | 4.18e-60           | 1.12e-20            | 0.0445              | Heterogénea        |
| cons.price.idx | 6.96e-39           | 1.70e-38           | 1.48e-11            | 7.90e-09            | Heterogénea        |
| cons.conf.idx  | 3.71e-41           | 1.14e-42           | 1.06e-07            | 8.28e-17            | Heterogénea        |
| euribor3m      | 4.49e-66           | 3.64e-65           | 9.24e-28            | 0.0577              | Homogénea marginal |
| nr.employed    | 5.15e-59           | 1.25e-58           | 4.21e-18            | 7.48e-29            | Heterogénea        |

**[JUSTIFICACIÓN DE LA RUTA NO PARAMÉTRICA]** Dado que el 100% de las variables continuas violan la normalidad ( $p < 10^{-10}$ ) y la gran mayoría presenta heterogeneidad de varianzas, queda formalmente invalidado el t-test de Student. Se adopta estrictamente la prueba no paramétrica de Mann-Whitney U.




Figura 1. Diagnóstico univariado, Q-Q Plot y Boxplot por clase para la variable 'duration'.

## 5. Comparación No Paramétrica (Mann-Whitney U) y Relevancia

A continuación se presenta el contraste no paramétrico entre clases y el ordenamiento de características según Información Mutua:

Tabla 4. Contraste Mann-Whitney U y Ranking de Información Mutua

| Variable       | Estadístico U | p-valor Mann-Whitney | Info. Mutua | Significativo      | Interpretación                                |
|----------------|---------------|----------------------|-------------|--------------------|-----------------------------------------------|
| duration       | 2.95e+05      | 2.08e-110            | 0.0741      | Sí ( $p < 0.001$ ) | 1º — Predictor más potente (duración llamada) |
| euribor3m      | 1.23e+06      | 2.38e-65             | 0.0728      | Sí ( $p < 0.001$ ) | 2º — Tasas bajas disparan depósitos           |
| cons.conf.idx  | 7.56e+05      | 2.67e-03             | 0.0664      | Sí ( $p < 0.01$ )  | 3º — Confianza influye en ahorro              |
| cons.price.idx | 9.56e+05      | 4.42e-08             | 0.0649      | Sí ( $p < 0.001$ ) | 4º — Variación de precios macro               |
| nr.employed    | 1.23e+06      | 2.22e-70             | 0.0623      | Sí ( $p < 0.001$ ) | 5º — Empleo nacional trimestral               |
| emp.var.rate   | 1.17e+06      | 2.45e-50             | 0.0494      | Sí ( $p < 0.001$ ) | 6º — Variación de empleo                      |
| pdays          | 9.97e+05      | 6.91e-101            | 0.0374      | Sí ( $p < 0.001$ ) | 7º — Recencia de contacto previo              |
| previous       | 6.25e+05      | 1.02e-43             | 0.0229      | Sí ( $p < 0.001$ ) | 8º — Historial de contactos                   |
| campaign       | 9.16e+05      | 9.19e-05             | 0.0072      | Sí ( $p < 0.001$ ) | 9º — Saturación de llamadas                   |
| age            | 7.92e+05      | 0.1420               | 0.0056      | No ( $p > 0.05$ )  | 10º — Mediana similar entre clases            |



Figura 2. Diagnóstico univariado y distribución condicional por clase para 'euribor3m'.

## 6. Asociación entre Variables Categóricas y la Suscripción

Se evaluó la independencia con la prueba Chi-cuadrado (y test exacto de Fisher) y se calculó la fuerza de asociación con la V de Cramér:

**Tabla 5. Pruebas de Asociación Categórica (Bank Additional)**

| Variable Categórica | Prueba                | p-valor  | V de Cramér ( $\phi_c$ ) | Fuerza Asociación | Hallazgo Principal                                          |
|---------------------|-----------------------|----------|--------------------------|-------------------|-------------------------------------------------------------|
| poutcome            | Chi-cuadrado          | 2.04e-99 | 0.3322                   | Fuerte            | Éxito previo ('success') es el predictor categórico nº 1.   |
| month               | Chi-cuadrado          | 2.90e-59 | 0.2698                   | Fuerte            | Marzo, sep, oct y dic presentan tasas >40% (mayo solo ~7%). |
| contact             | Chi-cuadrado (Fisher) | 1.85e-18 | 0.1366                   | Moderada          | Canal celular duplica conversión frente a fijo.             |
| job                 | Chi-cuadrado          | 1.23e-10 | 0.1303                   | Moderada          | Estudiantes y jubilados suscriben más que obreros.          |
| default             | Chi-cuadrado          | 5.60e-06 | 0.0766                   | Débil             | Clientes con morosidad casi nunca suscriben.                |
| education           | Chi-cuadrado          | 2.26e-03 | 0.0736                   | Débil             | Educación universitaria tiene mayor tasa de apertura.       |
| marital             | Chi-cuadrado          | 1.63e-02 | 0.0500                   | Débil             | Solteros tienen ligeramente mayor propensión.               |
| loan                | Chi-cuadrado          | 0.5684   | 0.0166                   | Nula / NS         | Tener préstamo personal no afecta la decisión.              |
| housing             | Chi-cuadrado          | 0.7307   | 0.0123                   | Nula / NS         | Crédito hipotecario no discrimina significativamente.       |
| day_of_week         | Chi-cuadrado          | 0.9723   | 0.0112                   | Nula / NS         | El día de la semana no influye en la tasa de éxito.         |

## 7. Diagnóstico de Correlación y Multicolinealidad (VIF)

Al analizar los coeficientes de correlación y el Factor de Inflación de Varianza (VIF), se identifica una multicolinealidad extrema entre los indicadores macroeconómicos de Bank Additional:

Tabla 6. Factores de Inflación de Varianza (VIF) — Bank Additional

| Variable Predictora | VIF   | Correlación Principal                                       | Diagnóstico de Colinealidad              |
|---------------------|-------|-------------------------------------------------------------|------------------------------------------|
| euribor3m           | 62.91 | $r = 0.970$ con emp.var.rate; $r = 0.943$ con nr.employed   | Colinealidad Severa ( $VIF \gg 10$ )     |
| emp.var.rate        | 31.95 | $r = 0.897$ con nr.employed; $r = 0.755$ con cons.price.idx | Colinealidad Severa ( $VIF \gg 10$ )     |
| nr.employed         | 31.14 | $r = 0.943$ con euribor3m                                   | Colinealidad Severa ( $VIF \gg 10$ )     |
| cons.price.idx      | 6.33  | $r = 0.755$ con emp.var.rate                                | Colinealidad Moderada/Alta ( $VIF > 5$ ) |
| cons.conf.idx       | 2.54  | $r = 0.277$ con euribor3m                                   | Colinealidad Baja                        |
| previous            | 1.82  | $r = -0.588$ con pdays                                      | Colinealidad Baja                        |
| pdays               | 1.62  | $r = -0.588$ con previous                                   | Colinealidad Baja                        |
| campaign            | 1.05  | Baja intercorrelación general                               | Colinealidad Despreciable                |
| duration            | 1.02  | Baja intercorrelación general                               | Colinealidad Despreciable                |
| age                 | 1.02  | Baja intercorrelación general                               | Colinealidad Despreciable                |

**Índice de Condición: 18.90** (casi-singularidad en la matriz de diseño). Esto exige la eliminación de variables redundantes o reducción por PCA para estabilizar estimadores lineales y redes neuronales.




Figura 3. Mapa de calor de correlación (Pearson y Spearman) en Bank Additional.

## 8. Detección de Outliers, Balance de Clases y Proyección Global

Tabla 7. Outliers Univariados y Multivariados

| Variable      | Outliers Z ( $ z >3$ ) | Outliers IQR (1.5x) | Límite Inferior IQR | Límite Superior IQR |
|---------------|------------------------|---------------------|---------------------|---------------------|
| age           | 32 (0.8%)              | 39 (0.9%)           | 9.5 años            | 69.5 años           |
| duration      | 87 (2.1%)              | 291 (7.1%)          | -218.0 seg          | 638.0 seg           |
| campaign      | 87 (2.1%)              | 235 (5.7%)          | -2.0 contactos      | 6.0 contactos       |
| pdays         | 160 (3.9%)             | 160 (3.9%)          | 999.0               | 999.0               |
| previous      | 121 (2.9%)             | 596 (14.5%)         | 0.0                 | 0.0                 |
| cons.conf.idx | 0 (0.0%)               | 43 (1.0%)           | -52.15              | -26.95              |
| balance (UCI) | 88 (1.9%)              | 506 (11.2%)         | -2,048 €            | 3,596 €             |

- **Mahalanobis Multivariado:** 290 outliers conjuntos (7.0%) detectados bajo umbral  $\chi^2(10)=29.6$ .
- **Balance de Clases (Test Binomial):**  $p = 0.0000$ . Desbalance severo (89.1% 'no' vs 10.9% 'yes'). Requiere evaluación con F1-Score Macro, PR-AUC y validación con Stratified K-Fold.




Figura 4. Proyección no supervisada PCA 2D sobre variables continuas estandarizadas.



## 9. Directrices de Limpieza y Preprocesamiento para Inteligencia Computacional

**Tabla 8. Matriz de Decisiones y Acciones de Ingeniería de Datos**

| Aspecto / Feature              | Evidencia Estadística                                                      | Riesgo en Modelado                                                                        | Acción de Preprocesamiento                                                                                            |
|--------------------------------|----------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| Fuga de Información (duration) | $p = 2.08e-110$ , IM = 0.0741                                              | Fuga de datos (data leakage). La duración solo se conoce al finalizar la llamada.         | Descartar 'duration' para modelos de prospección en producción. Mantener solo para benchmark.                         |
| Colinealidad Macroeconómica    | VIF > 60 entre euribor3m, emp.var.rate, nr.employed ( $r > 0.94$ )         | Inestabilidad de coeficientes e hiperplanos en regresión logística, redes y SVM lineales. | Opción A: Retener sólo euribor3m. Opción B: Reducción por PCA (2 componentes explican >90% varianza).                 |
| Valores Nulos / 'unknown'      | Categoría 'unknown' en job, marital, education, default, housing, loan     | Pérdida de filas si se eliminan; sesgo si se imputa incorrectamente.                      | Tratar 'unknown' como categoría explícita. Codificar con One-Hot Encoding (nominales) y Ordinal Encoding (education). |
| Variables No Informativas      | day_of_week ( $p = 0.972$ ), housing ( $p = 0.731$ ), loan ( $p = 0.568$ ) | Aumento innecesario de dimensionalidad y ruido.                                           | Eliminar 'day_of_week' y evaluar supresión de 'loan'/'housing' según regularización del modelo.                       |
| Escalado y Asimetría           | Skewness > 3 y colas pesadas en duration, campaign, previous, balance      | Sensibilidad extrema a outliers en algoritmos basados en distancias (k-NN, SVM, MLP).     | Aplicar RobustScaler (mediana e IQR) o PowerTransformer (Yeo-Johnson / $\log(1+x)$ ).                                 |
| Variable bimodal 'pdays'       | Acumulación artificial en 999 (sin contacto)                               | Distorsión de relaciones lineales y escalamiento.                                         | Crear feature booleana 'pcontacted = (pdays != 999)' y transformar el número de días restante.                        |
| Desbalance de Clases           | 89% 'no' vs 11% 'yes' (p_binom = 0.000)                                    | Modelos sesgados a la clase mayoritaria (Accuracy trivial ~89%).                          | Stratified K-Fold obligatorio. Entrenar con class_weight='balanced' o SMOTE / ADASYN. Optimizar PR-AUC.               |

## 10. Conclusiones y Referencias Bibliográficas

- Rigor Metodológico:** La comprobación de supuestos impidió conclusiones espurias que habrían surgido de contrastes paramétricos inadecuados.
- Poder Discriminante Macroeconómico:** Los factores económicos externos (euribor3m, cons.conf.idx, cons.price.idx) demostraron ser más influyentes que las características demográficas aisladas.
- Control de Riesgos:** Se establecieron las directrices técnicas para aislar la fuga de datos en 'duration' y mitigar la colinealidad (VIF > 60).

### Referencias:

- Moro, S., Laureano, R., & Cortez, P. (2011). Using Data Mining for Bank Direct Marketing: An Application of the CRISP-DM Methodology. ESM'2011.
- Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. Decision Support Systems, 62, 22-31.
- Cortez, P. (2014). Data Mining with Neural Networks and Support Vector Machines using the rminer R Package.