PROYECTO FINAL: MODELO DE INTELIGENCIA COMPUTACIONAL

Ficha del proyecto

Cada equipo construye, entrena y evalúa con rigor un modelo basado en un paradigma de inteligencia computacional para resolver un problema real con datos, siguiendo la metodología por etapas CRISP-ML(Q), y presenta el trabajo como un artículo científico. El proyecto dura cinco semanas, del lunes 2 de noviembre al viernes 4 de diciembre de 2026: cada semana corresponde a una o dos fases y cierra con un entregable, y el proyecto termina con una sustentación oral.

Campo	Detalle
Asignatura	Inteligencia Computacional (posgrado), Facultad de Ingeniería, UDFJC
Modalidad	Trabajo autónomo en equipos de 1 o 2 estudiantes
Duración	Cinco semanas: lunes 2 de noviembre a viernes 4 de diciembre de 2026
Entregables semanales	Domingos a las 23:59: entregable 1 el 8 nov, entregable 2 el 15 nov, entregable 3 el 22 nov y entregable 4 el 29 nov
Retroalimentación	El docente comenta cada entregable antes del martes siguiente
Entrega final	Jueves 3 de diciembre, 23:59: artículo, código y presentación
Sustentación	Viernes 4 de diciembre: 12 minutos por equipo + 5 de preguntas
Herramientas	MATLAB o Python (Google Colab); se aceptan otras si el resultado es reproducible
Canal	Google Classroom: entregas, preguntas y anuncios

Objetivo

Formular un problema de predicción, clasificación, agrupamiento u optimización; resolverlo con al menos un modelo de inteligencia computacional; y demostrar con evidencia estadística si ese modelo supera a una referencia más simple.

Paradigmas admitidos y requisitos mínimos

El modelo principal debe pertenecer a uno de estos paradigmas, o combinarlos. Las redes NAR/NARX trabajadas en la sesión de series de tiempo son válidas, pero el proyecto debe ir más allá del Taller 2: otro problema, otro dataset u otro paradigma.

Paradigma	Ejemplos de modelos	Problemas típicos
Redes neuronales artificiales	MLP, CNN, RNN (LSTM, GRU), NAR/NARX, autoencoders, redes de base radial	Regresión, clasificación, series de tiempo, señales e imágenes
Sistemas difusos	Mamdani, Takagi-Sugeno, ANFIS, agrupamiento fuzzy c-means	Control, clasificación interpretable, modelado con conocimiento experto
Computación evolutiva	Algoritmos genéticos, estrategias evolutivas, evolución diferencial, programación genética	Optimización, selección de variables, ajuste de hiperparámetros, regresión simbólica
Inteligencia de enjambre	PSO, colonia de hormigas, colonia de abejas	Optimización continua y combinatoria, entrenamiento de redes
Sistemas híbridos	Neuro-difuso (ANFIS), neuro-evolutivo, red optimizada con GA o PSO, híbrido estadístico-neuronal	Cualquiera de los anteriores

Requisitos mínimos

1. Un problema con datos reales (públicos o propios) y una pregunta de investigación explícita.
2. Al menos **tres modelos comparados**: una referencia trivial (ingenuo, clase mayoritaria o equivalente), una referencia clásica (estadística o de aprendizaje automático convencional) y el modelo de inteligencia computacional propuesto.
3. Ajuste de hiperparámetros documentado y análisis de sensibilidad de al menos dos hiperparámetros del modelo propuesto.
4. Validación acorde a la naturaleza de los datos y un conjunto de prueba que solo se usa al final.
5. Prueba estadística de la diferencia entre el modelo propuesto y las referencias.
6. Código reproducible y artículo en formato IEEE.

Si el paradigma es de optimización (evolutivo o de enjambre), puede usarse para optimizar otro modelo o para resolver directamente un problema de optimización; en el segundo caso las referencias son otro metaheurístico y un método exacto o aleatorio, y se reportan al menos 30 ejecuciones independientes.

Marco metodológico: CRISP-ML(Q)

El proyecto sigue CRISP-ML(Q), el modelo de proceso para aprendizaje automático con aseguramiento de calidad propuesto por Studer et al. (2021). Extiende CRISP-DM, el estándar de minería de datos de 2000, en dos aspectos: une la comprensión del problema y de los datos en una sola etapa, y agrega una etapa de monitoreo y mantenimiento. Además, cada etapa define requisitos de calidad, riesgos y métodos para controlarlos. Las ocho fases de este instructivo son la forma concreta de recorrer esas etapas en cinco semanas, y los entregables semanales funcionan como sus puertas de calidad.



CRISP-ML(Q) · 6 etapas, 8 fases del proyecto

El proceso no es lineal: si la evaluación muestra que no se alcanzan los criterios de éxito, el equipo vuelve a la preparación de datos o al modelado, y documenta esa iteración en el artículo.

Correspondencia entre etapas y fases

Etapa CRISP-ML(Q)	Tareas de la etapa	Fases del proyecto	Puerta de calidad
1. Comprensión del problema y de los datos	Alcance, criterios de éxito, factibilidad, recolección y verificación de la calidad de los datos	F1 Estado del arte, F2 Selección de datos	Entregables 1 y 2: pregunta, criterio de éxito medible y dataset validado
2. Preparación de datos	Selección, limpieza, construcción de variables y estandarización	F4 Preprocesamiento	Entregable 3: pipeline sin fuga y documentado

Etapa CRISP-ML(Q)	Tareas de la etapa	Fases del proyecto	Puerta de calidad
3. Modelado	Revisión de soluciones similares, medidas de calidad del modelo, selección y entrenamiento, reproducibilidad	F3 Selección de modelos, F5 Métricas, F6 Entrenamiento	Entregables 2, 3 y 4: modelos, métricas, espacio de hiperparámetros y configuración final declarados antes de ver la prueba
4. Evaluación	Desempeño en prueba reservada, robustez, explicabilidad, comparación con los criterios de éxito	F7 Prueba de modelos	El resultado se contrasta con el criterio de éxito fijado en la etapa 1
5. Despliegue	Entrega del modelo en condiciones de uso	F8 Artículo y sustentación: en el curso, desplegar es entregar un resultado reproducible y comunicable	Entrega final y sustentación
6. Monitoreo y mantenimiento	Detección de cambios en los datos, reentrenamiento	Fuera del alcance; se planea en la sección de Discusión	—

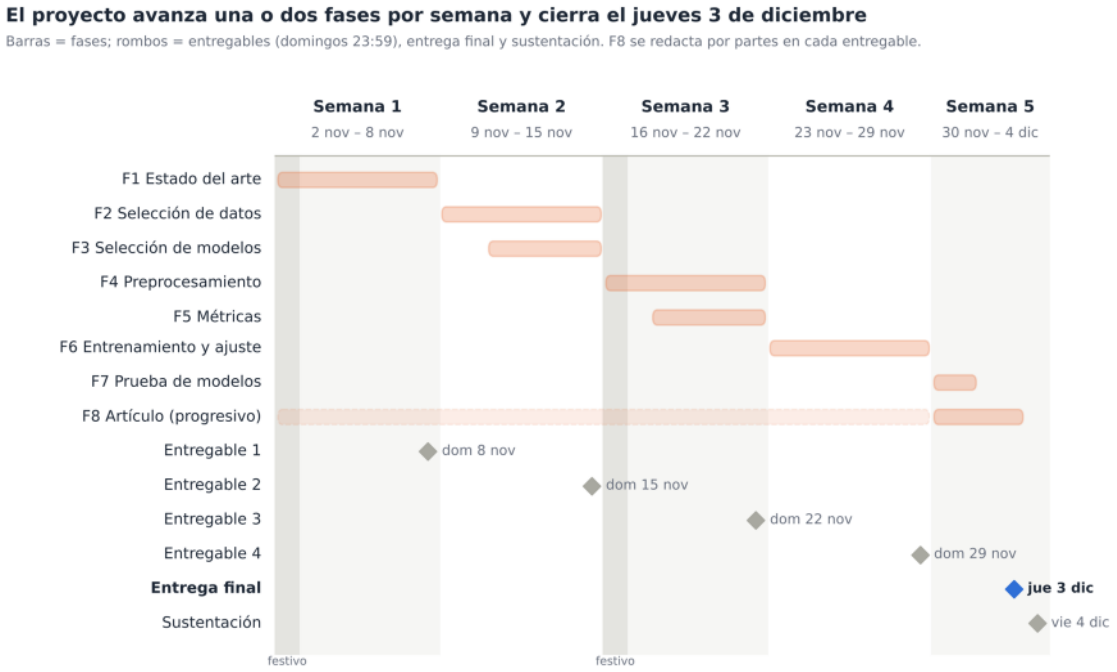
Criterio de éxito (etapa 1): cada equipo fija en el entregable 1 una meta medible, por ejemplo «el modelo propuesto reduce el RMSE de prueba al menos 10 % frente a la referencia clásica, con diferencia significativa al 5 %». Al final se reporta si se alcanzó o no; no alcanzarlo con un análisis honesto también es un resultado válido.

Aseguramiento de calidad por etapa

Etapa	Requisito de calidad	Riesgo típico	Método de aseguramiento	Evidencia en la entrega
1	Problema factible con los datos disponibles	Pregunta vaga; datos insuficientes o sin licencia	Matriz del estado del arte, criterios D1–D7, criterio de éxito escrito	Entregable 1 (propuesta)
2	Datos limpios y transformaciones reproducibles	Fuga de información; imputación o balanceo con todo el conjunto	Partición antes de transformar; `Pipeline`; ficha del dataset	Sección de Metodología y código
3	Modelo adecuado y entrenamiento estable	Sobreajuste; resultados que dependen de la semilla; búsqueda sobre la prueba	Referencias trivial y clásica; validación; ≥ 5 semillas; registro de experimentos	Registro de experimentos y tabla de sensibilidad
4	Desempeño real, robusto y explicable	Optimismo por reusar la prueba; diferencias atribuibles al azar	Prueba usada una vez; intervalos de confianza; pruebas de significancia; análisis de errores	Sección de Resultados
5	Resultado reproducible por terceros	Código que no corre; cifras que no coinciden con el artículo	README, versiones y semillas; ejecución en sesión limpia	Repositorio y anexo de reproducibilidad
6	Plan de vida del modelo	Deterioro por cambios en los datos	Plan de monitoreo y reentrenamiento descrito	Párrafo en la Discusión

Cronograma

El trabajo se organiza por semanas: cada una tiene una o dos fases y cierra el domingo a las 23:59 con un entregable que recibe retroalimentación antes del martes siguiente. El artículo se redacta por partes: cada entregable incluye la sección correspondiente en la plantilla IEEE, de modo que la última semana se dedica a la prueba final, los resultados y la revisión.



Cronograma semanal · 8 fases, 4 entregables semanales, entrega final y sustentación

Plan semanal

Semana	Fechas	Fases y trabajo	Entregable
1	Lun 2 – dom 8 nov	F1 Estado del arte: búsqueda, filtrado, matriz y síntesis; pregunta y criterio de éxito	E1 · dom 8 nov · 10 %
2	Lun 9 – dom 15 nov	F2 Selección y validación de datos; F3 Selección de modelos	E2 · dom 15 nov · 10 %
3	Mar 17 – dom 22 nov	F4 Preprocesamiento sin fuga; F5 Métricas y pruebas; entrenamiento de las referencias	E3 · dom 22 nov · 10 %
4	Lun 23 – dom 29 nov	F6 Entrenamiento, búsqueda de hiperparámetros, sensibilidad y semillas	E4 · dom 29 nov · 10 %
5	Lun 30 nov – vie 4 dic	F7 Prueba final (lun–mar); F8 cierre del artículo y presentación	Entrega final · jue 3 dic · 45 %; sustentación · vie 4 dic · 15 %

Fase 1. Revisión del estado del arte · Etapa 1 CRISP-ML(Q) (semana 1: 2 al 8 de noviembre)

La revisión define qué se ha hecho, con qué datos y con qué resultados, para que la propuesta del equipo aporte algo y se compare con cifras publicadas. Se hace una revisión estructurada y breve, inspirada en PRISMA 2020, no una revisión sistemática completa.

Pasos

1. Escribir el problema en una frase y descomponerlo en tres bloques de búsqueda: dominio (por ejemplo, demanda eléctrica), tarea (pronóstico) y método (red neuronal, lógica difusa, algoritmo genético).
2. Construir la ecuación de búsqueda con sinónimos en inglés unidos con OR dentro de cada bloque y AND entre bloques. Ejemplo: `("load forecasting" OR "electricity demand") AND ("neural network" OR LSTM OR NARX) AND (benchmark OR comparison)`.
3. Buscar en al menos dos bases: Scopus o IEEE Xplore (acceso institucional UDFJC) y Google Scholar o arXiv. Limitar a 2019–2026 y agregar los trabajos clásicos citados con frecuencia.
4. Filtrar en dos rondas (título y resumen; luego texto completo) con criterios de inclusión escritos de antemano: aborda la misma tarea, reporta métricas cuantitativas, describe los datos.
5. Registrar el conteo de cada etapa (encontrados, tras duplicados, tras primer filtro, incluidos) para un diagrama de flujo tipo PRISMA en el artículo.
6. Llenar la matriz del estado del arte y redactar una síntesis de una página que termine en la brecha que el proyecto atiende.

Matriz del estado del arte (mínimo 15 trabajos; al menos 10 de 2021 en adelante)

Referencia	Problema y datos	Paradigma y modelo	Referencias comparadas	Validación	Métrica y resultado	Limitaciones	Relevancia para el proyecto
Autor (año)							

Entregable 1 (domingo 8 de noviembre, 23:59): documento de 3 a 4 páginas en la plantilla IEEE con el problema, la pregunta de investigación, el criterio de éxito medible (etapa 1 de CRISP-ML(Q)), la ecuación y el conteo de la búsqueda, la matriz del estado del arte y la síntesis redactada como borrador de la sección II del artículo. Si el equipo quiere usar datos propios, incluye aquí la solicitud de aprobación.

Fase 2. Selección y validación de los datos · Etapa 1 CRISP-ML(Q) (semana 2: 9 al 15 de noviembre)

Los datos se eligen por el problema, no al revés: deben permitir responder la pregunta de investigación y, si es posible, compararse con trabajos de la matriz que usaron el mismo conjunto.

Dónde buscar

Repositorio	Fortaleza
UCI Machine Learning Repository	Conjuntos clásicos, documentados y con DOI
Datos Abiertos Colombia	Datos públicos nacionales: clima, energía, movilidad, salud, educación
OpenML	Miles de tareas con resultados de referencia comparables
Kaggle Datasets	Variedad amplia; verificar licencia y origen
Zenodo	Datos de artículos científicos con DOI
PhysioNet	Señales biomédicas (algunas requieren registro y curso de ética)

Se permiten datos propios del trabajo de grado o de un proyecto institucional, con aprobación del docente en el entregable 1 y autorización de uso.

Criterios de validación del conjunto de datos

Criterio	Condición mínima
D1 Tamaño	≥ 1.000 observaciones para redes neuronales; ≥ 300 para modelos difusos o problemas de optimización con justificación
D2 Variable objetivo	Definida, medible y sin ambigüedad; para clasificación, reportar el balance de clases
D3 Calidad	Faltantes en la variable objetivo ≤ 10 %; duplicados identificados
D4 Estructura	Si hay tiempo, índice ordenado y muestreo regular; si hay sujetos o grupos, identificador de grupo
D5 Disponibilidad	Toda variable de entrada estaría disponible en el momento de usar el modelo
D6 Licencia y ética	Licencia que permita uso académico; datos personales anonimizados
D7 Documentación	Origen, fecha, unidades y significado de cada variable

Ficha del conjunto de datos (va en la Metodología del artículo; basada en *Datasheets for Datasets*): fuente y enlace, licencia, periodo o contexto de recolección, número de observaciones y variables, tipo y unidades de cada variable, variable objetivo, faltantes y atípicos, sesgos conocidos y uso previsto.

Análisis exploratorio mínimo: estadísticos descriptivos, distribución de la variable objetivo, correlaciones entre entradas, faltantes por variable y, según el caso, descomposición STL y ACF (series de tiempo), balance de clases (clasificación) o visualización en dos dimensiones (agrupamiento).

Fase 3. Selección de los modelos a entrenar · Etapa 3 CRISP-ML(Q) (semana 2: 11 al 15 de noviembre)

Cada modelo del estudio cumple un papel. La elección se justifica con el estado del arte y con las propiedades de los datos observadas en el análisis exploratorio, no por popularidad.

Papel	Propósito	Ejemplos
Referencia trivial	Fija el piso: un modelo propuesto que no la supera no aporta	Ingenuo o ingenuo estacional; clase mayoritaria; media del entrenamiento
Referencia clásica	Demuestra que la complejidad del modelo propuesto se justifica	ARIMA/ETS, regresión lineal o logística, k-NN, árbol de decisión, random forest, SVM, k-means
Modelo propuesto	Responde la pregunta de investigación con un paradigma de inteligencia computacional	MLP, LSTM, CNN, NARX, ANFIS, red optimizada con GA o PSO
Variante (opcional, suma en la rúbrica)	Atribuye la mejora a una decisión concreta	Estudio de ablación: con y sin exógenas, con y sin optimización evolutiva

Preguntas que debe responder la justificación

1. ¿Qué propiedad de los datos aprovecha el modelo propuesto (no linealidad, dependencia temporal, estructura espacial, incertidumbre lingüística, espacio de búsqueda grande)?
2. ¿Qué modelos obtuvieron los mejores resultados en la matriz del estado del arte y por qué se eligió este?
3. ¿Cuántos parámetros tiene el modelo y es razonable para el tamaño del conjunto de datos?
4. ¿Cabe el entrenamiento en el presupuesto de cómputo (Colab gratuito o MATLAB en equipo personal) y en el tiempo del proyecto?

Regla de oro: los modelos y sus espacios de hiperparámetros se fijan antes de ver el conjunto de prueba; los modelos se registran en el entregable 2 y los espacios de hiperparámetros en el entregable 3.

Fase 4. Preprocesamiento sin fuga de información · Etapa 2 CRISP-ML(Q) (semana 3: 16 al 22 de noviembre)

La regla que gobierna esta fase: **primero se parten los datos y después se ajusta cualquier transformación, usando solo el entrenamiento**. Escalar, imputar, seleccionar variables o balancear clases con todo el conjunto filtra información de la prueba y produce resultados optimistas que no se repiten en la práctica.

Partición según el tipo de datos

Tipo de datos	Partición correcta
Observaciones independientes	Aleatoria estratificada: 70 % entrenamiento, 15 % validación, 15 % prueba (o validación cruzada de k pliegues sobre el 85 % de desarrollo)
Series de tiempo	Por bloques en orden temporal; validación de origen móvil; la prueba es el tramo final
Varias mediciones por sujeto, paciente o equipo	Por grupos: todas las mediciones de un sujeto quedan del mismo lado
Datos espaciales	Por bloques o regiones, para no evaluar con vecinos casi idénticos

Pasos del pipeline (cada transformación se ajusta con entrenamiento y se aplica igual a validación y prueba)

Paso	Qué hacer	Qué reportar
Limpieza	Eliminar duplicados, corregir tipos y unidades, revisar rangos físicamente imposibles	Registros eliminados y por qué
Faltantes	Imputación simple (mediana, interpolación temporal) o por modelo; indicador de faltante si es informativo	Porcentaje imputado por variable y método
Atípicos	Detectar (IQR, z robusto, STL robusta); decidir si son error o fenómeno real	Criterio y número tratado
Codificación	One-hot u ordinal para categóricas; codificación cíclica (seno, coseno) para hora o mes	Variables resultantes

Paso	Qué hacer	Qué reportar
Escalado	Estandarización o min-max, obligatorio para redes y métodos basados en distancia	Parámetros calculados solo con entrenamiento
Ingeniería de variables	Retardos, ventanas móviles, interacciones, variables de dominio	Justificación de cada variable creada
Selección de variables	Filtros, importancia o búsqueda evolutiva, dentro de la validación cruzada	Variables finales
Balanceo	SMOTE, submuestreo o pesos de clase, solo en entrenamiento	Distribución antes y después

Fase 5. Definición de métricas y pruebas estadísticas · Etapa 3 CRISP-ML(Q) (semana 3: 18 al 22 de noviembre)

Las métricas se eligen antes de entrenar y se declaran en el entregable 3. Se nombra una **métrica principal**, la que decide qué modelo gana, y dos o tres secundarias que muestran otros aspectos del desempeño.

Tarea	Métrica principal sugerida	Secundarias	Prueba de significancia
Regresión	RMSE o MAE (en unidades de la variable)	R^2, MAPE si no hay valores cercanos a cero	Wilcoxon pareado sobre errores absolutos; t pareada por pliegues
Series de tiempo	MASE o RMSE por horizonte	MAE, sMAPE, RMSE(h)	Diebold-Mariano (con corrección de Harvey, Leybourne y Newbold)
Clasificación balanceada	Exactitud o F1 macro	Matriz de confusión, AUC-ROC	McNemar sobre las mismas observaciones de prueba
Clasificación desbalanceada	F1 macro, AUC-PR o exactitud balanceada	Sensibilidad y especificidad por clase, MCC	McNemar; intervalos bootstrap
Agrupamiento	Silueta (sin etiquetas) o ARI (con etiquetas)	Davies-Bouldin, Calinski-Harabasz	Estabilidad por remuestreo
Optimización	Mejor valor de la función objetivo	Media y desviación en 30 ejecuciones, curva de convergencia, evaluaciones de la función	Wilcoxon o Mann-Whitney entre algoritmos; Friedman + Nemenyi si son más de dos

Reglas de reporte

1. Toda métrica de prueba lleva su incertidumbre: intervalo de confianza del 95 % por bootstrap o media ± desviación en varias semillas.
2. Una diferencia sin prueba de significancia se reporta como «diferencia observada», no como «el modelo es mejor».
3. Si se comparan más de dos modelos en varios conjuntos o pliegues, usar Friedman con prueba posterior de Nemenyi (Demšar, 2006).
4. Reportar también el costo: tiempo de entrenamiento, tiempo de inferencia y número de parámetros.

Fase 6. Entrenamiento y ajuste de hiperparámetros · Etapa 3 CRISP-ML(Q) (semana 4: 23 al 29 de noviembre)

Esta fase es la que más tiempo consume. Conviene empezar con un experimento pequeño que corra de punta a punta y después ampliarlo, en lugar de diseñar el experimento completo y descubrir errores el último día.

Orden de trabajo

1. **Prueba de humo**: entrenar el modelo propuesto con pocos datos y pocas épocas para verificar que el pipeline corre y que la pérdida baja. Una red debe poder sobreajustar un lote pequeño; si no lo logra, hay un error.
2. **Referencias**: entrenar la referencia trivial y la clásica con el mismo pipeline y la misma partición.
3. **Búsqueda de hiperparámetros** del modelo propuesto sobre la validación (nunca sobre la prueba): búsqueda aleatoria, en rejilla, bayesiana (Optuna, `bayesopt` en MATLAB) o, si el paradigma lo permite, evolutiva o por enjambre.
4. **Análisis de sensibilidad**: variar al menos dos hiperparámetros en tres niveles cada uno y presentar un mapa de calor o tabla con media ± desviación.
5. **Repetibilidad**: reentrenar la configuración final con al menos 5 semillas distintas y reportar la variabilidad.

Hiperparámetros típicos por paradigma

Paradigma	Hiperparámetros a explorar
Redes neuronales	Capas y neuronas, activación, tasa de aprendizaje, tamaño de lote, regularización (L2, dropout), paciencia de parada temprana, retardos o ventana
Sistemas difusos	Número y tipo de funciones de pertenencia, número de reglas, método de inferencia y defuzzificación, épocas de ANFIS
Evolutivos	Tamaño de población, probabilidades de cruce y mutación, selección, número de generaciones, elitismo
Enjambre (PSO)	Número de partículas, inercia, coeficientes cognitivo y social, límites de velocidad, iteraciones

Registro de experimentos: cada corrida se anota en una hoja o en un archivo CSV con fecha, configuración, semilla, métrica de validación, tiempo y observaciones. Esta tabla alimenta directamente la sección de Experimentación del artículo y es parte del entregable.

Presupuesto de cómputo: calcular antes de lanzar la búsqueda cuántos entrenamientos implica (configuraciones × pliegues × semillas) y cuánto dura cada uno. Si supera unas 3 horas en Colab, reducir la rejilla o usar búsqueda aleatoria.

Fase 7. Prueba de los modelos y análisis de resultados · Etapa 4 CRISP-ML(Q) (semana 5: 30 de noviembre y 1 de diciembre)

Con las configuraciones congeladas, todos los modelos se evalúan **una sola vez** en el conjunto de prueba. Si después de ver la prueba se cambia algo, ese cambio y su efecto se declaran en el artículo como análisis posterior.

Qué debe producir esta fase

1. **Tabla de resultados**: todas las métricas para los tres o más modelos, con intervalo de confianza o media ± desviación, tiempo y número de parámetros.
2. **Prueba de significancia** entre el modelo propuesto y cada referencia, con estadístico y valor p.
3. **Análisis de errores**: dónde falla el modelo. Según la tarea: residuos en el tiempo y su ACF, matriz de confusión con ejemplos mal clasificados, error por rango de la variable objetivo o por grupo.
4. **Comparación con la literatura**: ubicar el resultado frente a los valores de la matriz del estado del arte, aclarando si los datos y el protocolo son comparables.
5. **Interpretabilidad**: al menos un análisis que explique el modelo. Por ejemplo, importancia por permutación o SHAP, curvas de respuesta parcial (como la de temperatura en NARX), reglas difusas activadas o variables seleccionadas por el algoritmo evolutivo.
6. **Robustez** (recomendado): comportamiento ante ruido añadido, datos faltantes o un periodo distinto.

Figuras mínimas: curva de aprendizaje del modelo propuesto, gráfica de predicho contra real (o matriz de confusión), gráfica del análisis de sensibilidad y comparación de modelos con barras de error.

Fase 8. Informe en formato de artículo y sustentación · Etapas 5 y 6 CRISP-ML(Q) (semanas 1 a 5, cierre del 30 de noviembre al 3 de diciembre)

El informe es un artículo de conferencia en la plantilla IEEE (dos columnas), de 8 a 10 páginas sin contar referencias ni anexos, en español, con título, resumen y palabras clave también en inglés. Se acepta la plantilla Springer LNCS con la misma estructura. La redacción es progresiva: los entregables 1 a 4 ya contienen los borradores de las secciones II a IV, y la semana 5 se dedica a Resultados, Discusión, Conclusiones, resumen y revisión final.

Sección	Contenido mínimo	Extensión orientativa
Título, autores, resumen y palabras clave	Problema, método, resultado principal con su cifra y conclusión, en 150–250 palabras	—
I. Introducción	Contexto y relevancia, pregunta de investigación, contribuciones en viñetas, organización del artículo	0,75 pág.
II. Estado del arte	Síntesis crítica por enfoques (no un resumen artículo por artículo), tabla comparativa reducida, diagrama tipo PRISMA y brecha	1,5 pág.
III. Metodología	Proceso seguido según las etapas de CRISP-ML(Q), ficha del dataset, análisis exploratorio, preprocesamiento, partición, formulación matemática de cada modelo, métricas, pruebas estadísticas, declaración de no fuga	2 pág.
IV. Experimentación	Hardware y software, espacios de hiperparámetros, método de búsqueda, semillas, criterios de parada, presupuesto de cómputo	1 pág.
V. Resultados	Tabla de resultados con incertidumbre, pruebas de significancia, sensibilidad, análisis de errores, interpretabilidad	2 pág.
VI. Discusión	Cumplimiento del criterio de éxito fijado en la etapa 1, por qué gana o pierde el modelo, comparación con la literatura, limitaciones y amenazas a la validez, costo, ética, viabilidad y plan de monitoreo y mantenimiento (etapa 6)	1 pág.
VII. Conclusiones y trabajo futuro	Respuesta directa a la pregunta de investigación	0,5 pág.
Referencias	Formato IEEE numerado; mínimo 15, todas citadas en el texto	—

Sección	Contenido mínimo	Extensión orientativa
Anexo de reproducibilidad	Enlace al repositorio o cuaderno, versiones de librerías, semillas, instrucciones para reproducir la tabla principal	—

Entregables finales (jueves 3 de diciembre, 23:59, un envío por equipo en Classroom)

1. Artículo en PDF.
2. Código ejecutado con salidas visibles: cuaderno de Colab o scripts de MATLAB, con un `README` que explique cómo reproducir los resultados.
3. Registro de experimentos (CSV u hoja de cálculo).
4. Presentación de la sustentación (8 a 10 diapositivas).

Estructura sugerida del repositorio o carpeta

```
proyecto/
├── README.md            # problema, cómo ejecutar, versiones
├── datos/               # crudos (o enlace de descarga) y procesados
├── cuadernos/           # 01_exploracion, 02_preprocesamiento, 03_modelos,
04_resultados
├── src/                 # funciones reutilizables
├── resultados/          # tablas, figuras, registro_experimentos.csv
└── articulo/            # fuente LaTeX o Word y PDF final
```

Sustentación (viernes 4 de diciembre): 12 minutos de exposición y 5 de preguntas. Todos los integrantes presentan y responden. Estructura sugerida: problema y brecha (2 min), datos y metodología (4 min), resultados con prueba de significancia (4 min), limitaciones y conclusión (2 min).

Uso de herramientas de IA generativa: se permite como apoyo para programar, revisar redacción o traducir, siempre que se declare en una nota al final del artículo qué herramienta se usó y para qué. El equipo responde por cada cifra, referencia y línea de código; las referencias inexistentes o resultados no reproducibles se califican como insuficientes.

Entregables semanales y calificación

La nota del proyecto se reparte en seis momentos: cuatro entregables semanales, la entrega final y la sustentación.

Momento	Fecha y hora	Qué se entrega	Peso
Entregable 1	Dom 8 nov, 23:59	Propuesta y estado del arte: problema, pregunta, criterio de éxito medible, ecuación y conteo de la búsqueda, matriz (≥ 15 trabajos) y borrador de la sección II del artículo	10 %
Entregable 2	Dom 15 nov, 23:59	Datos y modelos: ficha y validación D1–D7 del dataset, análisis exploratorio, tres modelos con su papel y justificación, borrador de la Metodología (datos y modelos)	10 %
Entregable 3	Dom 22 nov, 23:59	Pipeline sin fuga, partición, métricas y pruebas declaradas, resultados de validación de las dos referencias, espacio de hiperparámetros del modelo propuesto, Metodología completa	10 %
Entregable 4	Dom 29 nov, 23:59	Entrenamiento: registro de experimentos, análisis de sensibilidad, 5 semillas, configuración final congelada y sección IV (Experimentación)	10 %
Entrega final	Jue 3 dic, 23:59	Artículo IEEE completo, código ejecutado con README, registro de experimentos, presentación	40 % (rúbrica)
Sustentación	Vie 4 dic	Exposición de 12 min y 5 de preguntas	20 %

Los entregables semanales tardíos pierden 10 % de su valor por cada día de retraso, hasta un máximo de dos días; la entrega final no admite retraso porque la sustentación es al día siguiente. La nota de la sustentación es individual: cada integrante debe poder explicar cualquier parte del trabajo.

Rúbrica de evaluación de la entrega final (100 puntos)

La rúbrica califica el artículo y el código (40 % de la nota del proyecto). Cada nivel equivale a un porcentaje fijo del criterio: Excelente 100 %, Bueno 80 %, Regular 60 %, Insuficiente 0–40 %.

Criterio (puntos)	Excelente (100 %)	Bueno (80 %)	Regular (60 %)	Insuficiente (0–40 %)
1. Estado del arte y planteamiento (15)	**15 pts.** Búsqueda documentada con ecuación y conteo tipo PRISMA; ≥ 15 trabajos pertinentes (≥ 10 recientes) sintetizados por enfoques; brecha clara y pregunta de investigación precisa.	**12 pts.** Revisión suficiente y pertinente; síntesis parcial o brecha poco conectada con la propuesta.	**9 pts.** Pocos trabajos o desactualizados; resumen artículo por artículo sin síntesis; pregunta vaga.	**0–6 pts.** Sin revisión formal, fuentes no académicas o referencias inexistentes.
2. Datos y preprocesamiento (15)	**15 pts.** Ficha completa del dataset y criterios D1–D7 verificados; análisis exploratorio que orienta decisiones; partición adecuada al tipo de datos; pipeline sin ninguna fuga y documentado.	**12 pts.** Datos adecuados y pipeline correcto con documentación incompleta.	**9 pts.** Exploración superficial o partición discutible; una fuga menor (p. ej., escalado con todo el conjunto).	**0–6 pts.** Datos inadecuados o sin describir; partición aleatoria en series de tiempo o fuga grave.
3. Modelado y experimentación (25)	**25 pts.** Tres o más modelos con papeles claros y justificados; formulación matemática correcta; búsqueda de hiperparámetros sobre validación;	**20 pts.** Cumple los mínimos con justificación o registro parcial; sin ablación.	**15 pts.** Falta una referencia, el ajuste de hiperparámetros o la sensibilidad; una sola semilla.	**0–10 pts.** Un solo modelo, sin referencias, o hiperparámetros elegidos sobre la prueba.

Criterio (puntos)	Excelente (100 %)	Bueno (80 %)	Regular (60 %)	Insuficiente (0–40 %)
	sensibilidad de ≥ 2 hiperparámetros; ≥ 5 semillas; registro de experimentos completo; ablación o variante.			
4. Evaluación y análisis crítico (25)	**25 pts.** Métrica principal declarada antes de entrenar; resultados con incertidumbre; prueba de significancia correcta; análisis de errores e interpretabilidad; comparación honesta con la literatura; limitaciones, costo y ética discutidos; conclusión que responde la pregunta.	**20 pts.** Evaluación completa con interpretación de causas poco profunda o limitaciones genéricas.	**15 pts.** Tablas y figuras descritas más que interpretadas; sin prueba de significancia o sin incertidumbre.	**0–10 pts.** Una sola métrica; conclusiones que contradicen los resultados o no sustentadas.
5. Artículo y reproducibilidad (20)	**20 pts.** Plantilla IEEE correcta, 8–10 páginas, todas las secciones, redacción técnica precisa, figuras y tablas numeradas y citadas, ≥ 15 referencias en formato IEEE; código corre de punta a punta con	**16 pts.** Formato y código correctos con errores menores de redacción, citación o documentación.	**12 pts.** Falta una sección o la extensión no se ajusta; código requiere correcciones para correr.	**0–8 pts.** Sin formato científico, código que no corre o resultados no reproducibles; plagio.

Criterio (puntos)	Excelente (100 %)	Bueno (80 %)	Regular (60 %)	Insuficiente (0–40 %)
	README y reproduce la tabla principal.			

Configuración en Google Classroom: en la tarea de la entrega final, *Rúbrica → Crear rúbrica*, activar *Usar puntuación* y crear los cinco criterios con cuatro niveles cada uno, pegando los descriptores de la tabla.

```
Criterio,Puntos máx.,Excelente,Bueno,Regular,Insuficiente
1. Estado del arte y planteamiento,15,15,12,9,6
2. Datos y preprocesamiento,15,15,12,9,6
3. Modelado y experimentación,25,25,20,15,10
4. Evaluación y análisis crítico,25,25,20,15,10
5. Artículo y reproducibilidad,20,20,16,12,8
```

Lista de verificación antes de entregar

Revisen cada punto en equipo antes del jueves 3 de diciembre.

Estado del arte y datos

- ☐ La pregunta de investigación aparece en la Introducción y se responde en las Conclusiones, junto con si se alcanzó el criterio de éxito.
- ☐ Hay al menos 15 referencias académicas, todas existen y todas están citadas en el texto.
- ☐ La ficha del dataset incluye fuente, licencia, tamaño, variables y unidades.

Preprocesamiento y modelos

- ☐ La partición respeta el tiempo, los grupos o la estratificación según corresponda.
- ☐ Todo escalado, imputación, selección de variables y balanceo se ajustó solo con entrenamiento.
- ☐ Hay una referencia trivial, una clásica y el modelo propuesto, con el mismo pipeline y la misma partición.
- ☐ Los hiperparámetros se eligieron con validación; la prueba se usó una sola vez.
- ☐ El modelo final se reentrenó con al menos 5 semillas.

Resultados

- ☐ La métrica principal se declaró en el entregable 3 y es la que decide.
- ☐ Cada métrica de prueba tiene intervalo de confianza o media ± desviación.
- ☐ Hay prueba de significancia entre el modelo propuesto y cada referencia.
- ☐ Hay análisis de errores y al menos un análisis de interpretabilidad.
- ☐ Se reportan tiempos y número de parámetros.

Artículo y código

- ☐ El artículo usa la plantilla IEEE y tiene entre 8 y 10 páginas sin referencias.
- ☐ Todas las figuras y tablas están numeradas, tienen título y se mencionan en el texto.
- ☐ El código corre de punta a punta en una sesión nueva de Colab o MATLAB y reproduce la tabla principal.
- ☐ El README indica versiones, semillas y pasos para reproducir.
- ☐ La nota sobre uso de IA generativa está incluida.
- ☐ La presentación de la sustentación está lista y cada integrante sabe explicar todo el trabajo.

Fuentes y guías metodológicas

Lecturas de apoyo para cada fase; no reemplazan la revisión del estado del arte propia del tema.

Fase	Referencia	Para qué sirve
1	Page, M. J., McKenzie, J. E., Bossuyt, P. M., et al. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ*, 372, n71. https://doi.org/10.1136/bmj.n71	Diagrama de flujo y reporte de la búsqueda
2	Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92.	Ficha del conjunto de datos
4	Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*.	Tipos de fuga de información y cómo evitarlos
5	Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7, 1–30.	Pruebas de Wilcoxon, Friedman y Nemenyi
5	Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.	Comparación de pronósticos (ya usada en los talleres)
8	IEEE Conference Template en Overleaf	Plantilla oficial del artículo en LaTeX; la versión Word está en el sitio de plantillas de IEEE
Marco	Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. Machine Learning and Knowledge Extraction, 3(2), 392–413. https://doi.org/10.3390/make3020020	Metodología por etapas con aseguramiento de calidad que estructura el proyecto
Marco	Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS.	Estándar original de seis fases del que deriva CRISP-ML(Q)